

The top banner features the Fudan University logo on the left, which includes the university's name in English ('FUDAN UNIVERSITY') and Chinese ('復旦大學') along with the founding year '1905'. To the right of the logo are several interlocking blue gears. Some of these gears contain white icons: a building, a graduation cap, a medical bag with a cross, a person silhouette, and an atomic symbol. The background of the banner is light blue with a dark blue curved shape on the far right.

人工智能的数学基础

01 事件与概率

李 斌

复旦大学 计算机科学技术学院

什么是概率？

■ 必然现象：一定条件下必然会发生——可以确切预测

- 在一个标准大气压下水加热到 100°C 必然会沸腾
- 用手向上抛一重物必然会落下
- 平面上任意三角形的两边之和大于第三边

■ 随机现象：**相同**条件下多次试验^①会得到**多种结果**，在一次试验中无法预知哪个结果会发生，但大量重复试验的结果会呈现一定规律


- 射击 → 位置预测
- 掷骰子 → 类别预测
- 手机使用寿命 → 时间预测
- 视频点击数 → 指标预测
-

人工智能中的任务大多具有随机性

^①试验包括观测。

什么是概率？

- **概率**，又称或然率、几率，是表示某种情况（事件）出现的可能性大小的一种数量指标，它介于0与1之间，也常以百分数来表示
- **概率论**研究随机现象的模型（即概率分布）及其性质，是研究**随机现象数量规律**的数学分支



随机事件

- **随机试验：**对随机现象作一次观察（或记录、实验）称为随机试验，这些试验具有以下特点
 - 可以在相同的条件下重复进行
 - 每次试验出现的结果不确定，但能事先知道试验所有可能的结果
- **样本空间：**随机试验的所有可能结果组成的集合称为样本空间，记为 Ω ；样本空间中的每一个元素称为样本点
 - 抛硬币 $\Omega = \{\text{正面}, \text{反面}\}$
 - 投篮5次命中次数 $\Omega = \{0, 1, 2, 3, 4, 5\}$
 - 掷骰子 $\Omega = \{1, 2, 3, 4, 5, 6\}$
 - 手机使用寿命 $\Omega = (0, +\infty)$

随机事件

- 随机事件：样本空间 Ω 的任一子集称为随机事件
- 在概率论中，“事件”不是指已发生了的情况，而是与试验结果有关的一个命题，其正确与否取决于试验结果
 - $A = \{\text{投篮5次至多有3次投中}\} = \{0, 1, 2, 3\}$
 - $B = \{\text{掷骰子朝上的一面是偶数}\} = \{2, 4, 6\}$
 - $C = \{\text{手机寿命超过5年}\} = \{x: x \geq 5\}$
- 在概率论中，单一的试验结果称为一个基本事件（即只含有一个样本点的子集），一个或多个基本事件构成一个事件
 - 掷骰子有6个基本事件
 - $\{2, 4, 6\}$ 构成事件{掷骰子朝上的一面是偶数}
 - Ω 为必然事件，概率为1，例如{掷骰子点数不超过6}
 - $\emptyset$ 为不可能事件，概率为0

古典概率

- 假定某个试验有 N 个可能结果，所有结果在试验中有**同等可能**的出现机会，即 $1/N$ ，则把试验结果称为“等可能的”
 - 掷硬币 $1/2$
 - 掷骰子 $1/6$
 - 抽黑桃A $1/54$
- 设一个试验有 N 个**等可能的结果**，而事件 E 包含其中的 M 个结果，则事件 E 的概率定义为


$$P(E) = \frac{1}{N} \cdot M = \frac{M}{N}$$

■ 坛子模型

- 一个坛子中有 N 个大小和质地完全一样的球，其中 M 个为白球其余为黑球，将这些球彻底扰乱后从坛子中摸出白球的概率为 M/N

几何概率

- 古典概率仅能用于全部试验结果为**有限个**且**等可能**成立的情况
- 可以把‘等可能’引申到试验结果有**无限多个**的情况
- 例：甲乙约定1点到2点之间在某处碰头，先到者等10分钟离去，假设两人各自在1点到2点之间随意选择一个时刻到达，问甲乙相遇的概率



所有等可能结果范围 $(x, y) \in \{\text{正方形区域}\}$

满足甲乙相遇条件结果的范围 $(x, y) \in \{\text{阴影区域}\}$

$$P(\{\text{甲乙相遇}\}) = \frac{1100}{3600} = \frac{11}{36}$$

- 几何概率：把等可能性解释为“等面积^①、等概率”

^①可以是长度、体积等任何测度。

概率的统计意义

- 虽然随机事件在某次试验中可以出现也可以不出现，但在大量试验中它却呈现出明显的规律性——**频率稳定性**
- 对于随机事件 A ，若在 N 次试验中出现 M 次，则称 $F_N(A) = \frac{M}{N}$ 为随机事件 A 在 N 次试验中出现的**频率**
- 著名的抛硬币试验

历史上抛掷硬币测试的记录

试验者	试验次数(n)	正面次数(r_n)	正面频率(r_n/n)
DeMorgan	2048	1061	0.5158
Buffon	4040	2048	0.5069
Pearson	12000	6019	0.5016
Pearson	24000	12012	0.5005

- **概率的统计意义**：通过试验估计事件概率的方法
- 频率是概率的估计，概率是当试验次数无限增大时频率的极限

概率的公理化定义

- 1933年，前苏联数学家柯尔莫哥洛夫成功将概率论公理化，他提出的公理为数很少且极为简单，在此基础上建立起了概率论
- 样本点 ω ：试验可能出现的结果
- 样本空间 Ω ：全体样本点的集合
- 事件：由 Ω 的子集（包括 Ω 本身与空集 $\emptyset$ ）构成一个集类 $\mathcal{F}^{\textcircled{1}}$ ， $\mathcal{F}$ 不必包含 Ω 的一切可能子集， $\mathcal{F}$ 中的每个成员就称为事件
- 基本事件：只含有一个样本点的子集 $\{\omega\}$

^① $\mathcal{F}$ 是由 Ω 的一些子集构成的 σ -代数。

安德雷·尼古拉耶维奇·柯
尔莫哥洛夫（1903—1987）



概率的公理化定义

■ 概率论公理：对 $\mathcal{F}$ 中任一事件 A ，定义事件 A 的概率 $P(A)$ 满足：

① 非负性 $P(A) \geq 0$

② 规范性 $P(\Omega) = 1$

③ 可列可加性 $P(A_1 \cup A_2 \cup \cdots) = P(A_1) + P(A_2) + \cdots$ （事件两两互斥）

样本空间与事件

- 例：掷骰子

$$\Omega = \{1,2,3,4,5,6\}, A = \{\text{掷出偶数点}\} = \{2,4,6\}$$

- 例：打靶5次射中次数

$$\Omega = \{0,1,2,3,4,5\}, A = \{\text{至少3次击中}\} = \{3,4,5\}$$

- 例：量血压

$$\Omega = \{(x, y): 0 \leq x < y \leq 300\},$$

$$A = \{\text{正常血压}\} = \{(x, y): 60 \leq x \leq 90, 90 \leq y \leq 140\}$$

- 例：甲乙碰头（见几何概率例题）

$$\Omega = \{(x, y): 0 \leq x, y \leq 60\},$$

$$A = \{\text{甲乙相遇}\} = \{(x, y): 0 \leq x, y \leq 60, |x - y| \leq 10\}$$

排列与组合

- 古典概率计算 $P(A) = \frac{M}{N}$ 归结为 M 与 N 的计数，涉及排列与组合
- 排列要考虑次序而组合不需要： ab 和 ba 是不同排列、相同组合
- n 个相异物件取 r ($1 \leq r \leq n$)个的不同排列总数

$$P_n^r = n(n-1)(n-2) \dots (n-r+1) = \frac{n!}{(n-r)!}$$

- n 个相异物件取 r ($1 \leq r \leq n$)个的不同组合总数

$$C_n^r = \frac{P_n^r}{P_r^r} = \frac{n!}{r!(n-r)!}$$

- 组合更通用的符号为 $\binom{n}{r}$ ，本课程使用该符号

排列与组合

- $\binom{n}{r}$ 又称为**二项式系数**，因为出现在二项展开式中

$$(a + b)^n = \sum_{i=0}^n \binom{n}{i} a^i b^{n-i}$$

- n 个相异物件分成 k 堆，各堆物件数分别为 $r_1, \dots, r_k$ 的分法是

$$\frac{n!}{r_1! \dots r_k!}$$

- 上式称为**多项式系数**，因为它是 $(x_1 + \dots + x_k)^n$ 的展开式中 $x_1^{r_1} \dots x_k^{r_k}$ 这一项的系数

古典概率的计算

- 例：一批产品共 N 个，其中废品有 M 个，现从中随机取出 n 个，问事件 $E = \{\text{其中恰好有 } m \text{ 个废品}\}$ 的概率 $P(E)$

$$P(E) = \frac{|E|}{|\Omega|} = \frac{\binom{M}{m} \binom{N-M}{n-m}}{\binom{N}{n}}$$

$\binom{M}{m}$ 个废品取法与 $\binom{N-M}{n-m}$ 合格品取法的所有组合数

- 例： n 双相异的鞋共 $2n$ 只，随机分成 n 堆，每堆2只，问事件 $E = \{\text{各堆都自成一双鞋}\}$ 的概率 $P(E)$

$$P(E) = \frac{|E|}{|\Omega|} = \frac{n!}{(2n)!/(2!)^n} = \frac{2^n n!}{(2n)!}$$

基于公式 $\frac{n!}{r_1! \dots r_k!}$ ，所有可能结果数为 $2n$ 只鞋子分成 n 堆的组合数

① $|E|$ 表示事件 E 包含结果的数量； $|\Omega|$ 表示试验所有可能结果的数量。

古典概率的计算

- 例： n 个男孩， m 个女孩（ $m \leq n + 1$ ）随机排成一列，问事件 $E = \{\text{任意两个女孩都不相邻}\}$ 的概率 $P(E)$

$$P(E) = \frac{|E|}{|\Omega|} = \frac{n! \binom{n+1}{m} m!}{(n+m)!}$$

先对 n 个男孩全排列 $n!$ ，再在 $n+1$ 的位置选出 m 个给女孩 $\binom{n+1}{m}$ ，再对 m 个女孩全排列 $m!$

- 例：有 21 本不同的书，随机分给 17 人，问事件 $E = \{\text{有 6 人得 0 本，5 人得 1 本，2 人得 2 本，4 人得 3 本}\}$ 的概率 $P(E)$

$$P(E) = \frac{|E|}{|\Omega|} = \frac{\frac{17!}{6!5!2!4!} \cdot \frac{21!}{(0!)^6(1!)^5(2!)^2(3!)^4}}{17^{21}}$$


基于公式 $\frac{n!}{r_1! \dots r_k!}$ ，17 人分成 6,5,2,4 四堆，分法有 $\frac{17!}{6!5!2!4!}$ 种；21 本书分成 0,0,0,0,0,0,1,1,1,1,1,2,2,3,3,3,3 十七堆，分法有 $\frac{21!}{(0!)^6(1!)^5(2!)^2(3!)^4}$ 种

事件的运算


- 样本空间 Ω 为全集，事件为子集，因此事件的运算为**集合运算**
- 设 A 与 B 为同一样本空间 Ω 中的两个事件，若 B 发生时一定导致 A 发生，则称事件 A **包含**事件 B ，记为 $B \subset A$ ；若 $B \subset A$ 的同时 $A \subset B$ ，则称事件 A 与事件 B **相等**，记为 $A = B$
 - 掷两粒骰子： $A = \{\text{点数之和大于10}\}$ ； $B = \{\text{至少一粒掷出6}\}$ ；即 $A \subset B$
 - 掷两粒骰子： $A = \{\text{两个点数奇偶不同}\}$ ； $B = \{\text{两个点数之和为奇数}\}$ ；即 $A = B$
- 若事件 A 与事件 B 不能在同一次试验中都发生（但可以都不发生），则称它们是**互斥**的；如果一些事件中任意两个都互斥，则称两两互斥
 - 掷一粒骰子： $E_i = \{\text{掷出的点数为}i\text{的倍数}\}$ ； $i = 2, 3, 4$ ，则 $E_3 = \{3, 6\}$ 与 $E_4 = \{4\}$ 互斥， $E_2 = \{2, 4, 6\}$ 与 $E_3 = \{3, 6\}$ 不互斥
- 互斥事件的一个特殊情况是**对立事件** $\bar{A} = \{A\text{不发生}\}$ ，注意到 $A \cup \bar{A} = \Omega$ ， $A \cap \bar{A} = \emptyset$ ，因此又称为逆事件
 - 掷骰子： $A = \{\text{掷出奇数点}\}$ ； $B = \{\text{掷出偶数点}\}$ ；即 $\bar{A} = B$

事件的运算


- 事件的和 $A \cup B$: A 与 B 至少发生一个, $A \cup B = \{x: x \in A \text{ 或 } x \in B\}$
- 事件的积 $A \cap B$ 或 AB : A 与 B 同时发生, $A \cap B = \{x: x \in A \text{ 且 } x \in B\}$
- 事件的差 $A - B$: A 发生而 B 不发生, $A - B = \{x: x \in A \text{ 且 } x \notin B\} = A\bar{B}$




Ω




A




$\bar{A}$



$A \cup B$



$A \cap B$



$A - B$

事件的运算

- 交换律: $A \cup B = B \cup A$, $AB = BA$
- 结合律: $(A \cup B) \cup C = A \cup (B \cup C)$, $(AB)C = A(BC)$
- 分配律: $(A \cup B) \cap C = AC \cup BC$, $(A \cap B) \cup C = (A \cup C) \cap (B \cup C)$
- 德摩根定律: $\overline{A \cup B} = \bar{A} \cap \bar{B}$, $\overline{A \cap B} = \bar{A} \cup \bar{B}$

推广到多个事件 $A_1, \dots, A_n$ 的情形:

- 事件的和 $\bigcup_{i=1}^n A_i$
- 事件的积 $\bigcap_{i=1}^n A_i$
- 德摩根定律: $\overline{\bigcup_{i=1}^n A_i} = \bigcap_{i=1}^n \bar{A}_i$ n个事件至少有一个发生的逆事件为n个事件都不发生
 $\overline{\bigcap_{i=1}^n A_i} = \bigcup_{i=1}^n \bar{A}_i$ n个事件都发生的逆事件为这n个事件至少有一个不发生

概率的性质

- 可列可加性（公理③）：若干个（可以有限也可以无限）**互斥**事件之和的概率等于各事件的概率之和，即

$$P(A_1 \cup A_2 \cup \dots) = P(A_1) + P(A_2) + \dots$$

基于古典概率定义可得：

$$P(A) = \frac{M_1 + M_2 + \dots}{N}$$

事件 A_i 发生的结果数为 M_i ，由于事件两两互斥，因此和事件 $A = A_1 \cup A_2 \cup \dots$ 发生的结果数为 $M_1 + M_2 + \dots$

$$= \frac{M_1}{N} + \frac{M_2}{N} + \dots$$

$$= P(A_1) + P(A_2) + \dots$$

- 由 $P(A) + P(\bar{A}) = P(\Omega) = 1$ 得 **$P(\bar{A}) = 1 - P(A)$** ，该公式可以把计算 $P(A)$ 转为计算 $P(\bar{A})$

概率的性质

- 当 $B \subset A$ 时, $P(A) \geq P(B)$

证明: 当 $B \subset A$ 时, $A = B \cup A\bar{B}$ 画图显见

$$\Rightarrow P(A) = P(B) + P(A\bar{B}) = P(B) + P(A - B)$$

所以 $P(A - B) = P(A) - P(B)$,

因为 $P(A - B) \geq 0$, 因此 $P(A) \geq P(B)$

- 概率的加法公式:

$$P(A \cup B) = P(A) + P(B) - P(AB)$$

证明: 因为 $A = AB \cup A\bar{B} \Rightarrow P(A) = P(AB) + P(A\bar{B})$

$$\Rightarrow P(A\bar{B}) = P(A) - P(AB)$$

又因为 $A \cup B = A\bar{B} \cup B \Rightarrow P(A \cup B) = P(B) + P(A\bar{B})$

所以 $P(A \cup B) = P(A) + P(B) - P(AB)$

概率的性质

- 例：甲乙赶火车，已知甲、乙能赶上的概率分别为0.7与0.8，甲乙都赶上的概率为0.6，求甲乙都没赶上的概率

解：设 $A = \{\text{甲赶上}\}$ ， $B = \{\text{乙赶上}\}$

由题意可知 $P(A) = 0.7$ ， $P(B) = 0.8$ ， $P(AB) = 0.6$

$$\begin{aligned}P(\text{甲乙都没赶上}) &= P(\bar{A}\bar{B}) = P(\overline{A \cup B}) = 1 - P(A \cup B) \\&= 1 - (P(A) + P(B) - P(AB)) = 0.1\end{aligned}$$

- 例：【德梅尔问题】一颗骰子投4次至少得到一个六点与两颗骰子投24次至少得到一个双六，哪个概率更大？

解：设 $A_n = \{\text{一颗骰子第}n\text{次得六点}\}$ ， $B_n = \{\text{两颗骰子第}n\text{次得双六}\}$

$$P(\overline{\cap_{n=1}^4 A_n}) = 1 - P(\cap_{n=1}^4 \bar{A}_n) = 1 - (1 - P(A_n))^4 = 1 - \left(\frac{5}{6}\right)^4 = 0.52$$

$$P(\overline{\cap_{n=1}^{24} B_n}) = 1 - P(\cap_{n=1}^{24} \bar{B}_n) = 1 - (1 - P(B_n))^{24} = 1 - \left(\frac{35}{36}\right)^{24} = 0.49$$

概率的性质

■ 例：【生日问题】一个班级 n 个人中至少有两人同一天生日的概率

解：设 $A = \{\text{至少有两人同一天生日}\}$

直接求 $P(A)$ 很困难，可以通过求 $P(\bar{A})$ 得到，即 $\bar{A} = \{\text{每人生日都不同}\}$

$$P(A) = 1 - P(\bar{A}) = 1 - \frac{|\bar{A}|}{|\Omega|} = 1 - \frac{\binom{365}{n} n!}{365^n}$$

$P(\bar{A})$ 可由古典概率计算，其中分母 365^n 为 n 个人生日的所有可能数，分子为 n 个人生日各不相同的可能数：从365中选 n 天， n 人全排列

n	5	10	20	23	30	40	60
$P(A)$	0.027	0.117	0.411	0.507	0.706	0.891	0.994

条件概率

- 例：一家有两个孩子，假设按年龄排列（男男、男女、女男、女女）四种可能性相等，设事件 $A = \{\text{一男一女}\}$ ，则 $P(A) = \frac{1}{2}$ ；如果已知事件 $B = \{\text{至少一女}\}$ ，那 $P(A|B)$ 是多少？

$$P(A|B) = \frac{|AB|}{|B|} = \frac{2}{3} = \frac{|AB|/|\Omega|}{|B|/|\Omega|} = \frac{2/4}{3/4} = \frac{P(AB)}{P(B)}$$

- 定义：设有两个事件 A 与 B ，且 $P(B) > 0$ ，则在给定 B 发生的条件下 A 发生的**条件概率**，记为 $P(A|B)$ ，定义为

$$P(A|B) = \frac{P(AB)}{P(B)}$$

- 由上式可得 $P(AB) = P(A|B)P(B)$ ；同样 $P(AB) = P(B|A)P(A)$
- $P(A_1A_2 \dots A_n) = P(A_1)P(A_2|A_1)P(A_3|A_1A_2) \dots P(A_n|A_1A_2 \dots A_{n-1})$

条件概率的性质

- 条件概率同样具有概率的三个基本性质

$$\text{非负性: } P(A|B) \geq 0$$

$$\text{规范性: } P(\Omega|B) = 1$$

$$\text{可列可加性: } P(A_1 \cup A_2 \cup \dots | B) = P(A_1|B) + P(A_2|B) + \dots$$

- 类似于概率，条件概率也可由三个基本性质导出其他性质

$$P(\emptyset|B) = 0$$

$$P(A|B) = 1 - P(\bar{A}|B)$$

$$P(A_1 \cup A_2|B) = P(A_1|B) + P(A_2|B) - P(A_1 A_2|B)$$

- 当 $B = \Omega$ 时，条件概率即为无条件概率，因此把概率看作条件概率也未尝不可（即省略了所有试验兼具备的基础条件）

事件的独立性

- 无条件概率 $P(A)$ 与条件概率 $P(A|B)$ 一般是有差异的，这反映了两个事件之间存在关联，若 $P(A|B) > P(A)$ ，则 B 促进了 A 发生
- 若 $P(A) = P(A|B)$ ，则 B 的发生对 A 的发生没有影响，由条件概率公式可得

$$P(AB) = P(A|B)P(B) \Rightarrow P(AB) = P(A)P(B)$$

- 定义：若两个事件满足 $P(AB) = P(A)P(B)$ ，则称两个**事件独立**
- 在实际问题中并不常用上式的定义去判断两个事件是否独立，因为通常并不知道真实的 $P(A)$ 与 $P(A|B)$ ；相反，从事件的实际角度去判断是否存在关联，从而基于独立性把计算 $P(AB)$ 简化为计算 $P(A)$ 与 $P(B)$
 - 两个不认识的同学的考试成绩
 - 一个人的收入与其姓名的笔画数
 - 骰子的点数与硬币的正反面

事件的独立性

- 例：掷三个骰子，已知事件 $B = \{\text{第一个骰子掷出1}\}$ ，问事件 $A = \{\text{掷出点数之和不小于10}\}$ 的条件概率 $P(A|B)$ ？

$$P(A|B) = \frac{P(AB)}{P(B)} = \frac{|AB|/|\Omega|}{|B|/|\Omega|} = \frac{|AB|}{|B|} = \frac{10}{36}$$

$|AB| = 10$ 因为第二、三粒骰子点数之和不小于9，一共10种情况

$|B| = 36$ 因为第二、三粒骰子可以投出任意点数

- 接上例：若事件 $B = \{\text{至少一个骰子掷出1}\}$ ，事件 $A = \{\text{三个骰子掷出的点数中至少有两个一样}\}$ ，问 A 与 B 是否独立？

$$\frac{|A\Omega|}{|\Omega|} = P(A) < P(A|\bar{B}) = \frac{P(A\bar{B})}{P(\bar{B})} = \frac{|A\bar{B}|}{|\bar{B}|}$$

$|\bar{B}| = 5^3$ 相当于每个骰子只能投出除1点外的5种可能

$\frac{|A\Omega|}{|\Omega|}$ 与 $\frac{|A\bar{B}|}{|\bar{B}|}$ 可计算（生日问题）得 $P(A) < P(A|\bar{B})$ ，继而推出 $P(A) > P(A|B)$

事件的独立性

- 定义：设 $A_1, A_2, \dots$ 为有限或无限个事件，如果从中取出任意有限个 $A_{i_1}, A_{i_2}, \dots, A_{i_m}$ ，下式都成立则称事件 $A_1, A_2, \dots$ 相互独立

$$P(A_{i_1}, A_{i_2}, \dots, A_{i_m}) = P(A_{i_1})P(A_{i_2}) \dots P(A_{i_m})$$

- 由条件概率出发可得等价的定义

$$P(A_{i_1} | A_{i_2}, \dots, A_{i_m}) = P(A_{i_1})$$

即任意事件 A_{i_1} 发生可能性的大小，不受其他事件发生的影响

- 乘法定理^①：若干独立事件之积的概率等于各事件概率的积

$$P(A_1, A_2, \dots, A_n) = P(A_1)P(A_2) \dots P(A_n)$$

- 若一系列事件 $A_1, A_2, \dots$ 相互独立，则将其其中任一部分改为对立事件后，所得事件列仍为相互独立

^①概率相加需要事件互斥，概率相乘需要事件独立。

事件的独立性

- 若一系列事件 $A_1, A_2, \dots$ 中任意两个都独立，则称它们两两独立
- 由相互独立必推出两两独立，**反之不一定**
- 例：有四个大小、质地一样的球，分别在其上写上数字1、2、3和“1、2、3”，引进三个事件 $A_i = \{\text{随机抽出一球上有数字}i\}$ ， $i = 1, 2, 3$

由于四个球中各有两个有 i ，因此 $P(A_1) = P(A_2) = P(A_3) = \frac{1}{2}$

由于四个球中只有一个同时有任意两个数字，因此 $P(A_1A_2) = P(A_2A_3) = P(A_1A_3) = \frac{1}{4}$

由于 $P(A_iA_j) = P(A_i)P(A_j) = \frac{1}{4}$ ，因此 A_1, A_2, A_3 两两独立

但是 $P(A_1A_2A_3) = \frac{1}{4} \neq P(A_1)P(A_2)P(A_3) = \frac{1}{8}$ ，因此 A_1, A_2, A_3 不相互独立

事件的独立性

- 例：向一架飞机射击，事件 $E = \{\text{击落飞机}\}$ ， $E_0 = \{\text{击中飞行员}\}$ ， $E_1 = \{\text{击中发动机1}\}$ ， $E_2 = \{\text{击中发动机2}\}$ ， E_0, E_1, E_2 的概率分别为 p_0, p_1, p_2 ，假定击中飞行员或同时击中两个发动机时飞机才被击落，求 $P(E)$

解：由题意知 $E = E_0 \cup E_1E_2$ ，又因为 E_0 与 E_1E_2 不互斥，根据加法公式


$$P(E) = P(E_0 \cup E_1E_2) = P(E_0) + P(E_1E_2) - P(E_0E_1E_2)$$

从实际角度可认为 E_0, E_1, E_2 三事件相互独立，因此

$$\begin{aligned} P(E) &= P(E_0) + P(E_1)P(E_2) - P(E_0)P(E_1)P(E_2) \\ &= p_0 + p_1p_2 - p_0p_1p_2 \end{aligned}$$

全概率公式

- 设 $B_1, B_2, \dots$ 为有限或无限个事件，它们两两互斥且在每次试验中至少发生一个，即对于 $i \neq j$ 有 $B_i B_j = \emptyset$ （不可能事件）， $B_1 \cup B_2 \cup \dots = \Omega$ （必然事件），具有这些性质的一组事件称为一个**完备事件群**



- 考虑任一事件 A ，有 $A = A\Omega = A \cap (B_1 \cup B_2 \cup \dots) = AB_1 \cup AB_2 \cup \dots$ ，因 $B_1, B_2, \dots$ 两两互斥， $AB_1, AB_2, \dots$ 也两两互斥，根据可列可加性

$$P(A) = P(AB_1) + P(AB_2) + \dots$$

再由条件概率的定义可得**全概率公式**

$$P(A) = P(A|B_1)P(B_1) + P(A|B_2)P(B_2) + \dots$$

全概率公式

- 全概率公式的**实际意义**：在较复杂的情况下直接算 $P(A)$ 不易，但 A 总是伴随某个 B_i 出现，适当去构造这组 B_i 往往可以**简化计算**
- 例：设一个家庭有 k 个小孩的概率为 p_k ($k = 1, 2, \dots$)，又设各小孩性别独立，生男生女概率各为 $\frac{1}{2}$ ，事件 $A = \{\text{家庭中所有小孩为同一性别}\}$ ，求 $P(A)$

解：引进事件 $B_k = \{\text{家庭中有}k\text{个小孩}\}$ ，则 $B_1, B_2, \dots$ 构成完备事件集，已知 $P(B_k) = p_k$ ，利用全概率公式可得

$$P(A) = \sum_k P(A|B_k)P(B_k) = \sum_k P(A|B_k)p_k = \sum_k 2\left(\frac{1}{2}\right)^k p_k$$

k 个小孩都为男孩
或都为女孩的概率

全概率公式

- 另一种理解： B_i 是导致 A 发生的可能途径，从不同途径导致 A 发生的概率各不相同 $P(A|B_i)$ ，选择某种途径的概率 $P(B_i)$ 也各不相同，但 $\sum_i P(B_i) = 1$ 枚举了所有途径的可能性，则 $P(A) = \sum_i P(A|B_i)P(B_i)$ 的形式即为从所有途径导致 A 发生的概率
- 例：雨伞掉了，落在图书馆中的概率为50%，找回的概率为0.8；落在教室的概率为30%，找回的概率为0.6；落在食堂的概率为20%，找回的概率为0.05，求找回雨伞的概率

解：引进事件 $B_1 = \{\text{落在图书馆}\}$ ， $B_2 = \{\text{落在教室}\}$ ， $B_3 = \{\text{落在食堂}\}$ ，三者构成完备事件集，事件 $A = \{\text{找回雨伞}\}$

$$P(A) = \sum_{k=1}^3 P(A|B_k)P(B_k) = 0.5 \times 0.8 + 0.3 \times 0.6 + 0.2 \times 0.05 = 0.59$$

贝叶斯公式



托马斯·贝叶斯
(1702—1761)

- 根据条件概率公式与全概率公式可得**贝叶斯公式**:

$$P(B_i|A) = \frac{P(AB_i)}{P(A)} = \frac{P(B_i)P(A|B_i)}{\sum_j P(A|B_j)P(B_j)}$$

贝叶斯公式由英国数学家**托马斯·贝叶斯**提出

- 贝叶斯公式的解释：事件**A**看作结果，事件**B₁, B₂, ...**看作导致结果的诸多原因，全概率公式可解释为由原因推结果，而贝叶斯公式则是由**结果推原因**
- 贝叶斯公式提出了新的推理思路， $P(B_i)$ 称为**先验概率**，反映了各种原因可能性的大小（一般是以往的经验甚至是主观概率）， $P(B_i|A)$ 称为**后验概率**，反映了事件**A**发生后对**B_i**发生可能性的新认识
- 依据贝叶斯公式的思想发展出一整套统计推断方法，称为贝叶斯统计

贝叶斯公式

- 例：某地发生一起刑事案件，按以往掌握资料，几个嫌犯的可能性分别为 $P(B_1), P(B_2), \dots$ ，当采集到现场DNA（事件 A ）后，嫌犯的可能性变为 $P(B_1|A), P(B_2|A), \dots$
- 例：设某种病菌在人口中的带菌率为0.03，检查时由于技术与操作不完善，会出现带菌者未必检出阳性反应（漏检）或不带菌者出现阳性反应（误检），设事件 $B = \{\text{带菌}\}$ ，事件 $A = \{\text{阳性}\}$ ，已知 $P(A|B) = 0.99$ ， $P(A|\bar{B}) = 0.05$ ， $P(B) = 0.03$ ，某人检测出阳性，问他带菌的概率是多少？

解：带菌的概率即需求 $P(B|A)$ ，根据贝叶斯公式

$$P(B|A) = \frac{P(B)P(A|B)}{P(B)P(A|B) + P(\bar{B})P(A|\bar{B})} = \frac{0.03 \cdot 0.99}{0.03 \cdot 0.99 + 0.97 \cdot 0.05} = 0.38$$

贝叶斯公式

- 当前的人工智能主要建立在统计学习基础之上，而统计学习则是依靠收集大量数据 X （例如图像、文本等）去推断模型参数 Θ （例如各种深度神经网络的模型参数）
- 当把模型参数 Θ 看作是随机变量（而非未知常数）时，就是**贝叶斯学习**

$$P(\Theta|X) = \frac{P(\Theta)P(X|\Theta)}{P(X)} = \frac{P(\Theta)P(X|\Theta)}{\int_{\Theta'} P(X|\Theta')P(\Theta')d\Theta'}$$

- 该公式^①提供了一个简洁且强大的学习框架，不但可以通过先验分布对模型参数注入知识（例如根据经验设定其范围），还可以推断出模型参数的后验分布


^①该公式把贝叶斯公式中全概率的累加换成了积分，是因为模型参数 Θ 一般是连续变量。

本章课后作业

1. 古典概率例题（第19页）：如果把男孩女孩围成一个圆圈，求 $E = \{\text{任意两个女孩都不相邻}\}$ 的概率 $P(E)$ 。
2. 袋中有 n 个大小材质相同的球，其中 a 个红球， b 个白球， $a + b = n$ ，从中每次摸一球，不放回，求第 k （ $1 \leq k \leq n$ ）次摸到红球的概率，从而说明抽签结果与顺序无关。
3. 设甲、乙、丙三人去参加某个活动的概率均为0.4，三人中至少有两人去参加的概率为0.3，三人同去参加的概率为0.05，求甲、乙、丙三人至少有一人参加的概率。
4. 设一社区三口之家占了70%，该社区有40%的家庭至少有一人职业为教师，且在三口之家中有30%的家庭至少有一人职业为教师，在社区随机找一户：
1) 求这一户既不是三口之家也没有教师的概率；
2) 已知这一户没有教师，求这一户是三口之家的概率。
5. 事件独立性例题（第26页）：1) 计算出 $P(A)$ 与 $P(A|\bar{B})$ 的具体结果验证 $P(A) < P(A|\bar{B})$ ；
2) 从 $P(A) < P(A|\bar{B})$ 推出 $P(A) > P(A|B)$ 。

本章课后作业

6. 如下图有五个独立元件组成的系统，假设每个原件正常工作的概率为 p ， $0 \leq p \leq 1$ ，求系统正常工作的概率。



7. 若发报机以0.7与0.3的概率发出信号0和1，由于随机干扰，发出信号0时接收机会以0.8与0.2的概率接收到0和1；同样地，发出信号1时接收机会以0.9与0.1的概率接收到1和0，当接收机收到信号0时，发报机发出的信号是0的概率是多少？

☺ 推荐趣味阅读：蒲丰投针问题、贝特朗悖论、三门问题

The top banner features the Fudan University logo on the left, which includes the university's name in English ('FUDAN UNIVERSITY') and Chinese ('復旦大學') along with the founding year '1905'. To the right of the logo are several interlocking blue gears. Some of these gears contain white icons: a building, a graduation cap, a medical bag with a cross, a person silhouette, and an atomic symbol. The background of the banner is light blue with a dark blue curved shape on the far right.

人工智能的数学基础

02 随机变量及其概率分布

李 斌

复旦大学 计算机科学技术学院

随机变量

- 随机试验的结果通常有两类：示数的和示性的
 - 产品检验抽样出的废品数
 - 某段公路一天的车流量
 - 一个灯泡的使用寿命
 - 抛硬币（示性：正/反）
 - 产品检验（示性：一等/二等/等外）
- 这些例子中的试验结果能用一个数来表示，这个数是随着试验结果的**不同而变化**的，即它是试验结果的实值函数
- 定义：设随机试验的样本空间为 Ω ，若 $X = X(\omega)$ 为定义在 Ω 上的实值单值函数，则称 $X = X(\omega)$ 为**随机变量**
- 常用大写英文字母 X, Y, Z 等表示随机变量，而对应的小写字母 x, y, z 表示随机变量的取值

随机变量

- 例：随机买一注彩票的获奖概率为 p ， $0 < p < 1$ ，某人买了3注，求中奖次数的概率

解：引入表示中奖次数的随机变量 X ，其所有可能取值为0,1,2,3，设事件 $A_i = \{\text{第}i\text{注中奖}\}$ ，对 $i = 1, 2, 3$ ， $P(A_i) = p$ ，且 A_i 之间相互独立，得

$$P\{X = 0\} = P(\bar{A}_1 \bar{A}_2 \bar{A}_3) = \binom{3}{0} p^0 (1-p)^3$$

$$P\{X = 1\} = P(A_1 \bar{A}_2 \bar{A}_3 \cup \bar{A}_1 A_2 \bar{A}_3 \cup \bar{A}_1 \bar{A}_2 A_3) = \binom{3}{1} p^1 (1-p)^2$$

$$P\{X = 2\} = \dots$$

样本空间 Ω 为三注彩票开奖结果的所有可能情况，

$\bar{A}_1 \bar{A}_2 \bar{A}_3$ ， $A_1 \bar{A}_2 \bar{A}_3$ ， $\bar{A}_1 A_2 \bar{A}_3$ 等为样本点，

随机变量 X 是样本点的函数，例如 $X(\bar{A}_1 \bar{A}_2 \bar{A}_3) = 0$ ， $X(A_1 \bar{A}_2 \bar{A}_3) = 1$

随机变量

- 第一章中大多是用语言描述一个随机事件并求其发生的概率；引入随机变量 X 后可以研究 X 取不同值时事件发生的可能性，即概率的分布
- 随机变量按其可能取值类型可以分为两大类：离散型与连续型
- 离散型随机变量： X 只能取有限个或可列个值
 - 掷一个骰子的点数： $X = 1, 2, 3, 4, 5, 6$
 - 抽检100个产品中的废品数： $X = 0, 1, 2, \dots, 100$
 - 某段公路一天的车流量： $X = 0, 1, 2, \dots$
 - 抛一个硬币直到正面首次出现所需的次数： $X = 1, 2, \dots$
- 连续型随机变量：取值范围充满一个区间且无法逐一列出
 - 测量一个人的血压： $X \in [0, 300]$
 - 称量一物体的误差： $X \in (-\infty, \infty)$
 - 一个灯泡的寿命： $X \in (0, \infty)$

离散型随机变量

- 研究一个随机变量，不仅要看其能取哪些值，更重要的是其取各种可能值的概率如何

- 定义：设 X 为离散型随机变量，其全部可能取值为 $\{x_1, x_2, \dots\}$ ，则称

$$p_i = P\{X = x_i\}, \quad i = 1, 2, \dots$$

为 X 的**概率质量函数**^①

- 性质：概率质量函数满足两条性质：

$$\textcircled{1} \quad p_i \geq 0, i = 1, 2, \dots$$

$$\textcircled{2} \quad p_1 + p_2 + \dots = 1$$

证：第一个性质是显然的；第二个性质是因为 $\Omega = x_1 \cup x_2 \cup \dots$ 是必然事件，且 $x_1, x_2, \dots$ 互斥，因此 $P\{x_1 \cup x_2 \cup \dots\} = P(x_1) + P(x_2) + \dots = 1$

^①英文为Probability Mass Function，简称PMF；也有意译为概率分布律的。

离散型随机变量

- 概率质量函数给出了概率1在离散随机变量 X 取值集合 $\{x_1, x_2, \dots\}$ 上的分布情况，因此也称为 X 的**概率分布**
- 概率分布也可以用列表形式给出
- 例：掷两粒骰子，以 X 记出现的点数之和，其可能取值为 $2, 3, \dots, 12$ 共11个，要确定其概率分布，需要计算 x 为上述每个值时的 $P\{X = x\}$

x	2	3	4	5	6	7	8	9	10	11	12
$P\{X = x\}$	$\frac{1}{36}$	$\frac{2}{36}$	$\frac{3}{36}$	$\frac{4}{36}$	$\frac{5}{36}$	$\frac{6}{36}$	$\frac{5}{36}$	$\frac{4}{36}$	$\frac{3}{36}$	$\frac{2}{36}$	$\frac{1}{36}$

分布函数

- 对于离散型随机变量，用概率质量函数表达其概率分布是最方便的；但有时候还会关心随机变量落在某一取值区间内的概率

- 掷两粒骰子点数之和大于10的概率
- 考试分数在C-到B+之间的概率
- 身高大于170cm的概率
- 灯泡寿命大于1000小时且小于2000小时的概率

- 定义：设 X 为一随机变量， x 为任意实数，则函数

$$F(x) = P\{X \leq x\}$$

称为随机变量 X 的概率分布函数

分布函数


- 设离散型随机变量 X 的概率分布为 $P\{X = x_i\} = p_i$, $i = 1, 2, \dots$, 则 X 的分布函数为

$$F(x) = P\{X \leq x\} = \sum_{x_i \leq x} P\{X = x_i\} = \sum_{x_i \leq x} p_i$$

- 概率分布与分布函数两者知其一就可以决定另一个

- 例：随机变量 X 的概率分布如下表：

x	0	1	3
$P\{X = x\}$	0.4	0.3	0.3



分布函数

- 对任意两个实数 $x_1 < x_2$ ，根据定义有

$$F(x_2) - F(x_1) = P\{X \leq x_2\} - P\{X \leq x_1\} = P\{x_1 < X \leq x_2\}$$

即如果 X 的分布函数已知，则可求出事件 $\{x_1 < X \leq x_2\}$ 的概率

- 性质： $F(x)$ 单调不减，当 $x_2 > x_1$ 时，有 $F(x_2) \geq F(x_1)$

证： $F(x)$ 为事件 $\{X \leq x\}$ 的概率，当 $x_2 > x_1$ 时，事件 $\{X \leq x_2\}$ 包含事件 $\{X \leq x_1\}$ ，因此 $F(x_2) - F(x_1) = P\{x_1 < X \leq x_2\} \geq 0$ 。

- 性质： 当 $x \rightarrow \infty$ 时， $F(x) \rightarrow 1$ ； 当 $x \rightarrow -\infty$ 时， $F(x) \rightarrow 0$

证： 当 $x \rightarrow -\infty$ ， $\{X \leq x\}$ 越来越接近不可能事件； 反之则越来越接近必然事件。

离散型随机变量：二项分布

- 设在 n 次独立重复试验中，每次试验都只有两个结果： A 和 $\bar{A}$ ，且每次试验中 A 发生的概率不变，记 $P(A) = p$ ， $P(\bar{A}) = 1 - p$ ， $0 < p < 1$ ，称这一系列试验为 n 重伯努利试验

- 抛 n 次硬币观察正反面

- 从一批产品中有放回的抽 n 个检验是否为废品

- 以 X 记 A 在 n 次伯努利试验中发生的次数，则 X 可取 $0, 1, \dots, n$ 个可能值， X 的概率分布为

$$P\{X = i\} = \binom{n}{i} p^i (1 - p)^{n-i}, \quad i = 0, \dots, n$$

n 次试验中发生 i 次 A 的位置取法数


其中 $0 < p < 1$ ， $n \geq 1$ ，称 X 服从参数为 (n, p) 的二项分布，记为 $X \sim B(n, p)$

离散型随机变量：二项分布

- 显然 $P\{X = i\} > 0$ ，且 $\sum_{i=0}^n \binom{n}{i} p^i (1-p)^{n-i} = (p + (1-p))^n = 1$ ，符合离散型随机变量概率分布的性质
- 当 $n = 1$ 时为二项分布的一个特例：0-1分布，也称为伯努利分布

$$P\{X = i\} = p^i (1-p)^{1-i}, \quad i = 0, 1$$

- 二项分布图例



离散型随机变量：二项分布

- 例：掷一粒骰子，1) 独立掷4次，设有 X 次点数大于4，试写出 X 的概率分布；2) 若掷出的骰子中有两次点数大于4就结束，且最多掷4次，试写出掷的次数 Y 的概率分布

解：1) 设事件 $A = \{\text{点数大于4}\}$ ，则 $P(A) = \frac{2}{6} = \frac{1}{3}$ ，显然 $X \sim B(4, \frac{1}{3})$

$$P\{X = i\} = \binom{4}{i} \left(\frac{1}{3}\right)^i \left(\frac{2}{3}\right)^{4-i}, \quad i = 0, 1, 2, 3, 4$$

2) 由题意知， Y 的取值为2, 3, 4，设事件 $A_i = \{\text{第}i\text{次的点数大于4}\}$

$$P\{Y = 2\} = P(A_1 A_2) = \left(\frac{1}{3}\right)^2 = \frac{1}{9}$$

$$P\{Y = 3\} = P(A_1 \bar{A}_2 A_3 \cup \bar{A}_1 A_2 A_3) = 2 \left(\frac{1}{3}\right)^2 \left(\frac{2}{3}\right) = \frac{4}{27}$$

$$\begin{aligned} P\{Y = 4\} &= P(A_1 \bar{A}_2 \bar{A}_3 \cup \bar{A}_1 A_2 \bar{A}_3 \cup \bar{A}_1 \bar{A}_2 A_3) + P(\bar{A}_1 \bar{A}_2 \bar{A}_3) \\ &= 3 \left(\frac{1}{3}\right) \left(\frac{2}{3}\right)^2 + \left(\frac{2}{3}\right)^3 = \frac{20}{27} = 1 - P\{Y = 2\} - P\{Y = 3\} \end{aligned}$$


离散型随机变量：泊松分布

- 若随机变量 X 的可能取值为 $0, 1, 2, \dots$ ，且概率分布为

$$P\{X = i\} = \frac{e^{-\lambda} \lambda^i}{i!}, \quad i = 0, 1, \dots$$

其中 $\lambda > 0$ ，称 X 服从参数为 λ 的泊松分布，记为 $X \sim P(\lambda)$

- 显然 $P\{X = i\} > 0$ ；由 $\sum_{i=0}^{\infty} \frac{\lambda^i}{i!} = e^{\lambda}$ 得 $\sum_{i=0}^{\infty} P\{X = i\} = e^{\lambda} e^{-\lambda} = 1$ ，符合离散型随机变量概率分布的性质
- 泊松分布多用于 X 表示在一定时间或空间内出现的事件个数
 - 一段时间内接到的电话数
 - 一本书一页上的印刷错误数
 - 显微镜下某区域中的白血球



离散型随机变量：泊松分布

- 把一段时间分成 n 等分，假设 n 足够大，从而使每等分短到最多只能发生一次事件，记概率为 $p = \frac{\lambda}{n} < 1$ ；并假设各等分发生事件是独立的，则该时段内发生事件的总数 X 应服从参数为 $(n, \frac{\lambda}{n})$ 的二项分布



$$\begin{aligned} P\{X = i\} &= \binom{n}{i} \left(\frac{\lambda}{n}\right)^i \left(1 - \frac{\lambda}{n}\right)^{n-i} \\ &= \frac{n(n-1) \dots (n-i+1)}{n^i} \cdot \frac{\lambda^i}{i!} \cdot \left(1 - \frac{\lambda}{n}\right)^n \left(1 - \frac{\lambda}{n}\right)^{-i} \approx \frac{e^{-\lambda} \lambda^i}{i!} \end{aligned}$$

当 $n \rightarrow \infty$ 时， ≈ 1 $\approx e^{-\lambda}$ ≈ 1

- 故当 n 充分大、 $p = \frac{\lambda}{n}$ 足够小时，有 $\binom{n}{i} p^i (1-p)^{n-i} \approx \frac{e^{-\lambda} \lambda^i}{i!}$ ，即二项分布可用泊松分布近似描述

离散型随机变量：泊松分布

- 一般来说，若 $X \sim B(n, p)$ ，其中 n 很大、 p 很小，而 $np = \lambda$ 不太大时，则 X 的分布接近于泊松分布 $P(\lambda)$



- 当 n 较大时二项分布计算量较大，因此在 n 较大 p 较小时可用泊松分布作为二项分布的一种近似

离散型随机变量：泊松分布

- 例：现需要100个符合规格的元件，购买该元件废品率为0.01，若要使购买的元件中至少有100个符合规格的概率不小于0.95，问需要额外购买多少个？

设额外需购买 a 个元件，以 X 记在这 $100 + a$ 个元件中所含的废品数

解1：设各元件是否合格相互独立， X 服从二项分布 $B(100 + a, 0.01)$

$$P\{X \leq a\} = \sum_{i=0}^a \binom{100+a}{i} (0.01)^i (0.99)^{100+a-i}$$

解2：由于 $n = 100 + a$ 这个数较大而 $p = 0.01$ 较小， $\lambda = np \approx 1$ 大小适中，可用泊松分布近似，因此 X 近似服从泊松分布 $P(1)$

$$P\{X \leq a\} = \sum_{i=0}^a \frac{e^{-\lambda} \lambda^i}{i!} \approx \sum_{i=0}^a \frac{e^{-1}}{i!}$$

为确定最小的 a 使 $P\{X \leq a\} \geq 0.95$ ，需对 $a = 0, 1, \dots$ 依次计算，解2更简单。

其他离散分布

- 一批产品共 N 个，其中废品有 M 个，现从中随机取出 n 个^①，以 X 记包含的废品数，则 X 服从**超几何分布**（ $0 \leq m \leq M$ ， $n - m \leq N - M$ ）

$$P\{X = m\} = \frac{\binom{M}{m} \binom{N-M}{n-m}}{\binom{N}{n}}$$

- 在 n 重伯努利试验中， $P(A) = p$ ， $P(\bar{A}) = 1 - p$ ， $0 < p < 1$ ，设在 A 首次发生前所需的试验次数为 X ，则 X 服从**几何分布**

$$P\{X = i\} = (1 - p)^i p, \quad i = 0, 1, 2, \dots$$

^①此为无放回抽样；有放回抽样为二项分布，当 $\frac{n}{N}$ 很小时，超几何分布和二项分布很接近。

连续型随机变量

- 连续型随机变量 X 的取值充满一个区间，无法一一列出，若指定一个值 x ，则 X 恰好是 x 的概率为0
- 对于连续型随机变量，刻画其概率分布可以使用分布函数 $F(x) = P\{X \leq x\}$ ，但更方便的是考虑概率密度

$$\frac{F(x+h) - F(x)}{h} = \frac{P\{x < X \leq x+h\}}{h} \quad \text{令 } h \rightarrow 0 \text{ 得 } F'(x), \text{ 为 } x \text{ 处单位长的概率}$$

- 定义：随机变量 X 有分布函数 $F(x)$ ，若存在一个非负实函数 $f(x)$ ，使得对任意实数 x ，有

$$F(x) = \int_{-\infty}^x f(t) dt$$

则称 X 为连续型随机变量， $f(x)$ 为 X 的**概率密度函数**^①

^①英文为Probability Density Function，简称密度函数。

连续型随机变量

■ 性质：概率密度函数的基本性质



① $f(x) \geq 0$

② $\int_{-\infty}^{\infty} f(x) dx = 1$ 全部概率为1

定积分与导数的关系

③ 对任何常数 $a < b$, 有 $P\{a < X \leq b\} = F(b) - F(a) = \int_a^b f(x) dx$


④ 在 $f(x)$ 的连续点 x 处, $F'(x) = f(x)$



连续型随机变量：均匀分布

- 设随机变量 X 具有密度函数


$$f(x) = \begin{cases} \frac{1}{b-a}, & \text{当 } a \leq x \leq b \\ 0, & \text{其他} \end{cases}$$



则称 X 服从区间 $[a, b]$ 上的**均匀分布**，常记为 $X \sim U[a, b]$

- 显然， $f(x) \geq 0$ 且 $\int_{-\infty}^{\infty} f(x) dx = 1$
- $U[a, b]$ 的分布函数为

$$F(x) = \begin{cases} 0, & \text{当 } x < a \\ \frac{x-a}{b-a}, & \text{当 } a \leq x \leq b \\ 1, & \text{当 } x > b \end{cases}$$



连续型随机变量：正态分布

- 若随机变量 X 具有如下密度函数，其中 $-\infty < \mu < \infty$ ， $\sigma > 0$ ，则称 X 服从参数为 (μ, σ) 的**正态分布**^①，记为 $X \sim N(\mu, \sigma^2)$

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad -\infty < x < \infty$$

- 显然 $f(x) \geq 0$ ；还需证明 $\int_{-\infty}^{\infty} f(x) dx = 1$

证：作变量变换，令 $t = \frac{x-\mu}{\sigma}$ ，转化为证明 $I = \int_{-\infty}^{\infty} e^{-\frac{t^2}{2}} dt = \sqrt{2\pi}$

$$I^2 = \int_{-\infty}^{\infty} e^{-\frac{t^2}{2}} dt \int_{-\infty}^{\infty} e^{-\frac{u^2}{2}} du = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^{-\frac{(t^2+u^2)}{2}} dt du$$


$$I^2 = \int_0^{2\pi} d\theta \int_0^{\infty} e^{-r^2} r dr = 2\pi, \quad \text{得 } I = \sqrt{2\pi}$$

二重积分极坐标转化 $t = r\cos\theta$ ， $u = r\sin\theta$

^①正态为Normal的翻译，即反映正常状况下一般事物所处的状态，例如人群的身高、收入等分布。

连续型随机变量：正态分布

- 正态分布的密度函数 $f(x)$ 关于 μ 对称：中间高、两头低
- μ 决定了 $f(x)$ 对称点的**位置**与 X 取值集中的位置
- σ 决定了 $f(x)$ 的**尺度**， σ 越大， $f(x)$ 越扁平， X 取值越分散



标准正态分布

$$X \sim N(0,1)$$

$$\phi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

连续型随机变量：正态分布

- $N(\mu, \sigma^2)$ 的分布函数为 $F(x) = \int_{-\infty}^x f(t) dt = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(t-\mu)^2}{2\sigma^2}} dt$; 则标准正态分布 $N(0,1)$ 的分布函数为

$$\Phi(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$$

因为 $N(0,1)$ 关于 y 轴对称, 由此可得, 对于任意 x 有

$$\Phi(-x) = P\{X \leq -x\} = P\{X \geq x\} = 1 - \Phi(x)$$

当 $X \sim N(\mu, \sigma^2)$, 对于任意实数 $a < b$

$$P\{a < X < b\} = \int_a^b \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx \xrightarrow{t=\frac{x-\mu}{\sigma}} P\{a < X < b\} = \int_{\frac{a-\mu}{\sigma}}^{\frac{b-\mu}{\sigma}} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$$

标准正态分布的密度函数

连续型随机变量：正态分布

- 接上页：可以将正态随机变量 $X \sim N(\mu, \sigma^2)$ 的概率计算归结为标准正态分布函数值的计算问题

$$P\{a < X < b\} = \Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right)$$

- 标准正态分布的分布函数值 $\Phi(x)$ 可通过查表获得



	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
0.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
0.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
0.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
0.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
0.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
0.7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794	0.7823	0.7852
0.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
0.9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389
1.0	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.1	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790	0.8810	0.8830
1.2	0.8849	0.8869	0.8888	0.8907	0.8925	0.8944	0.8962	0.8980	0.8997	0.9015

连续型随机变量：正态分布

- 若 $X \sim N(\mu, \sigma^2)$ ，由前页结果 $P\{a < X < b\} = \Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right)$ 与 $\Phi(-x) = 1 - \Phi(x)$ 可得


$$P\{|X - \mu| < \sigma k\} = \Phi(k) - \Phi(-k) = 2\Phi(k) - 1$$

当 $k = 1, 2, 3$ 时，通过查表可得：

$$P\{|X - \mu| < \sigma\} = 2\Phi(1) - 1 = 0.6826$$

$$P\{|X - \mu| < 2\sigma\} = 2\Phi(2) - 1 = 0.9544$$

$$P\{|X - \mu| < 3\sigma\} = 2\Phi(3) - 1 = 0.9974$$



连续型随机变量：指数分布



- 若随机变量 X 具有如下密度函数，其中 $\lambda > 0$ ，则称 X 服从参数为 λ 的**指数分布**，记为 $X \sim E(\lambda)$

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

- 显然 $f(x) \geq 0$ ； $\int_{-\infty}^{\infty} f(x) dx = \int_0^{\infty} \lambda e^{-\lambda x} dx = -e^{-\lambda x} \Big|_0^{\infty} = 1$

- $E(\lambda)$ 的分布的函数为

$$F(x) = \int_{-\infty}^x f(t) dt = \begin{cases} 1 - e^{-\lambda x}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$



连续型随机变量：指数分布

- 当 $X \sim E(\lambda)$ 时，对任意的 $t > 0$ ， $t_0 > 0$ ，有

$$\begin{aligned} P\{X > t_0 + t | X > t_0\} &= \frac{P\{X > t_0 + t\}}{P\{X > t_0\}} = \frac{1 - F(t_0 + t)}{1 - F(t_0)} \\ &\text{在灯泡用了 } t_0 \text{ 时间没坏的条件下，再用 } t \text{ 时间不坏的概率} \\ &= \frac{1 - (1 - e^{-\lambda(t_0+t)})}{1 - (1 - e^{-\lambda t_0})} = e^{-\lambda t} \\ &= 1 - F(t) = P\{X > t\} \quad \text{灯泡从最初使用 } t \text{ 时间不坏的概率} \end{aligned}$$

- $P\{X > t_0 + t | X > t_0\} = P\{X > t\}$ 称为指数分布的**无记忆性**
- 指数分布最常见的一个场合是‘无老化’的寿命^①分布

^①寿命泛指发生某事件所需经历的时间。

连续型随机变量：指数分布

- 例：设某地段相邻两次交通事故间隔时间（单位：月） X 服从参数 $\lambda = \frac{1}{6.5}$ 的指数分布：1) 求8个月内没有发生交通事故的概率；2) 已知过去8个月没发生交通事故，求在未来2个月不发生交通事故的概率

1) 解：由题意知 $X \sim E\left(\frac{1}{6.5}\right)$ ，则

$$P\{X > 8\} = 1 - F(8) = e^{-\frac{8}{6.5}} \approx 0.202$$

2) 解：由指数分布的无记忆性知

$$P\{X > 8 + 2 | X > 8\} = P\{X > 2\} = e^{-\frac{2}{6.5}} \approx 0.735$$

离散型随机向量

- 设 $X = (X_1, X_2, \dots, X_n)$ 为一个 n 维向量，其每个分量，即 $X_1, X_2, \dots, X_n$ ，都是一维随机变量，则称 X 是一个 n 维**随机向量**或 n 元随机变量
- 如果一个随机向量 $X = (X_1, X_2, \dots, X_n)$ 中每一个分量 X_i 都是离散型随机变量，则称 X 为离散型的
- **定义：** 设 n 维离散型随机向量 $X = (X_1, X_2, \dots, X_n)$ 中每一个分量 X_i 的可能取值为 $\{x_{i,1}, x_{i,2}, \dots\}$ ，则

$$p_{j_1, j_2, \dots, j_n} = P\{X_1 = x_{1, j_1}, X_2 = x_{2, j_2}, \dots, X_n = x_{n, j_n}\}$$

称为随机向量 $X = (X_1, X_2, \dots, X_n)$ 的**联合概率分布**，且满足

$$p_{j_1, j_2, \dots, j_n} \geq 0;$$

$$\sum_{j_1} \sum_{j_2} \dots \sum_{j_n} p_{j_1, j_2, \dots, j_n} = 1$$

	$X_1 = x_{1,1}$	$X_1 = x_{1,2}$	$X_1 = x_{1,3}$
$X_2 = x_{2,1}$	0.1	0.3	0.2
$X_2 = x_{2,2}$	0.2	0.2	0

离散型随机向量：多项分布

- 设 $A_1, A_2, \dots, A_n$ 是某一试验下的**完备事件群**（即两两互斥且和为必然事件），每次试验 n 个事件中必发生且只发生一个^①，对 $i = 1, \dots, n$ ，记 $P\{A_i\} = p_i$ ， $p_i \geq 0$ ， $p_1 + \dots + p_n = 1$
- 现将试验独立重复 N 次，以 X_i 记在 N 次试验中事件 A_i 出现的次数，则 $X = (X_1, X_2, \dots, X_n)$ 为一个 n 维随机向量， $X_1, X_2, \dots, X_n$ 均为非负整数且其和为 N ，此时 X 服从**多项分布**，记为 $X \sim M(N; p_1, \dots, p_n)$
- 为定出多项分布的概率分布，需计算在 $k_1, \dots, k_n$ 为非负整数且 $k_1 + \dots + k_n = N$ 时所有的概率
$$P\{X_1 = k_1, X_2 = k_2, \dots, X_n = k_n\}$$

可参考本章中二项分布的定义，并根据第一章中介绍的多项式系数写出此概率分布（课后作业）
- 可证明上述概率分布满足非负且和为1


^①多项分布为二项分布在试验结果的可能性 $n > 2$ 时的推广。

连续型随机向量

- 设 $X = (X_1, X_2, \dots, X_n)$ 是一个 n 维随机向量，其取值可视为 n 维欧氏空间 $\mathbb{R}^n$ 中的一个点，如果 X 的全部取值能充满 $\mathbb{R}^n$ 中的某一区域，则称 X 为连续型的
- 描述多维连续型随机向量的概率分布，最方便的是使用概率密度函数
- 定义：若 $f(x_1, \dots, x_n)$ 是定义在 $\mathbb{R}^n$ 上的非负函数，使对 $\mathbb{R}^n$ 中的任何集合 A 有

$$P\{X \in A\} = \int \dots \int_A f(x_1, \dots, x_n) dx_1 \dots dx_n$$

且满足 $\int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} f(x_1, \dots, x_n) dx_1 \dots dx_n = 1$ ，
称 f 是 X 的**联合概率密度函数**



连续型随机向量：二维正态分布

- 最重要的多维连续型分布是多维正态分布，因为‘中心密、外围稀’反映了正常状况下一般事物分布的状态
- 若二维随机变量 (X_1, X_2) 具有如下概率密度函数（ $-\infty < \mu_1 < \infty$ ， $-\infty < \mu_2 < \infty$ ， $\sigma_1 > 0$ ， $\sigma_2 > 0$ ， $-1 < \rho < 1$ ）

$$f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \cdot \exp\left\{-\frac{1}{2(1-\rho^2)}\left[\frac{(x_1-\mu_1)^2}{\sigma_1^2} - \frac{2\rho(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2}\right]\right\}$$

则称 (X_1, X_2) 服从**二维正态分布**，记为 $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$



- 显然 $f(x_1, x_2) > 0$ ；也可证 $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x_1, x_2) dx_1 dx_2 = 1$ （略）

随机向量

- 与一维情况一样，也可以用概率分布函数去描述随机向量的概率分布，其定义为

$$F(x_1, x_2, \dots, x_n) = P\{X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n\}$$

- 在多维情况下，分布函数极少使用，统计学习中会经常使用离散型随机向量的概率分布与连续型随机向量的概率密度函数



边缘分布

- 例：下表为一个二维离散型随机向量 (X_1, X_2) 的概率分布以及 X_1 与 X_2 相应的边缘分布

$P\{X_1, X_2\}$	$X_2 = -1$	$X_2 = 0$	$X_2 = 5$	$P\{X_1\}$
$X_1 = 1$	0.17	0.05	0.21	0.43
$X_1 = 3$	0.04	0.28	0.25	0.57
$P\{X_2\}$	0.21	0.33	0.46	1.00

- 直观理解：在 X_i 每个可能取值上对 $(X_1, X_2, \dots, X_n)$ 中除 X_i 外的所有随机变量在其所有可能取值上的概率求和（离散型）或积分（连续型）

离散型： $P\{X_1 = x_{1,k}\} = \sum_{j_2, \dots, j_n} P\{X_1 = x_{1,k}, X_2 = x_{2,j_2}, \dots, X_n = x_{n,j_n}\}$

连续型： $f_1(x_1) = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} f(x_1, x_2, \dots, x_n) dx_2 \dots dx_n$


边缘分布

- 例：设 $X = (X_1, X_2, \dots, X_n)$ 服从多项分布 $M(N; p_1, \dots, p_n)$ ，则 X_i 的边缘分布为二项分布 $B(N, p_i)$

仅需把 X_i 对应的事件 A_i 看作一方，发生概率为 p_i ；其余事件 $\overline{A_i}$ 作为一个整体看作另一方，发生概率为 $\sum_{j \neq i} p_j = 1 - p_i$ ， X_i 即为 N 重伯努利试验中 A_i 发生的次数。

- 例：若 (X_1, X_2) 服从二维正态分布 $N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ ，则 X_1 与 X_2 的边缘分布分别是一维正态分布 $N(\mu_1, \sigma_1^2)$ 与 $N(\mu_2, \sigma_2^2)$

当 $\rho = 0$ 时，根据二维正态分布密度函数公式显见 $f(x_1, x_2) = f(x_1)f(x_2)$ ，又因为 $\int_{-\infty}^{\infty} f(x_2) dx_2 = 1$ ，因此 $\int_{-\infty}^{\infty} f(x_1, x_2) dx_2 = f(x_1) \int_{-\infty}^{\infty} f(x_2) dx_2 = f(x_1)$ ；
当 $\rho \neq 0$ 时，此结论仍然成立，证略。



- 二维正态分布的例子表明：联合分布可以决定边缘分布，**反之不然**

条件概率分布

- 例：从一群人中随机抽取一个人，分别以 X 与 Y 表示其体重和身高，则 X 与 Y 均为随机变量，分别服从一定的概率分布；若限制在 $1.7 \leq Y \leq 1.8$ 条件下去求 X 的条件分布，则与无条件时 X 的分布相比，体重取大值的概率会增加
- 在许多问题中有关的变量往往是彼此有影响的，这使条件分布成为研究变量之间相依关系的有力工具
- 离散型随机变量的**条件概率分布**

$$P\{X = x_i | Y = y_j\} = \frac{P\{X = x_i, Y = y_j\}}{P\{Y = y_j\}} = \frac{p_{ij}}{\sum_k p_{kj}} \quad \text{边缘分布}$$

- 连续型随机变量的**条件密度函数**

$$f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)}, \quad f_Y(y) \neq 0$$

边缘分布

条件概率分布

- 例：根据前例中二维离散型随机向量的概率分布表计算条件分布

$P\{X_1, X_2\}$	$X_2 = -1$	$X_2 = 0$	$X_2 = 5$	$P\{X_1\}$
$X_1 = 1$	0.17	0.05	0.21	0.43
$X_1 = 3$	0.04	0.28	0.25	0.57
$P\{X_2\}$	0.21	0.33	0.46	1.00

$$P\{X_1 = 1|X_2 = 0\} = \frac{P\{X_1=1, X_2=0\}}{P\{X_2=0\}} = \frac{0.05}{0.33} \quad P\{X_2 = 5|X_1 = 3\} = \frac{P\{X_2=5, X_1=3\}}{P\{X_1=3\}} = \frac{0.25}{0.57}$$

- 例：设 $X = (X_1, X_2, \dots, X_n)$ 服从多项分布 $M(N; p_1, \dots, p_n)$ ，试求在 $X_2 = k_2$ 的条件下 X_i 的条件分布

该例与前例（见边缘分布）一样，已知 n 维随机向量服从多项分布，求其中任意一个变量 X_i 的分布，因此 X_i 仍然服从二项分布。

与前例不同之处在于， $X_2 = k_2$ 是给定的条件，不存在随机性，于是试验总次数变为 $N - k_2$ ，又因为已不需要考虑事件 A_2 的发生，因此除事件 A_2 之外的其他事件的概率需要重新规范化（使和为1），即 $\frac{p_i}{1-p_2}$ ；因此 X_i 的条件概率分布为 $B\left(N - k_2, \frac{p_i}{1-p_2}\right)$ 。

条件概率分布

- 例：设 (X_1, X_2) 服从二维正态分布 $N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ ，求在给定 $X_1 = x_1$ 的条件下 X_2 的条件密度函数 $f_{X_2}(x_2|x_1)$

解：利用条件概率密度公式 $f_{X_2|X_1}(x_2|x_1) = \frac{f(x_1, x_2)}{f_{X_1}(x_1)}$ ，以及一维正态分布、二维正态分布的概率密度函数，经简单整理可得

$$f_{X_2|X_1}(x_2|x_1) = \frac{1}{\sqrt{2\pi}\sigma_2\sqrt{1-\rho^2}} \exp \left[-\frac{\left(x_2 - \overset{\text{条件分布中心点}}{\mu_2 + \rho\sigma_2\sigma_1^{-1}(x_1 - \mu_1)} \right)^2}{2(1-\rho^2)\sigma_2^2} \right]$$

- 正态随机变量的条件分布**仍为正态**
- ρ 刻画了 X_1 与 X_2 之间的相依关系：若 $\rho > 0$ ，则条件分布中心点随 x_1 增加而增加，即 X_2 有随着 X_1 的增加而增加的倾向；若 $\rho < 0$ ，则 X_2 有随着 X_1 的增加而下降的倾向

条件概率分布

- 与条件概率公式一样，条件密度函数也可以写成

$$f(x, y) = f_{X|Y}(x|y)f_Y(y) = f_{Y|X}(y|x)f_X(x)$$

- 条件概率密度可以推广到任意多个变量的场合，设有 n 维随机变量 $(X_1, X_2, \dots, X_n)$ ，其概率密度函数为 $f(x_1, x_2, \dots, x_n)$ ，则

$$f(x_1, x_2, \dots, x_n) = f_{X_{k+1:n}|X_{1:k}}(x_{k+1}, \dots, x_n|x_1, \dots, x_k)f_{X_{1:k}}(x_1, \dots, x_k)$$

- 对 $f(x, y) = f_{X|Y}(x|y)f_Y(y)$ 两边积分，可解释为 X 的概率密度是其条件概率密度在 Y 不同取值下的加权和，是**全概率公式**在概率密度上的表现形式

$$f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy = \int_{-\infty}^{\infty} f_{X|Y}(x|y)f_Y(y) dy$$

随机变量的独立性

- 与随机事件独立的概念类似，如果 $f_{X|Y}(x|y)$ 不随 Y 的取值而变化，即不依赖于 y ，则表示 X 的分布情况与 Y 取什么值无关，这时就称 X, Y 两个随机变量独立

- 由于 $f_{X|Y}(x|y)$ 仅是 x 的函数，记 $f_{X|Y}(x|y) = g(x)$ ，可得

$$f_X(x) = \int_{-\infty}^{\infty} f_{X|Y}(x|y) f_Y(y) dy = g(x) \int_{-\infty}^{\infty} f_Y(y) dy = g(x)$$

因此 $f_{X|Y}(x|y) = f_X(x)$ ，继而可得

$$f(x, y) = f_{X|Y}(x|y) f_Y(y) = f_X(x) f_Y(y)$$

- 定义：设 n 维随机向量 $(X_1, \dots, X_n)$ 的联合密度函数为 $f(x_1, \dots, x_n)$ ，而 X_i 的边缘密度函数为 $f_i(x_i), i = 1, \dots, n$ ，如果

$$f(x_1, \dots, x_n) = f_1(x_1) \dots f_n(x_n)$$

则称 $X_1, \dots, X_n$ 相互独立

随机变量的独立性

- 定理：若连续型随机变量 $X_1, \dots, X_n$ 相互独立，则对任何 $a_i < b_i$, $i = 1, \dots, n$ ，则 n 个事件 $A_1 = \{a_1 \leq X_1 \leq b_1\}, \dots, A_n = \{a_n \leq X_n \leq b_n\}$ 也相互独立；反之，对任何 $a_i < b_i$, $i = 1, \dots, n$ ，若 $A_1, \dots, A_n$ 相互独立，则 $X_1, \dots, X_n$ 相互独立
- 定理：若连续型随机向量 $(X_1, \dots, X_n)$ 的概率密度函数 $f(x_1, \dots, x_n)$ 可表示为 n 个函数 $g_1, \dots, g_n$ 之积，即 $f(x_1, \dots, x_n) = g_1(x_1) \dots g_n(x_n)$ ，则 $X_1, \dots, X_n$ 相互独立，且 X_i 的边缘密度函数 $f_i(x_i)$ 与 $g_i(x_i)$ 只相差一个常数因子
- 定理：若连续型随机变量 $X_1, \dots, X_n$ 相互独立，而 $Y_1 = g_1(X_1, \dots, X_m)$, $Y_2 = g_2(X_{m+1}, \dots, X_n)$ ，则 Y_1 与 Y_2 独立
- 以上定理同样适用于离散型随机变量

随机变量的独立性

- 定义：设 $X_1, \dots, X_n$ 都是离散型随机变量，若对任何常数 $x_1, \dots, x_n$ 都有

$$P\{X_1 = x_1, \dots, X_n = x_n\} = P\{X_1 = x_1\} \dots P\{X_n = x_n\}$$

则称 $X_1, \dots, X_n$ 相互独立

- 例：设 $X = (X_1, X_2, \dots, X_n)$ 服从多项分布 $M(N; p_1, \dots, p_n)$ ，对任何 $i \neq j$ ， X_i 与 X_j 不独立

根据多项式分布的定义，有 $X_1 + X_2 + \dots + X_n = N$ ，从直观上看，当 $n > 2$ 时，虽然 X_i 不足以唯一决定 X_j ，但 x_i 取很大值时， x_j 取大值时的概率就降低，这说明 X_j 在给定 X_i 之下的条件分布依赖于 X_i 的给定值。也可基于 X_i 的边缘分布（见边缘分布的例题） $X_i \sim B(N, p_i)$ 证明。

- 例：设 (X_1, X_2) 服从二维正态分布 $N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ ，由其联合密度函数 $f(x_1, x_2)$ 的形式看出，当且仅当 $\rho = 0$ 时， X_1 与 X_2 独立

当 $\rho = 0$ 时，根据二维正态分布的密度函数易得 $f(x_1, x_2) = f(x_1)f(x_2)$ ，即 X_1 与 X_2 独立。

本章课后作业


1. 某销售员独立地向顾客1与顾客2推销售价分别为17.3万元与18.7万元的A、B两款车，与顾客1与顾客2成交的概率分别为0.4与0.7，设每位顾客最多买一辆且选择两款车的概率相等，试给出该销售员的成交额 X 的可能取值与对应的概率。
2. 参考二项分布的定义并根据第一章中介绍的多项式系数，写出多项分布的概率分布，并证明其具有离散型随机向量概率分布的两条性质。
3. 试证明几何分布的无记忆性，即为了达到首次成功所需尝试的试验次数与前面已失败次数无关。
4. 设某公交车站单位时间内候车人数 X 服从参数为4.8的泊松分布，求：1) 随机观察一个单位时间，至少有3人候车的概率；2) 独立地随机观察5个单位时间，恰有4个单位时间至少有3人候车的概率。
5. 江湾校区校车站每天早上6:00开始发第一班车，之后每隔30分钟发一班车，设某同学在早上6:20以后 X 分钟到站，假设 X 服从 $(0,50)$ 上的均匀分布，求该同学候车时间不到15分钟的概率。
6. 通过调二维正态分布的五个参数 $\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho$ 观察概率密度函数的变化，总结出各参数值是如何影响概率密度函数的。

①可使用<https://demonstrations.wolfram.com/TheBivariateNormalDistribution/>。

本章课后作业

7. 随机变量 X 的密度函数为 $f(x) = \begin{cases} k(1-x), & 0 < x < 1 \\ x/4, & 1 \leq x \leq 2 \\ 0, & \text{其他} \end{cases}$ ，求：1) 常数 k ；2) 分布函数 $F(x)$ ；3) $P\{X < 1.5\}$ 的值。
8. 设一天中经过一路口的重型车辆数 X 近似服从正态分布 $N(\mu, \sigma^2)$ ，已知有25%的天数超过400辆，有33%的天数不到350辆，求 μ 和 σ 。提示：需通过查表先获得 $P\{X > 400\} = \Phi(x_1)$ 与 $P\{X < 350\} = \Phi(x_2)$ 中 x_1 与 x_2 的值。
9. 设一群体80%的人不吸烟、15%的人少量吸烟、5%的人大量吸烟，且已知近期他们患呼吸道疾病的概率分别为5%、25%、70%，记 $X = 0, 1, 2$ 分别为不吸烟、少量吸烟、大量吸烟； $Y = 0, 1$ 分别为不患病与患病，求：1) X, Y 的联合分布与边缘分布；2) 求患病人中吸烟的概率。

☺ 拓展阅读：除本章已经介绍过的伯努利分布与二项分布、类别分布与多项分布、泊松分布、几何分布等离散分布，以及均匀分布、一元与二元正态分布、指数分布之外，人工智能的研究与应用中还经常会用到多元正态分布、拉普拉斯分布、贝塔分布、狄里克雷分布等。



	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
0.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
0.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
0.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
0.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
0.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
0.7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794	0.7823	0.7852
0.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
0.9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389
1.0	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.1	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790	0.8810	0.8830
1.2	0.8849	0.8869	0.8888	0.8907	0.8925	0.8944	0.8962	0.8980	0.8997	0.9015
1.3	0.9032	0.9049	0.9066	0.9082	0.9099	0.9115	0.9131	0.9147	0.9162	0.9177
1.4	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9279	0.9292	0.9306	0.9319
1.5	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406	0.9418	0.9429	0.9441
1.6	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1.7	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616	0.9625	0.9633
1.8	0.9641	0.9649	0.9656	0.9664	0.9671	0.9678	0.9686	0.9693	0.9699	0.9706
1.9	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	0.9750	0.9756	0.9761	0.9767
2.0	0.9772	0.9778	0.9783	0.9788	0.9793	0.9798	0.9803	0.9808	0.9812	0.9817
2.1	0.9821	0.9826	0.9830	0.9834	0.9838	0.9842	0.9846	0.9850	0.9854	0.9857
2.2	0.9861	0.9864	0.9868	0.9871	0.9875	0.9878	0.9881	0.9884	0.9887	0.9890
2.3	0.9893	0.9896	0.9898	0.9901	0.9904	0.9906	0.9909	0.9911	0.9913	0.9916
2.4	0.9918	0.9920	0.9922	0.9925	0.9927	0.9929	0.9931	0.9932	0.9934	0.9936
2.5	0.9938	0.9940	0.9941	0.9943	0.9945	0.9946	0.9948	0.9949	0.9951	0.9952
2.6	0.9953	0.9955	0.9956	0.9957	0.9959	0.9960	0.9961	0.9962	0.9963	0.9964
2.7	0.9965	0.9966	0.9967	0.9968	0.9969	0.9970	0.9971	0.9972	0.9973	0.9974
2.8	0.9974	0.9975	0.9976	0.9977	0.9977	0.9978	0.9979	0.9979	0.9980	0.9981
2.9	0.9981	0.9982	0.9982	0.9983	0.9984	0.9984	0.9985	0.9985	0.9986	0.9986
3.0	0.9987	0.9987	0.9987	0.9988	0.9988	0.9989	0.9989	0.9989	0.9990	0.9990

The top banner features the Fudan University logo on the left, which includes the university's name in English ('FUDAN UNIVERSITY') and Chinese ('復旦大學'), along with the founding year '1905'. To the right of the logo are several interlocking blue gears. Some of these gears contain white icons: a building, a graduation cap, a medical bag with a cross, a person silhouette, and an atomic symbol. The background of the banner is a light blue gradient with a dark blue curved shape on the far right.

人工智能的数学基础

03 随机变量的数字特征

李 斌

计算机科学技术学院

数学期望

- 概率分布是随机变量概率性质最完整的刻画，而随机变量的数字特征则反映了其分布某些方面的特性
- 最重要的两类数字特征之一是数学期望（或称**均值**）
 - 某城市的平均房价
 - 某型号灯泡的平均使用寿命
- 数学期望名称的来源：甲、乙二人赌技相同，各出赌金100元，约定先胜三局者为胜，取得全部200元；现在甲胜两局乙胜一局的情况下中止，问赌本该如何分？

解：再赌两局一定能决出胜负，甲胜的概率为 $\frac{3}{4}$ ，乙胜的概率为 $\frac{1}{4}$ ；

引入随机变量 X 表示甲的最终所得，有两个可能取值：200和0

$$P\{X = 200\} = \frac{3}{4}, P\{X = 0\} = \frac{1}{4}$$

甲能‘期望’得到的数目为 $200 \times \frac{3}{4} + 0 \times \frac{1}{4} = 150$ ，乙为 $200 \times \frac{1}{4} + 0 \times \frac{3}{4} = 50$

数学期望

- 设随机变量 X 只取有限个可能值 $x_1, \dots, x_n$ ，其概率分布为 $P\{X = x_i\} = p_i$ ， $i = 1, \dots, n$ ，则 X 的**数学期望** $E(X)$ 为

$$E(X) = p_1x_1 + p_2x_2 + \dots + p_nx_n$$

即数学期望为随机变量取值以其**概率为权**的均值

- 均值的直观理解：

$$\bar{X} = \frac{N_1x_1 + N_2x_2 + \dots + \overset{N_n \text{ 次试验 } X \text{ 取值为 } x_n}{N_nx_n}}{\underset{\substack{\text{试验重复 } N \text{ 次} \\ (N = N_1 + N_2 + \dots + N_n)}}{N}} = \frac{N_1}{N}x_1 + \frac{N_2}{N}x_2 + \dots + \frac{N_n}{N}x_n$$

当 N 很大时 $\frac{N_n}{N}$ 接近 p_n
(概率的统计定义)

数学期望

- 定义：设**离散型**随机变量 X 的概率分布为 $P\{X = x_i\} = p_i, i = 1, 2, \dots$ ，若级数 $\sum_{i=1}^{\infty} x_i p_i$ 绝对收敛（即 $\sum_{i=1}^{\infty} |x_i| p_i < \infty$ ），则称级数 $\sum_{i=1}^{\infty} p_i x_i$ 为 X 的数学期望，记为

$$E(X) = \sum_{i=1}^{\infty} x_i p_i$$

若 $\sum_{i=1}^{\infty} |x_i| p_i = \infty$ ，则称随机变量 X 的期望不存在^①

- 定义：设**连续型**随机变量 X 的密度函数为 $f(x)$ ，若 $\int_{-\infty}^{\infty} |x| f(x) dx < \infty$ ，则称积分 $\int_{-\infty}^{\infty} x f(x) dx$ 为 X 的数学期望，记为

$$E(X) = \int_{-\infty}^{\infty} x f(x) dx$$

若 $\int_{-\infty}^{\infty} |x| f(x) dx = \infty$ ，则称随机变量 X 的期望不存在

^①因为若只是 $\sum_{i=1}^{\infty} x_i p_i$ 收敛，则对级数的各项排序后可以使其不收敛或收敛于其他值，这与 $E(X)$ 作为刻画概率分布某种特性的客观意义违背。

常用分布的期望

- 例：二项分布 $B(n, p)$ 的期望： np

$$\begin{aligned} E(X) &= \sum_{i=0}^n i \cdot P\{X = i\} = \sum_{i=1}^n i \cdot \binom{n}{i} p^i (1-p)^{n-i} \\ &= np \sum_{i=1}^n \binom{n-1}{i-1} p^{i-1} (1-p)^{n-i} = np(p + 1 - p)^{n-1} = np \end{aligned}$$

平均次数

- 例：泊松分布 $P(\lambda)$ 的期望： λ

$$\begin{aligned} E(X) &= \sum_{i=0}^{\infty} i \cdot P\{X = i\} = \sum_{i=0}^{\infty} i \cdot \frac{\lambda^i}{i!} e^{-\lambda} \\ &= \lambda \sum_{i=1}^{\infty} \frac{\lambda^{i-1}}{(i-1)!} e^{-\lambda} = \lambda e^{-\lambda} \sum_{i=0}^{\infty} \frac{\lambda^i}{i!} = \lambda e^{-\lambda} e^{\lambda} = \lambda \end{aligned}$$

平均次数

- 二项分布和泊松分布的期望都是事件发生的平均次数，这也解释了第二章中用二项分布近似泊松分布令 $p = \frac{\lambda}{n}$ 的原因

常用分布的期望

- 例：均匀分布 $U[a, b]$ 的期望： $\frac{a+b}{2}$

$$E(X) = \int_{-\infty}^{\infty} x f(x) dx = \int_a^b x \frac{1}{b-a} dx = \frac{a+b}{2}$$

- 例：指数分布 $E(\lambda)$ 的期望： $\frac{1}{\lambda}$

$$\begin{aligned} E(X) &= \int_{-\infty}^{\infty} x f(x) dx = \int_0^{\infty} x \lambda e^{-\lambda x} dx = - \int_0^{\infty} x de^{-\lambda x} \\ &= -xe^{-\lambda x} \Big|_0^{\infty} + \int_0^{\infty} e^{-\lambda x} dx = \frac{1}{\lambda} \quad \text{平均寿命, } \lambda \text{ 为失效率} \end{aligned}$$

- 例：正态分布 $N(\mu, \sigma^2)$ 的期望： μ

$$\begin{aligned} E(X) &= \int_{-\infty}^{\infty} x f(x) dx = \int_{-\infty}^{\infty} x \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx \\ &\xrightarrow{t=\frac{x-\mu}{\sigma}} \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} (\mu + \sigma t) e^{-\frac{t^2}{2}} dt = \frac{\mu}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{t^2}{2}} dt + \frac{\sigma}{\sqrt{2\pi}} \int_{-\infty}^{\infty} t e^{-\frac{t^2}{2}} dt = \mu \\ &\qquad\qquad\qquad = \sqrt{2\pi} \text{ 见第二章} \qquad\qquad\qquad \text{奇函数积分为0} \end{aligned}$$

数学期望的性质

- 若干个随机变量之和的期望等于各变量的期望之和
- 定理：若 n 个随机变量 $X_1, X_2, \dots, X_n$ 的数学期望都存在，则对任意 $n + 1$ 个实数 $c_0, c_1, c_2, \dots, c_n$ ， $\sum_{i=1}^n c_i X_i + c_0$ 的数学期望也存在，且

$$E(\sum_{i=1}^n c_i X_i + c_0) = \sum_{i=1}^n c_i E(X_i) + c_0$$

- 例：二项分布的数学期望（用期望的性质简化计算）

$X \sim B(n, p)$ 可以看成是 n 重伯努利试验中事件 A 发生的次数， $P(A) = p$ ；引入随机变量 $X_i = 1$ 表示第 i 次试验 A 发生， $X_i = 0$ 表示第 i 次试验 A 未发生，因此 $X = \sum_{i=1}^n X_i$ ；
又因为 $E(X_i) = p$ ，可得 $E(X) = E(\sum_{i=1}^n X_i) = \sum_{i=1}^n E(X_i) = np$

- 例：正态分布的数学期望（用期望的性质简化计算）

由于 $Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$ ，所以任意正态分布 $N(\mu, \sigma^2)$ 的随机变量 X 都可以写成标准正态分布随机变量的线性组合， $X = \sigma Z + \mu$ ，因此 $E(X) = E(\sigma Z + \mu) = \sigma E(Z) + \mu = \mu$

数学期望的性质

- 例：一电梯载着12位乘客从1层到11层，假设中途没有乘客进入，每位乘客独立等概率到达各层（如果某层没有乘客下，电梯在该层不停），记电梯停留次数为 X ，求 $E(X)$

解：令 $X_i = \begin{cases} 1, & \text{第}i\text{层有人下} \\ 0, & \text{第}i\text{层没人下} \end{cases}$ ， $i = 2, 3, \dots, 11$ ，则 $X = \sum_{i=2}^{11} X_i$

X_i 的概率分布为 $P\{X_i = 0\} = \left(1 - \frac{1}{10}\right)^{12}$ ， $P\{X_i = 1\} = 1 - P\{X_i = 0\}$

$$\begin{aligned} E(X) &= E\left(\sum_{i=2}^{11} X_i\right) = \sum_{i=2}^{11} E(X_i) \\ &= 10 \times [1 \times (1 - 0.9^{12}) + 0 \times 0.9^{12}] \approx 7.2 \end{aligned}$$

此题中的 X_i 虽然服从参数相同的伯努利分布，但它们之间不是相互独立的，所以不是 n 重伯努利试验。

数学期望的性质

- 若干相互独立的随机变量之积的期望等于各变量的期望之积
- 定理：若 n 个随机变量 $X_1, X_2, \dots, X_n$ 相互独立，数学期望都存在，则 $\prod_{i=1}^n X_i$ 的数学期望也存在，且

$$E(\prod_{i=1}^n X_i) = \prod_{i=1}^n E(X_i)$$

- 例：一长方形土地，其边长的测量值（单位米） X_1, X_2 分别服从 $N(150, 3^2)$ 和 $N(165, 2^2)$ ，且 X_1 与 X_2 相互独立，求由此算得的土地面积 X 的数学期望

解：由题意知 $X = X_1 X_2$ ，且 X_1 与 X_2 相互独立，故

$$E(X) = E(X_1 X_2) = E(X_1)E(X_2) = 150 \times 165 = 24750$$

条件数学期望

- 已知 (X, Y) 联合概率分布或密度函数，则给定 $X = x$ 下 Y 的条件期望为

离散型：
$$E(Y|X = x_i) = \sum_{j=1}^{\infty} y_j P\{Y = y_j | X = x_i\}$$

连续型：
$$E(Y|X = x) = \int_{-\infty}^{\infty} y f_{Y|X}(y|x) dy$$

- 条件分布 $P(Y|X)$ 是随机变量 Y 与随机变量 X 依赖关系的完全刻画，条件期望 $E(Y|X = x)$ 则反映了随着 X 取值变化 Y 的平均变化情况

- 身高为 x 时的平均体重
- 学历为 x 时的平均收入


- 例：第二章中已知二维正态分布 $N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ 的条件分布仍为正态分布 $N(\mu_2 + \rho\sigma_2\sigma_1^{-1}(x_1 - \mu_1), (1 - \rho^2)\sigma_2^2)$

由于 $N(\mu, \sigma^2)$ 的期望为 μ ，因此 $E(X_2|X_1 = x_1) = \mu_2 + \rho\sigma_2\sigma_1^{-1}(x_1 - \mu_1)$ ；
可见当 $\rho \neq 0$ 时， X_2 的条件期望与 X_1 的取值 x_1 相关

中位数

- 定义：设连续型随机变量 X 的分布函数为 $F(X)$ ，则满足以下条件的数 m 称为 X 或分布函数 F 的**中位数**

$$P(X \leq m) = F(m) = \frac{1}{2}$$



- 对于连续型随机变量 $P(X = m) = 0$ ，因此


$$P(X \leq m) = P(X < m) = P(X > m) = P(X \geq m) = \frac{1}{2}$$

- 中位数与数学期望对比

	数学期望	中位数
受个别特大值或特小值的干扰	大	小
对于任何随机变量都存在	否	是
具有很多 优良的数学性质	是	否
值是否唯一、是否对连续型与离散型都有定义	是	否

方差

- 另一类重要的数字特征是用于刻画随机变量在其中心位置附近**散布程度**的数字特征，其中最重要的是方差
- 假设随机变量 X 有均值 $a = E(X)$ ，偏离量 $X - a$ 也是随机变量，若想基于此计算一个数字特征刻画散布程度，对 $(X - a)^2$ 求期望是合适的^①



^①若对 $X - a$ 求期望，则 $E(X - a) = E(X) - a = 0$ ；若对 $|X - a|$ 求期望， $E(|X - a|)$ 称为平均绝对离差，也是刻画散布程度的数字特征；但因为有绝对值，在数学上处理不方便。

方差

- 定义：设随机变量 X 分布为 F ，且数学期望 $E(X)$ 与 $E[(X - E(X))^2]$ 都存在，则

$$Var(X) = E[(X - E(X))^2]$$

$E(X)$ 为常数

称为 X 或分布 F 的**方差**， $\sigma = \sqrt{Var(X)}$ （取正根）称为**标准差**

- 记 $E(X) = a$ ，由于 $(X - a)^2 = X^2 - 2Xa + a^2$ ，根据期望的性质可得

$$\begin{aligned} Var(X) &= E[(X - a)^2] = E(X^2 - 2Xa + a^2) \\ &= E(X^2) - 2aE(X) + a^2 = E(X^2) - [E(X)]^2 \end{aligned}$$

- 计算方差可使用 $Var(X) = E(X^2) - [E(X)]^2$

常用分布的方差

■ 例：二项分布 $B(n, p)$ 的方差： $np(1 - p)$

$$\begin{aligned} E(X^2) &= \sum_{i=0}^n i^2 \cdot P\{X = i\} = \sum_{i=1}^n i^2 \cdot \binom{n}{i} p^i (1-p)^{n-i} \\ &= \sum_{i=1}^n [i(i-1) + i] \binom{n}{i} p^i (1-p)^{n-i} \\ &= \sum_{i=1}^n i(i-1) \binom{n}{i} p^i (1-p)^{n-i} + \sum_{i=1}^n i \binom{n}{i} p^i (1-p)^{n-i} \\ &= n(n-1)p^2 \sum_{i=2}^n \binom{n-2}{i-2} p^{i-2} (1-p)^{n-i} + np \quad \begin{array}{l} B(n, p) \text{ 的} \\ \text{期望为 } np \end{array} \\ &= n(n-1)p^2(p + 1 - p)^{n-2} + np \\ &= n(n-1)p^2 + np \\ \text{Var}(X) &= E(X^2) - [E(X)]^2 = n(n-1)p^2 + np - (np)^2 = np(1-p) \end{aligned}$$

常用分布的方差

■ 例：泊松分布 $P(\lambda)$ 的方差： λ

$$\begin{aligned} E(X^2) &= \sum_{i=0}^{\infty} i^2 \cdot P\{X = i\} = \sum_{i=0}^{\infty} i^2 \cdot \frac{\lambda^i}{i!} e^{-\lambda} \\ &= \lambda \sum_{i=1}^{\infty} i \cdot \frac{\lambda^{i-1}}{(i-1)!} e^{-\lambda} = \lambda \sum_{i=1}^{\infty} [(i-1) + 1] \frac{\lambda^{i-1}}{(i-1)!} e^{-\lambda} \\ &= \lambda \left[\lambda \sum_{i=2}^{\infty} \frac{\lambda^{i-2}}{(i-2)!} e^{-\lambda} + \sum_{i=1}^{\infty} \frac{\lambda^{i-1}}{(i-1)!} e^{-\lambda} \right] \\ &= \lambda^2 e^{\lambda} e^{-\lambda} + \lambda e^{\lambda} e^{-\lambda} \\ &= \lambda^2 + \lambda \end{aligned}$$

$$\text{Var}(X) = E(X^2) - [E(X)]^2 = \lambda^2 + \lambda - \lambda^2 = \lambda$$

常用分布的方差

- 例：均匀分布 $U[a, b]$ 的方差： $\frac{(b-a)^2}{12}$

$$E(X^2) = \int_{-\infty}^{\infty} x^2 f(x) dx = \int_a^b x^2 \frac{1}{b-a} dx = \frac{b^2+ab+a^2}{3}$$

$$Var(X) = E(X^2) - [E(X)]^2 = \frac{b^2+ab+a^2}{3} - \left(\frac{a+b}{2}\right)^2 = \frac{(b-a)^2}{12}$$

- 例：指数分布 $E(\lambda)$ 的方差： $\frac{1}{\lambda^2}$

$$\begin{aligned} E(X^2) &= \int_{-\infty}^{\infty} x^2 f(x) dx = \int_0^{\infty} x^2 \lambda e^{-\lambda x} dx = -\int_0^{\infty} x^2 de^{-\lambda x} \\ &= -x^2 e^{-\lambda x} \Big|_0^{\infty} + 2 \int_0^{\infty} x e^{-\lambda x} dx = \frac{2}{\lambda} E(X) \end{aligned}$$

$$Var(X) = E(X^2) - [E(X)]^2 = \frac{2}{\lambda} \cdot \frac{1}{\lambda} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2}$$

常用分布的方差


■ 例：正态分布 $N(\mu, \sigma^2)$ 的方差： σ^2

$$\text{Var}(X) = E[(X - \mu)^2] = \int_{-\infty}^{\infty} (x - \mu)^2 f(x)$$

$$= \int_{-\infty}^{\infty} (x - \mu)^2 \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx$$

$$\begin{aligned} &\xrightarrow{t=\frac{x-\mu}{\sigma}} \frac{\sigma^2}{\sqrt{2\pi}} \int_{-\infty}^{\infty} t^2 e^{-\frac{t^2}{2}} dt = -\frac{\sigma^2}{\sqrt{2\pi}} \int_{-\infty}^{\infty} t de^{-\frac{t^2}{2}} \\ &= -\frac{\sigma^2}{\sqrt{2\pi}} \left[te^{-\frac{t^2}{2}} \Big|_{-\infty}^{\infty} - \int_{-\infty}^{\infty} e^{-\frac{t^2}{2}} dt \right] \\ &= -\frac{\sigma^2}{\sqrt{2\pi}} [0 - \sqrt{2\pi}] = \sigma^2 \end{aligned}$$

$= \sqrt{2\pi}$ 见第二章



可见正态分布中尺度参数 σ^2 的解释就是分布的方差

方差的性质

- 方差之所以成为刻画散布程度的最重要的数字特征，在于其具有一些优良的数学性质
- 定理：设随机变量 X 的方差存在， c 为一常数，则

1. $Var(c) = 0$

若 $X = c$ ，则 $E(X) = c$ ，故 $E[(X - E(X))^2] = 0$

2. $Var(X + c) = Var(X)$

因为 $E(X + c) = E(X) + c$ ，故 $Var(X + c) = E[((X + c) - (E(X) + c))^2] = E[(X - E(X))^2] = Var(X)$

3. $Var(cX) = c^2 Var(X)$

因为 $E(cX) = cE(X)$ ，故 $Var(cX) = E[(cX - cE(X))^2] = c^2 E[(X - E(X))^2] = c^2 Var(X)$

4. $Var(X) \leq E[(X - c)^2]$ ，当且仅当 $E(X) = c$ 时等号成立

$E[(X - c)^2] - Var(X) = E[(X - c)^2] - E(X^2) + [E(X)]^2 = [E(X)]^2 - 2cE(X) + c^2 = (E(X) - c)^2 \geq 0$

方差的性质

- 两两独立随机变量之和的方差等于各变量的方差之和
- 定理：对任意正整数 $n \geq 2$ ，设 $X_1, X_2, \dots, X_n$ 为两两独立的随机变量，方差都存在，则 $X_1 + X_2 + \dots + X_n$ 的方差也存在，且

$$\text{Var}(X_1 + \dots + X_n) = \text{Var}(X_1) + \dots + \text{Var}(X_n)$$

证：记 $E(X_i) = a_i$ ， $i = 1, \dots, n$ ，因 $E(\sum_{i=1}^n X_i) = \sum_{i=1}^n a_i$ ，有

$$\begin{aligned}\text{Var}(X_1 + \dots + X_n) &= E[\sum_{i=1}^n X_i - \sum_{i=1}^n a_i]^2 = E[\sum_{i=1}^n (X_i - a_i)]^2 \\&= \sum_{i,j=1}^n E[(X_i - a_i)(X_j - a_j)] \\&= \sum_{i=1}^n E[(X_i - a_i)^2] + 2 \sum_{1 \leq i < j \leq n} E[(X_i - a_i)(X_j - a_j)] \\&= \sum_{i=1}^n \text{Var}(X_i) \qquad \qquad \qquad = 0, \text{ 由于 } X_i \text{ 与 } X_j \text{ 两两独立,} \\&\qquad \qquad \qquad \qquad \qquad \qquad \qquad \qquad \text{有 } E(X_i X_j) = E(X_i)E(X_j)\end{aligned}$$

方差的性质

- 例：设 X 为一随机变量， $E(X) = a$ ， $Var(X) = \sigma^2$ ，记 $Y = \frac{X-a}{\sigma}$ ，则 $E(Y) = 0$ ， $Var(Y) = \frac{1}{\sigma^2} E(X - a)^2 = 1$ ，这样对 X 做线性变换后，得到一个具有均值0、方差1的随机变量 Y ，称为 Y 是 X 的**标准化**

- 例：二项分布的方差（用方差的性质简化计算）

$X \sim B(n, p)$ 可以看成是 n 重伯努利试验中事件 A 发生的次数， $P(A) = p$ ；引入随机变量 $X_i = 1$ 表示第 i 次试验 A 发生， $X_i = 0$ 表示第 i 次试验 A 未发生，因此 $X = \sum_{i=1}^n X_i$ ；
易知 $E(X_i) = p$ ， $E(X_i^2) = p$ ， $Var(X_i) = E(X_i^2) - [E(X_i)]^2 = p(1 - p)$ ，
可得 $Var(X) = Var(\sum_{i=1}^n X_i) = \sum_{i=1}^n Var(X_i) = np(1 - p)$

- 例：正态分布的方差（用方差的性质简化计算）

由于 $Z = \frac{X-\mu}{\sigma} \sim N(0,1)$ ，所以任意正态分布 $N(\mu, \sigma^2)$ 的随机变量 X 都可以写成标准正态分布随机变量的线性组合， $X = \sigma Z + \mu$ ，因此 $Var(X) = Var(\sigma Z + \mu) = \sigma^2 Var(Z) + Var(\mu) = \sigma^2 \cdot 1 + 0 = \sigma^2$

矩

- 定义：设 X 为随机变量， c 为常数， k 为正整数，则 $E[(X - c)^k]$ 称为 X 关于 c 点的 k 阶矩
- 比较重要的有两种情况：
 1. 当 $c = 0$ 时 $\alpha_k = E(X^k)$ ，称为 X 的 k 阶原点矩
 2. 当 $c = E(X)$ 时 $\mu_k = E[(X - E(X))^k]$ ，称为 X 的 k 阶中心矩
- 一阶原点矩就是期望 $E(X)$
- 二阶中心矩就是方差 $E[(X - E(X))^2]$
- 人工智能中高阶矩极少使用

协方差

- 对于多元变量，除了考虑每一个分量的中心位置和散布程度，还对分量之间的**关系**感兴趣，其中最重要的是协方差和相关系数
- **定义：**对于数学期望都存在的随机变量 X 和 Y ，当 $(X - E(X))(Y - E(Y))$ 的数学期望存在时，称 $Cov(X, Y)$ 为 X 和 Y 的**协方差**

$$Cov(X, Y) = E[(X - E(X))(Y - E(Y))]$$

- 与方差类似，协方差 $Cov(X, Y) = E(XY) - E(X)E(Y)$
- 根据协方差的定义， c_i 为常数，易见

1. $Cov(X, Y) = Cov(Y, X)$

2. $Cov(X, X) = Var(X)$

3. $Cov(c_1X + c_2, c_3Y + c_4) = c_1c_3Cov(X, Y)$ 证明同方差的性质

协方差的性质

- 定理：若 X 和 Y 相互独立，则 $Cov(X, Y) = 0$

证：因为 X 和 Y 相互独立， $E(XY) = E(X)E(Y)$ ，因此 $Cov(X, Y) = E(XY) - E(X)E(Y) = 0$ ；但 $Cov(X, Y) = 0$ 不能推出 X 和 Y 相互独立

- 定理：对任意正整数 $n \geq 2$ ，设 $X_1, X_2, \dots, X_n$ 为方差存在的随机变量，则 $X_1 + X_2 + \dots + X_n$ 的方差也存在，且

$$Var(X_1 + \dots + X_n) = \sum_{i=1}^n Var(X_i) + 2 \sum_{1 \leq i < j \leq n} Cov(X_i, X_j)$$

证：记 $E(X_i) = a_i$ ， $i = 1, \dots, n$ ，从方差的性质（两两独立随机变量之和的方差等于各变量的方差之和）的证明中已知

$$\begin{aligned} Var(X_1 + \dots + X_n) &= \sum_{i=1}^n E[(X_i - a_i)^2] + 2 \sum_{1 \leq i < j \leq n} E[(X_i - a_i)(X_j - a_j)] \\ &= \sum_{i=1}^n Var(X_i) + 2 \sum_{1 \leq i < j \leq n} Cov(X_i, X_j) \end{aligned}$$

协方差的性质

- 例： n 个人把各自的名片混放在一起（ $n \geq 2$ ），然后每人从中随机抽取一张，以 X 表示抽到自己名片的人数，求 $E(X)$ 及 $Var(X)$

解： 设 $X_i = \begin{cases} 1, & \text{第 } i \text{ 人抽到自己的名片} \\ 0, & \text{第 } i \text{ 人抽到别人的名片} \end{cases}$, $i = 1, 2, \dots, n$, 则 $X = X_1 + X_2 + \dots + X_n$,

且对 $i = 1, 2, \dots, n$, 有 $P\{X_i = 1\} = \frac{1}{n}$, $P\{X_i = 0\} = 1 - \frac{1}{n}$;

易知 $E(X_i) = \frac{1}{n}$, $Var(X_i) = \frac{1}{n} \left(1 - \frac{1}{n}\right)$, 于是有

$$E(X) = E(X_1 + \dots + X_n) = E(X_1) + \dots + E(X_n) = n \cdot \frac{1}{n} = 1$$

另外对 $i \neq j$, $P\{X_i X_j = 1\} = P\{X_i = 1, X_j = 1\} = \frac{(n-2)!}{n!} = \frac{1}{n(n-1)}$,

$P\{X_i X_j = 0\} = 1 - P\{X_i X_j = 1\} = 1 - \frac{1}{n(n-1)}$, 可得 $E(X_i X_j) = \frac{1}{n(n-1)}$,

$$\begin{aligned} Var(X) &= Var(X_1 + \dots + X_n) = \sum_{i=1}^n Var(X_i) + 2 \sum_{1 \leq i < j \leq n} [E(X_i X_j) - E(X_i)E(X_j)] \\ &= n \cdot \frac{1}{n} \left(1 - \frac{1}{n}\right) + 2 \cdot \frac{n(n-1)}{2} \left(\frac{1}{n(n-1)} - \frac{1}{n^2}\right) = 1 \end{aligned}$$

协方差的性质

- 定理：若随机变量 X, Y 的协方差存在，当 $Var(X)Var(Y) \neq 0$ 时，有 $(Cov(X, Y))^2 \leq Var(X)Var(Y)$ ，等号成立当且仅当 X 与 Y 之间有严格的线性关系（即存在常数 a, b 使 $Y = a + bX$ ）时成立

证：为简便记 $E(X) = m_1$, $E(Y) = m_2$, $Var(X) = \sigma_1^2$, $Var(Y) = \sigma_2^2$ ；现考虑

$$E[t(X - m_1) + (Y - m_2)]^2 = \sigma_1^2 t^2 + 2Cov(X, Y) \cdot t + \sigma_2^2 \geq 0$$

对于二次三项式 $at^2 + 2bt + c$ ，若 $a > 0$
且对 t 的任何实值都非负，则必有 $ac \geq b^2$

由上式可得 $[Cov(X, Y)]^2 \leq \sigma_1^2 \sigma_2^2$ ；

若上式等号成立，则 $\sigma_1^2 t^2 + 2Cov(X, Y) \cdot t + \sigma_2^2 = (\sigma_1 t \pm \sigma_2)^2$ ， $\pm$ 取决于 $Cov(X, Y)$ 的正负；暂设 $Cov(X, Y) > 0$ ，则取 $(\sigma_1 t + \sigma_2)^2$ ，即 $t = -\frac{\sigma_2}{\sigma_1}$ 时为0，

代入上式可得 $E\left[-\frac{\sigma_2}{\sigma_1}(X - m_1) + (Y - m_2)\right]^2 = 0$ ；又因为“若随机变量只能取非负值，而 $E(Z) = 0$ ，则 $Z = 0$ ”，因此 $-\frac{\sigma_2}{\sigma_1}(X - m_1) + (Y - m_2) = 0$ ，即知 X 与 Y 之间有严格的线性关系。反向证明略。

相关系数

- 类似方差标准化，协方差**标准化**后为 $Cov(X', Y') = \frac{E[(X-E(X))(Y-E(Y))]}{\sqrt{Var(X)}\sqrt{Var(Y)}}$
- **定义：**对于随机变量 X 和 Y ，当 $E(X^2)$ 与 $E(Y^2)$ 均存在^①且 $Var(X)$ 和 $Var(Y)$ 均为非零实数时，称

$$Corr(X, Y) = \frac{Cov(X, Y)}{\sqrt{Var(X)}\sqrt{Var(Y)}}$$


为 X 与 Y 的**相关系数**，相关系数可视为“标准尺度下的协方差”

- **定理：**由协方差的性质立即可得
 1. 若 X 和 Y 相互独立，则 $Corr(X, Y) = 0$ ，称 X 与 Y **不相关**
 2. $-1 \leq Corr(X, Y) \leq 1$ ，等号当且仅当 X 与 Y 有严格线性关系时达到
由 $(Cov(X, Y))^2 \leq Var(X)Var(Y)$ 得到

^① “ $E(X^2)$ 与 $E(Y^2)$ 均存在”的假设意味着 X 和 Y 的数学期望与方差以及 XY 的数学期望均存在；事实上，
 $0 \leq |X| \leq X^2 + 1$ ， $0 \leq |Y| \leq Y^2 + 1$ ， $0 \leq |XY| \leq \frac{X^2 + Y^2}{2}$

相关系数

- 相关系数并不是刻画了 X 与 Y 之间一般关系的程度，而只是**线性关系**的程度，因此相关系数也称为线性相关系数
- 如果 $0 < |Corr(X, Y)| < 1$ 则解释为， X 与 Y 之间有一定程度的线性关系而非严格的线性关系，因为 X 的值并不能决定 Y 的值



相关系数

- 若 X 和 Y 相互独立，则 X 与 Y 不相关；但反过来一般**不成立**
- 例：设 (X, Y) 服从单位圆内的均匀分布，试求 X 与 Y 的协方差，并判断相关性与独立性

解： (X, Y) 的联合密度函数为 $f(x, y) = \begin{cases} \frac{1}{\pi}, & \text{当 } x^2 + y^2 < 1 \text{ 时} \\ 0, & \text{当 } x^2 + y^2 \geq 1 \text{ 时} \end{cases}$ ，则

$$E(X) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xf(x, y) dx dy = \iint_{x^2+y^2 < 1} \frac{x}{\pi} dx dy = 0; \text{ 同理可得 } E(Y) = 0,$$

$$E(XY) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xyf(x, y) dx dy = \iint_{x^2+y^2 < 1} \frac{xy}{\pi} dx dy = 0,$$

由 $Cov(X, Y) = E(XY) - E(X)E(Y) = 0$ 可知 $Corr(X, Y) = 0$ ， X 与 Y 不相关；

X 的边缘密度函数为 $f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy = \int_{-\sqrt{1-x^2}}^{\sqrt{1-x^2}} \frac{1}{\pi} dy = \frac{2\sqrt{1-x^2}}{\pi}$ ；同理可得 $f_Y(y) = \frac{2\sqrt{1-y^2}}{\pi}$ ；即 $f(x, y) \neq f_X(x)f_Y(y)$ ， X 与 Y 不独立。

相关系数

- 有一个重要**特例**，当 (X, Y) 服从二维**正态分布**时，由 $\text{Corr}(X, Y) = 0$ 可以推出 X, Y 独立，即对于正态分布不相关与相互独立等价

- 例：设 (X, Y) 服从二维正态分布 $N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ ，求 $\text{Corr}(X, Y)$

解：
$$\begin{aligned} \text{Cov}(X, Y) &= E[(X - \mu_1)(Y - \mu_2)] = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \cdot \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x - \mu_1)(y - \mu_2) \\ &\quad \cdot \exp\left\{-\frac{1}{2(1-\rho^2)}\left[\frac{(x-\mu_1)^2}{\sigma_1^2} - \frac{2\rho(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2}\right]\right\} dx dy \\ &\quad = \left(\frac{x-\mu_1}{\sigma_1} - \frac{\rho(y-\mu_2)}{\sigma_2}\right)^2 + \left(\sqrt{1-\rho^2}\frac{(y-\mu_2)}{\sigma_2}\right)^2 \end{aligned}$$

做变量代换
$$\begin{cases} u = \frac{1}{\sqrt{1-\rho^2}}\left(\frac{x-\mu_1}{\sigma_1} - \frac{\rho(y-\mu_2)}{\sigma_2}\right) \\ v = \frac{(y-\mu_2)}{\sigma_2} \end{cases}, \text{ 则}$$

$$\text{Cov}(X, Y) = \frac{1}{2\pi} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \left(\sqrt{1-\rho^2}\sigma_1 u + \sigma_1\rho v\right) \sigma_2 v \cdot \exp\left(-\frac{u^2+v^2}{2}\right) du dv$$

相关系数

接前页：由于

$$\begin{aligned}\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} uv \exp\left(-\frac{u^2+v^2}{2}\right) dudv &= \int_{-\infty}^{\infty} u \exp\left(-\frac{u^2}{2}\right) du \int_{-\infty}^{\infty} v \exp\left(-\frac{v^2}{2}\right) dv = 0 \\ \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} v^2 \exp\left(-\frac{u^2+v^2}{2}\right) dudv &= \int_{-\infty}^{\infty} \exp\left(-\frac{u^2}{2}\right) du \int_{-\infty}^{\infty} v^2 \exp\left(-\frac{v^2}{2}\right) dv = 2\pi,\end{aligned}$$

可得 $Cov(X, Y) = \rho\sigma_1\sigma_2$ ，因此

$$Corr(X, Y) = \frac{Cov(X, Y)}{\sqrt{Var(X)}\sqrt{Var(Y)}} = \frac{\rho\sigma_1\sigma_2}{\sigma_1\sigma_2} = \rho$$

至此，二维正态分布中5个参数的含义均已明确；

当 $\rho = 0$ ，即 X 与 Y 不相关时， X 与 Y 独立

$$\begin{aligned}f(x, y) &= \frac{1}{2\pi\sigma_1\sigma_2} \exp\left\{-\frac{1}{2}\left[\frac{(x-\mu_1)^2}{\sigma_1^2} + \frac{(y-\mu_2)^2}{\sigma_2^2}\right]\right\} \\ &= \frac{1}{\sqrt{2\pi}\sigma_1} \exp\left\{-\frac{(x-\mu_1)^2}{2\sigma_1^2}\right\} \cdot \frac{1}{\sqrt{2\pi}\sigma_2} \exp\left\{-\frac{(y-\mu_2)^2}{2\sigma_2^2}\right\} = f_X(x)f_Y(y)\end{aligned}$$

本章课后作业

1. 若随机变量 X 与 Y 的数学期望都存在，通过期望定义证明 $E(X + Y) = E(X) + E(Y)$ 从而说明“随机变量之和的期望等于各变量的期望之和”无需满足互斥的条件；通过期望的定义证明 X 与 Y 相互独立是 $E(XY) = E(X)E(Y)$ 成立的充分非必要条件（非必要可通过给出 X 与 Y 不相互独立但 $E(XY) = E(X)E(Y)$ 成立的例子）。
2. 某电子产品寿命（单位：年）服从指数分布，密度函数为 $f(x) = \begin{cases} \frac{1}{3}e^{-\frac{x}{3}}, & x > 0 \\ 0, & \text{其他} \end{cases}$ ，已知每件产品的生产成本为350元，出售价格为500元；若厂方向顾客承诺，如果产品出售1年之内发生故障，则免费调换一件，之后厂方不再承担后续责任；如果在1年以上3年之内发生故障，则予以一次免费维修，维修成本为50元；超过3年，则不负责免费维修；问该厂每售出一件产品，其平均净收入为多少？
3. 若 $X = (X_1, X_2, \dots, X_n)$ 服从多项分布 $M(N; p_1, \dots, p_n)$ ，试计算随机变量每个分量的期望与方差，以及分量两两之间的协方差与相关系数。
4. 若随机变量 X_i 与 Y 的协方差存在（ $i = 1, 2$ ），证明
$$\text{Cov}(X_1 + X_2, Y) = \text{Cov}(X_1, Y) + \text{Cov}(X_2, Y)。$$

本章课后作业

5. 设 X_i ($i = 1, 2, \dots, n$) 为独立同分布的随机变量, 若它们的方差存在, 记为 σ^2 , 令 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, 证明, 对任意 $k = 1, 2, \dots, n$, $Cov(\bar{X}, X_k) = \frac{\sigma^2}{n}$. 提示: 需用到上题证明的结论。
6. 独立掷一粒均匀的骰子 n 次 ($n \geq 2$), 记 X 与 Y 分别表示试验中1点朝上与6点朝上的出现的次数, 求 X 与 Y 的相关系数并判断两者的相关关系。
7. 设有1千万元要投资甲、乙两种证券, 若将资金 x 投资于甲证券, $y = 1 - x$ 投资于乙证券, 则 (x, y) 就形成一个投资组合, 记随机变量 X 与 Y 分别表示投资甲、乙证券的收益率; 已知 X 与 Y 的期望 (平均收益) 分别为 μ_1 和 μ_2 , 方差 (代表风险) 分别为 $\sigma_1^2 = 0.3$ 和 $\sigma_2^2 = 0.5$, X 与 Y 的相关系数为 $\rho = 0.4$, 试求该投资组合的平均收益 (期望) 与风险 (方差), 并求使投资组合风险最小的 x 是多少。

☺ 拓展阅读: 本章介绍了信息熵的基本概念, 在人工智能中, 信息熵有多个重要应用, 例如决策树中会用到熵与条件熵, 分类模型会用到交叉熵损失等。

The top banner features the Fudan University logo on the left, which includes the university's name in English ('FUDAN UNIVERSITY') and Chinese ('復旦大學'), along with the founding year '1905'. To the right of the logo are several interlocking blue gears of different sizes. Some gears contain white icons: a building, a graduation cap, a medical bag with a cross, a person silhouette, and an atomic symbol. The background is a light blue gradient with a dark blue curved shape on the far right.

人工智能的数学基础


04 随机样本与参数估计

李 斌

复旦大学 计算机科学技术学院

数理统计

- 概率论是数理统计学的基础，数理统计学是概率论的重要应用
- **数理统计**：使用概率论和数学的方法，通过试验或观察收集带有随机误差的数据，并在设定的模型之下，对这种数据进行分析，从而对所研究的问题作出推断（即**统计推断**^①）



^①英文为statistical inference。

总体与样本

- 在数理统计中，研究对象的全体称为**总体**，总体中的每个成员称为**个体**；总体中所包含的个体数称为**总体容量**，容量有（无）限的总体称为有（无）限总体
 - 某小学中10岁儿童的身高（有限）
 - 全国10岁儿童的身高（数量很多时可看作无限）
 - 某城市的PM2.5浓度（无限）
- 为了对总体进行研究，首先要收集数据，方法一般有两种：通过**试验**收集数据，通过**抽样**收集数据
 - 测量某个物体的重量（试验）
 - 某城市的PM2.5浓度（抽样）
 - 大学生的消费情况（抽样）
- 人工智能真实应用中的‘数据’通常是从无限总体中抽样出的数据

总体与样本

- 总体的某个（些）指标 X ，对于不同的个体来说有不同的取值，这些取值构成一个分布，因此 X 可以看作是一个随机变（向）量
- 总体分布不同，分析的方法也不同；赋有一定概率分布的总体称为**统计总体**，例如指数分布总体、正态分布总体等
- 数理统计主要任务是从总体中抽取一部分个体，称为**样本**，根据样本对总体分布给出推断
- 从总体 X 中随机抽取 n 个个体，记为 $X_1, \dots, X_n$ ，称为**随机样本**， n 为**样本容量**；若在抽取时确保总体中的每个个体等概率被抽中，则理论上 X_i 与总体 X 具有相同的分布；进一步，若每个个体独立抽取，则随机样本 $X_1, \dots, X_n$ 为**独立同分布**的随机变量，称为**简单随机样本**
- 对于有限总体，采用有放回的抽样就能得到简单随机样本；对于无限总体或当有限总体容量很大的时候，采用不放回抽样

①本课程之后提到的‘样本’均指简单随机样本。

统计推断

- 统计推断提供了从样本数据中推断出有关总体结论的方法，有两大类重要问题：**参数估计**与**假设检验**

- 例：某工厂生产大批的电子元件，假定元件的寿命服从指数分布，在实际应用中，可以提出许多感兴趣的问题，例如：1) 元件的平均寿命如何；2) 如果使用单位要求平均寿命达到5000小时，问这批元件可否被接受？

第一个问题是参数估计问题。由第三章中指数分布的数学期望可知，服从指数分布 $E(\lambda)$ 的期望寿命为 $\frac{1}{\lambda}$ ，而 λ 即为指数分布的参数，因此可以把问题转换为基于样本均值 $\bar{X}$ 估计 $\frac{1}{\lambda}$ 。

第二个问题是假设检验问题。既然可用 $\bar{X}$ 估计 $\frac{1}{\lambda}$ ，那么就可以看 $\bar{X}$ 是否不小于一个指定的数 C ，若 $\bar{X} \geq C$ （由于 $\bar{X}$ 是随机变量，因此不是直接与5000比较），则接受这批产品，否则不接受。

- 人工智能中主要涉及的是参数估计问题，即基于样本估计出能够刻画总体分布的模型参数，并用于预测来自同一个总体分布的未见样本

统计量

- 在获取样本之后，下一步就要从中提取有用信息对总体进行统计推断
- 完全由样本所决定的量叫作**统计量**；统计量不依赖于未知参数
- 例：设 $X_1, \dots, X_n$ 是从正态总体 $N(\mu, \sigma^2)$ 中抽出的样本，则 $\bar{X} = \frac{X_1 + \dots + X_n}{n}$ 是统计量，因为其完全由样本决定；而 $\bar{X} - \mu$ 不是统计量，因为 μ 未知
- 定义：设 $X_1, \dots, X_n$ 是来自总体 X 的一个样本， $g(X_1, \dots, X_n)$ 是样本的函数，若 g 中不含未知参数，则称 $g(X_1, \dots, X_n)$ 是一统计量
 1. 样本均值： $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$
 2. 样本方差： $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n-1} (\sum_{i=1}^n X_i^2 - n\bar{X}^2)$
无偏估计（见后）
 3. 样本标准差： $S = \sqrt{S^2}$

统计量

4. 样本 k 阶原点矩: $a_k = \frac{1}{n} \sum_{i=1}^n X_i^k$, $k = 1, 2, \dots$

5. 样本 k 阶中心矩: $m_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$, $k = 1, 2, \dots$

■ 对以上几个常用统计量, 有如下说明:

- ✓ 一般采用样本均值 $\bar{X}$ 作为总体均值 μ 的估计, 采用样本方差 S^2 作为总体方差 σ^2 的估计
- ✓ 总体方差的估计可以用 S^2 也可以用 m_2 , 区别在于 S^2 是无偏估计, 两者相差一个常数因子: $m_2 = \frac{n-1}{n} S^2$
- ✓ 总体的任一个未知参数可以有多个不同的估计, 因此参数估计不唯一
- ✓ 假设 $X_1, \dots, X_n$ 是一个从总体 X 中抽取的简单随机样本, $\mu_k = E(X^k)$ 存在, 由辛钦大数定律可知 $\lim_{n \rightarrow \infty} P\{|a_k - \mu_k| \geq \epsilon\} = 0$, $k = 1, 2, \dots$

统计量

- 例：设一批灯泡的寿命 X （单位：时）服从参数为 λ 的指数分布， λ 未知，从该批灯泡中采用简单随机抽样抽取容量为10的样本 $X_1, \dots, X_{10}$ ，样本观测值分别为 $x_1, \dots, x_{10}$ ，1）写出总体 X 的概率密度函数；2）写出样本的联合概率密度函数；3）计算样本均值

解：1）总体 X 的概率密度函数为 $f(x; \lambda) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & \text{其他} \end{cases}$


2）样本 $X_1, \dots, X_{10}$ 的联合概率密度函数为

$$f(x_1, \dots, x_{10}; \lambda) = \underbrace{f(x_1; \lambda) \dots f(x_{10}; \lambda)}_{X_1, \dots, X_{10} \text{独立同分布}} = \begin{cases} \lambda^{10} e^{-\lambda \sum_{i=1}^{10} x_i}, & x_1, \dots, x_{10} > 0 \\ 0, & \text{其他} \end{cases}$$

3）样本均值 $\bar{x} = \frac{1}{10} \sum_{i=1}^{10} x_i$

参数的点估计

- 设总体 X 的概率密度函数（ X 为连续型）或概率分布（ X 为离散型）为 $f(x; \theta)$ ^①， $X_1, \dots, X_n$ 是 X 的一个样本，点估计问题就是要构造一个适当的统计量 $\hat{\theta}(X_1, \dots, X_n)$ 估计参数 θ ，称 $\hat{\theta}(X_1, \dots, X_n)$ 为 θ 的一个**估计量**
- 由于未知参数 θ 与其估计量 $\hat{\theta}$ 均为坐标系中的点，因此称为**点估计**
- 两种常用的点估计方法：**矩估计**与**极大似然估计**



^①本课程之后称 $f(x; \theta)$ 为‘总体分布’，分号之后的 θ 表示分布的参数， $\theta = \{\theta_1, \dots, \theta_m\}$ 可以是一组参数。

矩估计

- 矩估计法由英国统计学家皮尔逊（K. Pearson）于1894年提出
- 理论依据：矩估计法的理论依据为大数定律，即当样本容量 $n \rightarrow \infty$ 时，样本矩（ a_k 或 m_k ）依概率收敛于相应的总体矩（ α_k 或 μ_k ）
- 基本思想：用样本矩作为相应总体矩的估计
- 基本步骤：设 $\theta_1, \dots, \theta_m$ 是总体 X 的待估参数，并假定 X 的前 m 阶矩存在
 - 1、求总体 X 的前 m 阶矩（不妨设是原点矩） $\alpha_1, \dots, \alpha_m$ ，并写成待估参数 $\theta_1, \dots, \theta_m$ 的函数形式，联立方程组
$$\begin{cases} \alpha_1 = E(X) = g_1(\theta_1, \dots, \theta_m) \\ \dots \dots \\ \alpha_m = E(X^m) = g_m(\theta_1, \dots, \theta_m) \end{cases}$$
 - 2、求出 θ_k 关于前 m 阶矩的函数表达式 $\theta_k = h_k(\alpha_1, \dots, \alpha_m)$, $k = 1, \dots, m$
 - 3、根据矩估计思想，以 a_k 代替 α_k 可得 $\hat{\theta}_k = h_k(a_1, \dots, a_m)$, $k = 1, \dots, m$

矩估计

■ 例：设 $X_1, \dots, X_n$ 是从正态总体 $N(\mu, \sigma^2)$ 中抽出的样本，求 μ, σ^2 的矩估计

解： μ 是总体一阶原点矩，用样本一阶原点矩 $\bar{X}$ 估计：

$$\hat{\mu} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

σ^2 是总体方差（总体二阶中心矩），可用样本二阶中心矩 m_2 估计：

$$\hat{\sigma}^2 = S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{n}{n-1} m_2 \quad \text{修正为无偏估计}$$

■ 例：设 $X_1, \dots, X_n$ 是从均匀总体 $U(a, b)$ 中抽出的样本，求 a 和 b 的矩估计

解：已知均匀分布的均值和方差分别为 $\frac{a+b}{2}$ 和 $\frac{(b-a)^2}{12}$ ，联立方程
$$\begin{cases} \bar{X} = \frac{(a+b)}{2} \\ m_2 = \frac{(b-a)^2}{12} \end{cases}$$
可得 $\hat{a} = \bar{X} - \sqrt{3m_2}^{\textcircled{1}}$ ， $\hat{b} = \bar{X} + \sqrt{3m_2}$

^①可用 S 代替 $\sqrt{m_2}$ ，后面不再累述。

矩估计

- 例：设 $X_1, \dots, X_n$ 是从二项总体 $B(n, p)$ 中抽出的样本，求 p 的矩估计

解： np 是总体的均值，可用样本一阶原点矩 $\bar{X}$ 估计： $\hat{p} = \frac{\bar{X}}{n}$

- 例：设 $X_1, \dots, X_n$ 是从指数总体 $E(\lambda)$ 中抽出的样本，求 λ 的矩估计

解： $\frac{1}{\lambda}$ 是总体的均值，可用样本一阶原点矩 $\bar{X}$ 估计： $\hat{\lambda} = \frac{1}{\bar{X}}$

哪个估计好？

$\frac{1}{\lambda^2}$ 是总体的方差，也可用样本二阶中心矩 m_2 估计： $\hat{\lambda} = \frac{1}{\sqrt{m_2}}$

- 例：设 $X_1, \dots, X_n$ 是从泊松总体 $P(\lambda)$ 中抽出的样本，求 λ 的矩估计

解： λ 是总体的均值，可用样本一阶原点矩 $\bar{X}$ 估计： $\hat{\lambda} = \bar{X}$

哪个估计好？

λ 是总体的方差，也可用样本二阶中心矩 m_2 估计： $\hat{\lambda} = m_2$

矩估计

■ 矩估计法的优点：

- ✓ 简便易行
- ✓ 当样本容量趋向无穷大时，矩估计量依概率收敛于相应参数
- ✓ 即使总体分布形式未知，只要知道待估参数关于总体各阶矩的函数形式时，便可求出该参数的矩估计

■ 矩估计法的缺点：

- ✓ 矩估计量不具有唯一性 通常能用低阶矩处理就不用高阶矩
- ✓ 矩估计量有时会不太合理 例如总体 $X \sim U[0, \theta]$ ，观测值分别为1,2,9时 $\hat{\theta} = 8$
- ✓ 在总体分布形式已知时，没有充分利用总体分布所提供的信息

极大似然估计


- 极大似然估计^①是在**参数分布族**的情况下使用的一种最广泛的参数估计方法，也是人工智能中用于模型参数估计的主要方法
 - 极大似然估计的思想始于德国数学家**高斯**的误差理论，由英国统计学家**费歇尔**（R. A. Fisher）在1912年至1922年间分析并大范围推广
- 独立同分布
- 设总体分布为 $f(x; \theta)$ ， $X_1, \dots, X_n$ 为从总体中抽出的简单随机样本，则 $X_1, \dots, X_n$ 的联合分布为 $\prod_{i=1}^n f(x_i; \theta)$ ，记为 $L(x_1, \dots, x_n; \theta)$ ；当把 $X_1, \dots, X_n$ 固定而把 L 看作是 θ 的函数时， L 称为**似然函数**
 - 若 $L(x_1, \dots, x_n; \theta') > L(x_1, \dots, x_n; \theta'')$ ，则说明被估计的参数是 θ' 的可能性比 θ'' 更大，但极大似然估计中参数并不是随机变量，无概率可言，因此改用‘似然’这个词

^①英文为Maximum Likelihood Estimation（简称MLE）。

极大似然估计

- 基本思想：把 $x_1, \dots, x_n$ 看作已知， θ 看作未知，改变 θ 使 $L(x_1, \dots, x_n; \theta)$ 取得最大值，即使用满足以下条件的 θ^* 作为估计值

$$L(x_1, \dots, x_n; \theta^*) = \max_{\theta} L(x_1, \dots, x_n; \theta)$$



极大似然估计

- 寻求极大似然估计可通过对 $L(x_1, \dots, x_n; \theta)$ 求 θ_i 的偏导并设为0求解；但由于 L 是乘积的形式，通常对 L 求对数后求解更方便

$$\ln L(x_1, \dots, x_n; \theta) = \ln \prod_{i=1}^n f(x_i; \theta) = \sum_{i=1}^n \ln f(x_i; \theta)$$

- 在 f 对 $\theta = \{\theta_1, \dots, \theta_k\}$ 存在连续的偏导数时，建立似然方程组

$$\frac{\partial \ln L(x_1, \dots, x_n; \theta_1, \dots, \theta_k)}{\partial \theta_i} = 0, \quad i = 1, \dots, k$$

- 若似然方程组有唯一解且是极大值点，则该点即为极大似然估计

极大似然估计

■ 设 $X_1, \dots, X_n$ 是从正态总体 $N(\mu, \sigma^2)$ 中抽出的样本，求 μ 和 σ^2 的MLE

解：似然函数为 $L(x_1, \dots, x_n; \mu, \sigma^2) = \prod_{i=1}^n \left[\frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right) \right]$

取对数得： $\ln L = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$

分别对 μ 和 σ^2 求偏导并设为0得到似然方程组：

$$\begin{cases} \frac{\partial \ln L}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \\ \frac{\partial \ln L}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2 = 0 \end{cases}$$

由第一式可得^①： $\mu^* = \frac{1}{n} \sum_{i=1}^n x_i = \bar{X}$ 与矩估计相同

把 $\mu^* = \bar{X}$ 代入第二式可得： $\sigma^{*2} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{X})^2 = m_2$ 与矩估计相同

^①还需验证是否是极大值点，可通过二阶导数是否小于0或者似然函数关于待估参数的单调性来判断。

极大似然估计

- 设 $X_1, \dots, X_n$ 是从指数总体 $E(\lambda)$ 中抽出的样本，求 λ 的MLE

解：似然函数为 $L(x_1, \dots, x_n; \lambda) = \prod_{i=1}^n (\lambda e^{-\lambda x_i})$ ，故 $\ln L = n \ln \lambda - \lambda \sum_{i=1}^n x_i$

对 λ 求偏导并设为0： $\frac{\partial \ln L}{\partial \lambda} = \frac{n}{\lambda} - \sum_{i=1}^n x_i = 0$

得到 λ 的极大似然估计为： $\lambda^* = \frac{n}{\sum_{i=1}^n x_i} = \frac{1}{\bar{X}}$ 与其一阶原点矩估计相同

- 设 $X_1, \dots, X_n$ 是从泊松总体 $P(\lambda)$ 中抽出的样本，求 λ 的MLE

解：似然函数为 $L(x_1, \dots, x_n; \lambda) = \prod_{i=1}^n \left(\frac{\lambda^{x_i}}{x_i!} e^{-\lambda} \right) = \frac{\lambda^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n x_i!} e^{-n\lambda}$

取对数得： $\ln L = (\sum_{i=1}^n x_i) \ln \lambda - \sum_{i=1}^n \ln(x_i!) - n\lambda$

对 λ 求偏导并设为0： $\frac{\partial \ln L}{\partial \lambda} = \frac{\sum_{i=1}^n x_i}{\lambda} - n = 0$

得到 λ 的极大似然估计为： $\lambda^* = \frac{\sum_{i=1}^n x_i}{n} = \bar{X}$ 与其一阶原点矩估计相同

极大似然估计

- 设 $X_1, \dots, X_n$ 是从二项总体 $B(n, p)$ 中抽出的样本，求 p 的MLE

解：似然函数为 $L(x_1, \dots, x_n; p) = \prod_{i=1}^n \left[\binom{N}{x_i} p^{x_i} (1-p)^{N-x_i} \right]$

取对数得： $\ln L = \sum_{i=1}^n \ln \binom{N}{x_i} + \sum_{i=1}^n x_i \ln p + \sum_{i=1}^n (N - x_i) \ln(1-p)$

对 p 求偏导并设为0： $\frac{\partial \ln L}{\partial p} = \frac{\sum_{i=1}^n x_i}{p} - \frac{nN - \sum_{i=1}^n x_i}{1-p} = 0$

得到 p 的极大似然估计为： $p^* = \frac{\sum_{i=1}^n x_i}{nN} = \frac{\bar{X}}{n}$ 与其一阶原点矩估计相同

- 以上几个应用中常见分布的参数的极大似然估计与矩估计一致，这并非是一般情形；但这种巧合也可一定程度说明估计是良好的

极大似然估计

■ 设 $X_1, \dots, X_n$ 是从均匀总体 $U(a, b)$ 中抽出的样本，求 a 和 b 的MLE

解：似然函数为
$$L(x_1, \dots, x_n; a, b) = \begin{cases} \frac{1}{(b-a)^n}, & \text{若 } a \leq x_i \leq b, i = 1, 2, \dots, n \\ 0, & \text{其他} \end{cases}$$

根据极大似然估计的定义，为使 $L(x_1, \dots, x_n; a, b)$ 达到最大，则 $(b - a)$ 要尽量的小，并且 b 不能小于 $\max(x_1, \dots, x_n)$ ， a 不能大于 $\min(x_1, \dots, x_n)$ ，否则会导致 $L = 0$

因此 a 和 b 的极大似然估计^①分别为：

$$\begin{aligned} a^* &= \min(x_1, \dots, x_n) \\ b^* &= \max(x_1, \dots, x_n) \end{aligned} \quad \text{与矩估计不同}$$

^①均匀总体参数 a 和 b 的MLE是顺序统计量，常见的顺序统计量包括样本的最大值、最小值、中位数等。

点估计的评价准则

- **无偏性**：估计量是统计量，其取值随着样本值的改变而改变，一个自然的评价指标即要求在大量重复抽样时，估计值 $\hat{\theta}(X_1, \dots, X_n)$ 的期望应与待估参数的真值 θ 相同，即满足 $E(\hat{\theta}) = \theta$ ，则称 $\hat{\theta}$ 是 θ 的**无偏估计**
- 例：设 $X_1, \dots, X_n$ 是从某总体中抽出的样本，则样本均值 $\bar{X}$ 是总体分布均值 μ 的无偏估计

解：由于 X_i 与总体分布相同，因此 $E(X_i) = \mu$ ，可得

$$E(\bar{X}) = E\left(\frac{\sum_{i=1}^n X_i}{n}\right) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \frac{n\mu}{n} = \mu$$

由此可知以下都是无偏估计：正态总体中用 $\bar{X}$ 估计 μ ；指数总体中用 $\frac{1}{\bar{X}}$ 估计 λ ；泊松总体中用 $\bar{X}$ 估计 λ ；二项总体中用 $\frac{\bar{X}}{n}$ 估计 p

点估计的评价准则

- 例：设 $X_1, \dots, X_n$ 是从某总体中抽出的样本，则样本方差 S^2 是总体分布方差 σ^2 的无偏估计

解：由上例已知 $E(\bar{X}) = \mu$ ，利用方差的性质可得

$$Var(\bar{X}) = Var\left(\frac{\sum_{i=1}^n X_i}{n}\right) = \frac{1}{n^2} \sum_{i=1}^n Var(X_i) = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}$$

对样本方差 S^2 求期望


$$\begin{aligned} E(S^2) &= E\left[\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right] = \frac{1}{n-1} E\left[\sum_{i=1}^n X_i^2 - n\bar{X}^2\right] \\ &= \frac{1}{n-1} \left[\sum_{i=1}^n E(X_i^2) - nE(\bar{X}^2)\right] \\ &= \frac{1}{n-1} \left[\sum_{i=1}^n (\sigma^2 + \mu^2) - n\left(\frac{\sigma^2}{n} + \mu^2\right)\right] = \sigma^2 \end{aligned}$$

$E(X_i^2) = Var(X_i) + [E(X_i)]^2$ $E(\bar{X}^2) = Var(\bar{X}) + [E(\bar{X})]^2$

一元线性回归

- 一元线性回归模型为 $y_i = wx_i + b + \epsilon_i$, $i = 1, \dots, n$, 其中 w 和 b 是未知参数, $\epsilon_i \sim N(0, \sigma^2)$ 为随机测量误差, (x_i, y_i) 为观测变量
- 假设独立测量的数据 $\{(x_i, y_i)\}_{i=1}^n$ 具有相同分布的测量误差, 可知 $y_i \sim N(wx_i + b, \sigma^2)$, 假设 σ^2 已知, 使用MLE估计 w 和 b

均值 μ 为 w 和 b 的线性函数



- 一元线性回归模型的极大似然估计与最小化均方误差等价, 即
$$\min_{w,b} \sum_{i=1}^n (y_i - (wx_i + b))^2$$
, 后者即著名的**最小二乘法**

本章课后作业

1. 设总体 X 的概率密度函数为 $f(x; \theta) = \begin{cases} \frac{6x(\theta-x)}{\theta^3}, & 0 < x < \theta \\ 0, & \text{其他} \end{cases}$ ，其中 $\theta > 0$ 未知， $X_1, \dots, X_n$ 是来自总体 X 的简单随机样本，求 θ 的矩估计量 $\hat{\theta}$ ，并计算 $E(\hat{\theta})$ 与 $Var(\hat{\theta})$ 。
2. 在一次抛硬币试验中，统计硬币正面朝上与反面朝上的次数，分别为 n^+ 与 n^- ，假设每次试验独立且服从相同的伯努利分布，求正面朝上概率的极大似然估计。
3. 求解一元线性回归模型参数 w 和 b 的极大似然估计（提示：虽然 $N(wx_i + b, \sigma^2)$ 的均值各不相同，但所有均值中都有共同的未知参数 w 和 b ）。
4. 设总体 X 的均值为1，方差 σ^2 存在， $X_1, \dots, X_n$ 是来自总体 X 的样本，判断估计量 $\frac{1}{n} \sum_{i=1}^n X_i^2 - 1$ 与 $\frac{1}{n} \sum_{i=1}^n (X_i - 1)^2$ 是否为 σ^2 的无偏估计。

☺ 拓展阅读：在机器学习中，极大似然估计被广泛应用于模型参数估计，包括回归模型（线性回归是最简单的回归模型）与分类模型（对数几率回归是最简单的分类模型之一）等。

The top banner features the Fudan University logo on the left, which includes the university's name in English ('FUDAN UNIVERSITY') and Chinese ('復旦大學'), along with the founding year '1905'. To the right of the logo are several interlocking blue gears. Some of these gears contain white icons: a building, a graduation cap, a medical cross, a person silhouette, and an atomic symbol. The background of the banner is a light blue gradient with a dark blue curved shape on the far right.

人工智能的数学基础

05 贝叶斯估计

李 斌

复旦大学 计算机科学技术学院

极大似然估计的缺点

- 例：在一次抛硬币试验中，硬币正面与反面朝上的次数分别为 n^+ 与 n^- ，假设每次试验独立且服从参数为 p 的伯努利分布，则正面朝上概率的极大似然估计为：
$$p^{\text{MLE}} = \frac{n^+}{n^+ + n^-}$$

若统计得到正面朝上的次数是9，反面朝上的次数是1，则 $p^* = \frac{1}{10}$ ；合理吗？

若统计得到正面朝上的次数是0，反面朝上的次数是3，则 $p^* = ?$ 。

- 例：设某路段相邻两次交通事故间隔时间（单位小时）为服从参数为 λ 的指数分布，则间隔时间的极大似然估计为：
$$\frac{1}{\lambda^{\text{MLE}}} = \frac{\sum_{i=1}^n x_i}{n}$$

若该地段只发生过两次交通事故，即间隔时间只观测到一次 x_1 ，则 $\frac{1}{\lambda^*} = x_1$ ；合理吗？

若该地段尚未发生过第二次交通事故，则 $\frac{1}{\lambda^*} = ?$

- 极大似然估计在观测太少或缺失的情况下会出现问题^①

^①机器学习中称为模型的过拟合（overfitting）。

贝叶斯统计

- 极大似然估计把 $X = \{X_1, \dots, X_n\}$ 看作已知，参数 θ 看作未知（但非随机变量），求解 $\theta^{\text{MLE}} = \operatorname{argmax}_{\theta} L(x_1, \dots, x_n; \theta)$
- 在贝叶斯统计中，参数 θ 被看作是一个**随机变量**^①，服从一定的分布 $p(\theta)$ ，该分布是在试验之前对 θ 的认识，因此称为**先验分布**
 - 抛硬币正面朝上的先验概率为50%（先验知识）
 - 相邻两次交通事故间隔时间的先验概率为相似路段历史记录均值（以往经验）
 - 目测今天下雨的概率为70%（主观概率）
- 把随机变量 X 与 θ 代入贝叶斯公式可得参数的**后验分布** $p(\theta|X)$

$$\text{后验分布 } p(\theta|X) = \frac{\text{先验分布 } p(\theta) \text{ 似然函数 } L(X; \theta)}{p(X)}$$



^① 贝叶斯学派把参数看作随机变量；频率学派（Frequentist）把参数看作固定的未知变量。

最大后验概率

- 通过最大化参数的后验概率 $p(\theta|X)$ 可得 θ 的**最大后验概率**^①估计

$$\begin{aligned}\theta^{\text{MAP}} &= \operatorname{argmax}_{\theta} p(\theta|X) = \operatorname{argmax}_{\theta} p(\theta|\{x_i\}_{i=1}^n) \\ &= \operatorname{argmax}_{\theta} \frac{p(\theta)L(\{x_i\}_{i=1}^n;\theta)}{\underbrace{p(\{x_i\}_{i=1}^n)}_{\text{常数}}} \\ &= \operatorname{argmax}_{\theta} p(\theta)L(\{x_i\}_{i=1}^n;\theta) \\ &= \operatorname{argmax}_{\theta} \underbrace{p(\theta)}_{\text{与MLE的区别}} \prod_{i=1}^n f(x_i;\theta)\end{aligned}$$

- MAP把贝叶斯估计中参数后验分布的推断转化为寻找其最优解的优化问题（**点估计**）

^①英文为Maximum *a posteriori*（简写MAP）。

最大后验概率

- 与MLE一样，MAP也可先对 $p(\theta)L(X; \theta)$ 求对数后再求解

$$\begin{aligned}\ln p(\theta)L(X; \theta) &= \ln p(\theta) \prod_{i=1}^n f(x_i; \theta) \\ &= \sum_{i=1}^n \ln f(x_i; \theta) + \ln p(\theta) \quad \text{与MLE的区别}\end{aligned}$$

- 在 f 与 p 对 $\theta = \{\theta_1, \dots, \theta_k\}$ 存在连续的偏导数时，建立方程组求解

$$\frac{\partial \{\sum_{i=1}^n \ln f(x_i; \theta) + \ln p(\theta)\}}{\partial \theta_j} = 0, \quad j = 1, \dots, k$$

- 例：一元线性回归模型为 $y_i = wx_i + b + \epsilon_i$, $i = 1, \dots, n$ ，其中 w 和 b 是未知参数， $\epsilon_i \sim N(0, \sigma^2)$ 为随机测量误差；假设独立测量的数据 $\{(x_i, y_i)\}_{i=1}^n$ 具有相同分布的测量误差， w 和 b 服从相同的先验分布 $N(0, \tau^2)$ ，使用MAP估计 w 和 b （见课后作业）

最大后验概率

- 例：在一次抛硬币试验中，抛10次硬币，其中正面朝上的次数是7，反面朝上的次数是3，假设每次试验独立且服从相同的伯努利分布，记参数 θ 为硬币正面朝上的概率；从常识得知，抛一枚正常的硬币，正面朝上的概率 $\theta = 0.5$ ，因此假设 θ 服从正态分布 $N(0.5, 0.01)$ ，写出参数 θ 的MAP估计表达式


解：每次抛硬币服从伯努利分布： $f(x_i; \theta) = \theta^{x_i}(1 - \theta)^{1-x_i}$ ， $x_i = 0, 1$

则似然函数 $L(X; \theta) = \prod_{i=1}^{10} f(x_i; \theta) = \theta^7(1 - \theta)^3$

参数先验服从正态分布： $p(\theta) = \frac{1}{0.1\sqrt{2\pi}} e^{\frac{-(\theta-0.5)^2}{2 \times 0.01}}$

$$\begin{aligned}\theta^{\text{MAP}} &= \operatorname{argmax}_{\theta} p(\theta) \prod_{i=1}^{10} f(x_i; \theta) \\ &= \operatorname{argmax}_{\theta} \left\{ e^{-50(\theta-0.5)^2} \theta^7(1 - \theta)^3 \right\}\end{aligned}$$

在 $\theta = 0.558$ 附近取到最大值



贝叶斯估计

- 在贝叶斯统计中，如果后验分布与先验分布属于同类，则先验分布与后验分布称为**共轭分布**，先验分布称为似然函数的**共轭先验**^①
- 共轭分布是贝叶斯估计使用过程中的一类重要工具， $p(X)$ 在贝叶斯估计中不可忽略，但往往难以计算，通常可通过引入似然函数的共轭先验**闭式求解**后验分布 $p(\theta|X)$ 的参数


$$p(\theta|X) = \frac{p(\theta)L(X;\theta)}{p(X)} = \frac{p(\theta)L(X;\theta)}{\int_{\theta'} p(\theta')L(X;\theta') d\theta'}$$

θ 为随机变量 通常难以计算


例子	先验分布	似然函数	后验分布
抛硬币正面朝上次数	Beta分布	二项分布	Beta分布
交通事故间隔时间	Gamma分布	指数分布	Gamma分布
某城市的PM2.5浓度	正态分布（方差已知）	正态分布	正态分布（方差已知）

^①英文为conjugate prior。


贝叶斯估计




二项分布 $B(n, p)$, $p \in [0, 1]$



$p \sim \text{Beta}(\alpha, \beta)$, $\alpha, \beta > 0$



指数分布 $E(\lambda)$, $\lambda \in (0, \infty)$





$\lambda \sim \text{Gamma}(k, \theta)$, $k, \theta > 0$

贝叶斯估计

■ 狄利克雷分布^①是多项分布的共轭先验

当多项分布 $M(n; p_1, \dots, p_K)$ 中的参数 $[p_1, \dots, p_K]^T$ 为随机向量时，需采用支撑集满足 $p_i \geq 0$ 且 $p_1 + \dots + p_n = 1$ 的分布，狄利克雷分布 $Dir(\alpha_1, \dots, \alpha_K)$ 即为此类分布



^①英文为Dirichlet distribution。

贝叶斯估计

■ 狄利克雷分布是多项分布的共轭先验

μ 为 K 维随机向量, $\mu_k \in (0,1)$ 且满足
 $\sum_{k=1}^K \mu_k = 1$; $E(\mu_k) = \frac{\alpha_k}{\sum_{k'=1}^K \alpha_{k'}}$

狄利克雷分布: $Dir(\mu; \alpha)^{\textcircled{1}} = \frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\Gamma(\alpha_1) \dots \Gamma(\alpha_k)} \prod_{k=1}^K \mu_k^{\alpha_k-1}$
 α 为 K 维超参数, $\alpha_k > 0$

多项分布: $Mult(x|\mu; n) = \frac{n!}{x_1! \dots x_K!} \prod_{k=1}^K \mu_k^{x_k}$
 x 为 K 维随机向量, $\sum_{k=1}^K x_k = N$

根据贝叶斯公式, μ 的后验分布为 $Dir(\mu|x; \alpha) = \frac{Dir(\mu; \alpha) Mult(x|\mu; n)}{p(x)}$, 该分布的参数是 α 和 x 的闭式表达式

^① $Dir(\mu; \alpha)$ 表示 μ 在 $Dir(\alpha)$ 分布下的概率, $Mult(x|\mu; n)$ 表示 x 在 $Mult(\mu; n)$ 分布下给定 μ 的条件概率。

贝叶斯估计

接上页：由 $Dir(\mu|x; \alpha) = \frac{Dir(\mu; \alpha) Mult(x|\mu; n)}{p(x)}$ 可得

$$\begin{aligned} Dir(\mu|x; \alpha) &= \frac{1}{p(x)} Dir(\mu; \alpha) Mult(x|\mu; n) \\ &= \left\{ \frac{1}{p(x)} \cdot \frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\Gamma(\alpha_1) \dots \Gamma(\alpha_K)} \cdot \frac{n!}{x_1! \dots x_K!} \right\} \cdot \prod_{k=1}^K \mu_k^{x_k} \cdot \prod_{k=1}^K \mu_k^{\alpha_k - 1} \\ &= C \cdot \prod_{k=1}^K \mu_k^{x_k + \alpha_k - 1} \\ &= Dir(\mu|x + \alpha) \end{aligned}$$

直接可知 $x_k + \alpha_k$ 为后验分布第 k 维参数，无需计算 C

狄利克雷分布的标准形式中， $\mu_k^{\alpha_k - 1}$ 中的 α_k 即为参数的第 k 维；由于此例中共轭分布的形式保证了 μ 的后验分布**一定是**狄利克雷分布，因此根据分布形式的对应关系立即可知上式 $\mu_k^{x_k + \alpha_k - 1}$ 中的 $x_k + \alpha_k$ 为后验分布第 k 维的参数，无需计算复杂的常数 C

贝叶斯估计

- 狄利克雷分布和多项分布这对共轭分布具有多种特殊形式

狄利克雷分布 $\xrightarrow{K=2}$ Beta分布

多项分布 $\xrightarrow{n=1}$ 类别分布

多项分布 $\xrightarrow{K=2}$ 二项分布

二项分布 $\xrightarrow{n=1}$ 伯努利（0—1）分布

	先验分布	似然函数	后验分布
维度 $K > 2$ 观测 $n > 1$	狄利克雷分布 (K 维参数 α)	多项分布 (参数 μ, n)	狄利克雷分布 (K 维参数 $x + \alpha$, 其中 $\sum_{k=1}^K x_k = n$)
维度 $K > 2$ 观测 $n = 1$	狄利克雷分布 (K 维参数 α)	类别分布 (参数 μ)	狄利克雷分布 (K 维参数 $x + \alpha$, 其中 $\sum_{k=1}^K x_k = 1$)
维度 $K = 2$ 观测 $n > 1$	Beta分布 (两个参数 α, β)	二项分布 (参数 p, n)	Beta分布 (参数 $x_1 + \alpha, x_2 + \beta$, 其中 $x_1 + x_2 = n$)
维度 $K = 2$ 观测 $n = 1$	Beta分布 (两个参数 α, β)	伯努利分布 (参数 p)	Beta分布 (参数 $x_1 + \alpha, x_2 + \beta$, 其中 $x_1 + x_2 = 1$)

贝叶斯估计

- 例：实验室向某学术会议投稿 n 篇论文，录用 n^+ 篇，未录用 n^- 篇，假设录用先验概率为会议的平均录用率，服从参数为 (α, β) 的Beta分布，每篇投稿独立且录用结果服从相同的伯努利分布，求录用结果出来前与出来后对录用率的期望

解：录用结果 n^+ 为 n 重伯努利试验，因此服从参数为 (n, p) 的二项分布

录用率 p 是服从Beta分布的随机变量，由贝叶斯公式可得

$$Beta(p|n^+; \alpha, \beta, n) = \frac{Binomial(n^+|p; n)Beta(p; \alpha, \beta)}{p(x)}$$

由Beta分布和二项分布的共轭性可得，录用率 p 的后验分布是参数为 $(n^+ + \alpha, n^- + \beta)$ 的Beta分布

因此录用率的期望为：出结果前 $\frac{\alpha}{\alpha+\beta}$ ，出结果后 $\frac{n^++\alpha}{n+\alpha+\beta}$ 。

已知服从狄利克雷（包括Beta分布）
的随机变量的期望为 $E(\mu_k) = \frac{\alpha_k}{\sum_{k'=1}^K \alpha_{k'}}$

贝叶斯估计

- 由于共轭分布对的后验与先验的类型一致，因此当前推断得到的后验分布可以作为下次推断的先验分布，形成类似人类决策的闭环

- 例：问题设置接前例，实验室从去年开始每年都向某学术会议投稿

1. 去年未投稿之前

先验： $p^{(0)} \sim \text{Beta}(\alpha, \beta)$

录用率的期望为 $\frac{\alpha}{\alpha+\beta}$

2. 去年5投2中

似然： $n^+ = 2 \sim \text{Binomial}(n = 5, p^{(0)})$

后验（下次先验）： $p^{(1)} \sim \text{Beta}(\alpha + 2, \beta + 3)$

今年录用率的期望为 $\frac{\alpha+2}{\alpha+\beta+5}$

3. 今年2投1中

似然： $n^+ = 1 \sim \text{Binomial}(n = 2, p^{(1)})$

后验（下次先验）： $p^{(2)} \sim \text{Beta}(\alpha + 2 + 1, \beta + 3 + 1)$

明年录用率的期望为 $\frac{\alpha+3}{\alpha+\beta+7}$

贝叶斯估计

- 假设方差已知，正态分布是正态分布的共轭先验
- 例：假设 $X_1, \dots, X_n$ 是从正态总体 $N(\theta, 1)$ 抽出的样本， θ 的先验分布为正态分布 $N(\mu, \sigma^2)$ ， μ, σ^2 已知，求 θ 的贝叶斯估计

已知： $p(\theta) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(\theta-\mu)^2}{2\sigma^2}}$, $p(x_i) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(x_i-\theta)^2}{2}}$

根据贝叶斯公式， θ 的后验分布为

$$\begin{aligned} p(\theta|\{x_i\}_{i=1}^n; \mu, \sigma^2) &= \frac{p(\theta) \prod_{i=1}^n p(x_i)}{p(\{x_i\}_{i=1}^n)} = \frac{\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(\theta-\mu)^2}{2\sigma^2}} \prod_{i=1}^n \left\{ \frac{1}{\sqrt{2\pi}} e^{-\frac{(x_i-\theta)^2}{2}} \right\}}{p(\{x_i\}_{i=1}^n)} \\ &= C \cdot e^{-\left[\frac{(\theta-\mu)^2}{2\sigma^2} + \sum_{i=1}^n \frac{(x_i-\theta)^2}{2} \right]} = C' \cdot e^{-\frac{-(\theta-\tau)^2}{2\eta^2}} \end{aligned}$$

因此 θ 的后验分布为 $N(\tau, \eta^2)$ ，其中 $\tau = \frac{n}{n+1/\sigma^2} \bar{x} + \frac{1/\sigma^2}{n+1/\sigma^2} \mu$ ， $\eta^2 = \frac{1}{n+1/\sigma^2}$ ，该分布的参数是 μ, σ^2 和 $x_1, \dots, x_n$ 的**闭式**表达式

贝叶斯估计

- 贝叶斯估计综合了先验信息与样本信息，是两者的折中；从前面介绍的两类典型的共轭分布对可以看出

1. 当 $n = 0$ 时，后验分布参数由先验分布决定： $Dir(\alpha_1, \dots, \alpha_K)$, $N(\mu, \sigma^2)$
2. 当 n 变大时，样本信息在后验分布参数中的比重越来越大
3. 当 $n \rightarrow \infty$ 时，先验信息对后验分布参数的影响可以忽略

狄利克雷分布后验： $Dir(x_1 + \alpha_1, \dots, x_K + \alpha_K)$ x_i 为第 i 类上的真实计数， α_i 可看作为‘伪计数’

正态分布后验： $N\left(\frac{n}{n+1/\sigma^2}\bar{x} + \frac{1/\sigma^2}{n+1/\sigma^2}\mu, \frac{1}{n+1/\sigma^2}\right)$ 当先验分布参数 σ^2 越小时，先验参数 μ 的权重就越大

- 贝叶斯估计由于具有上述优点，在人工智能中具有广泛的应用

本章课后作业

1. 求解一元线性回归模型参数 w 和 b 的最大后验概率（MAP）估计（题目见第5页），并与第4章课后作业中的极大似然估计（MLE）比较区别。
2. 设一箱产品中的不合格品个数服从泊松分布 $Poisson(\lambda)$ ， λ 有1.5和1.8两个可能取值，且先验分布为 $P(\lambda = 1.5) = 0.45$ ， $P(\lambda = 1.8) = 0.55$ ，现检查了一箱产品，发现有3个不合格品，试计算 λ 的后验分布（提示：该题不需要用到共轭分布的知识）。
3. 在一次抛硬币试验中，抛10次硬币，其中正面朝上的次数是6，反面朝上的次数是4，假设每次试验独立且服从相同的伯努利分布，记参数 θ 为硬币正面朝上的概率；假设 $p(\theta)$ 服从Beta分布 $Beta(\alpha, \alpha)$ ，基于Beta分布为伯努利分布的共轭先验，求 θ 的后验分布 $p(\theta|X)$ 及其参数，并讨论 α 取值对 $p(\theta|X)$ 的影响（为何可以看作伪计数）。
4. 对于第14页上狄利克雷分布后验与正态分布后验（方差已知），思考并分别给出一个应用场景（例如本章例题中的论文投稿场景），并结合实际应用解释先验分布参数、样本、后验分布参数所代表的含义。

☺ 拓展阅读：除了本章介绍的共轭分布对之外，常见的还有Gamma分布是泊松分布的共轭先验、Beta分布是几何分布的共轭先验、Gamma分布是均值已知正态分布的共轭先验等。

The top banner features the Fudan University logo on the left, which includes the university's name in English ('FUDAN UNIVERSITY') and Chinese ('復旦大學') along with the founding year '1905'. To the right of the logo are several interlocking blue gears of different sizes. Some gears contain white icons: a building, a graduation cap, a medical bag with a cross, a person silhouette, and an atomic symbol. The background is a light blue gradient with a dark blue curved shape on the far right.

人工智能的数学基础

06 混合模型的参数估计

李 斌

复旦大学 计算机科学技术学院


混合模型

- 例：假设有三枚硬币，分别记作 A, B, C ，三枚硬币正面出现的概率分别是 π, p, q ，进行如下掷硬币试验：先掷硬币 A ，根据其结果选出硬币 B 或硬币 C （正面选硬币 B ，反面选硬币 C ），然后掷选出的硬币，出现正面记1，出现反面记0；独立重复 $N = 10$ 次，观测结果如下：

$$\{X_1, \dots, X_{10}\} = \{1, 1, 0, 1, 0, 0, 1, 0, 1, 1\}$$

假设只能观测到最终结果，不能观测掷硬币的过程，问如何估计三硬币正面出现的概率，即三硬币模型的参数 π, p, q ？

观测结果 $x_1, \dots, x_{10}$ 并不知道来自 B 还是 C ，假设每个观测 X_i 都对应一个（随机）隐变量^① $Z_i \in \{0, 1\}$ 指示其来自 B 还是 C



^①英文为latent variable。

混合模型

- 回顾第二章中的全概率公式： $f_X(x) = \int_{-\infty}^{\infty} f_{X|Y}(x|y)f_Y(y) dy$ ，若把其中的 Y 改为隐变量 Z ，且为服从类别分布的离散型随机变量，则 $f_X(x)$ 可写成**混合模型**的形式

$$f_X(x) = \sum_{k=1}^K f_{X|Z}(x|z_k)P_Z(Z = z_k)$$

Z 的取值 z_k 决定了 $f_{X|Z}(x|z_k)$ 的参数，
且 $\sum_{k=1}^K P_Z(Z = z_k) = 1$

称为第 k 个成分

1. $f_{X|Z}(x|z_k), k = 1, \dots, K$ 通常为同一种分布形式
2. $P_Z(Z = z_k)$ 表示观测 x 来自第 k 个成分^①的先验概率（成分的权重）
3. 直观理解即为 K 个分布的**加权和**，仍符合分布的两个基本条件

^①英文为Component； K 个成分都为某分布时称为某混合模型，例如人工智能中广泛使用的高斯混合模型。

混合模型


- 例：三硬币模型^①（即伯努利混合模型）

$$\begin{aligned}P(X_i = x_i) &= P_Z(Z_i = 0)P(X_i|Z_i = 0) + P_Z(Z_i = 1)P(X_i|Z_i = 1) \\ &= \pi p^{x_i}(1 - p)^{1-x_i} + (1 - \pi)q^{x_i}(1 - q)^{1-x_i}\end{aligned}$$

- 例：高斯混合模型

其中 $w_k = P_Z(Z = z_k)$, $\sum_{k=1}^K w_k = 1$

$$p(x_i) = w_1 N(x_i; \mu_1, \sigma_1^2) + w_2 N(x_i; \mu_2, \sigma_2^2) + w_3 N(x_i; \mu_3, \sigma_3^2) + w_4 N(x_i; \mu_4, \sigma_4^2)$$




^①三硬币模型中只有两个成分（成分数 $K = 2$ ），此时类别分布就退化为伯努利分布。

混合模型

- 混合模型的参数如何估计——引入隐变量 Z_i 指示 X_i 的隶属成分

若知道每个样本分别隶属于哪个成分（红、绿、蓝分别表示隶属于成分1、2、3），就只需对对应的样本子集估计每个成分参数，例如使用MLE



期望最大化算法

- 当模型中具有隐变量时，无法使用MLE等常规参数估计方法
- 期望最大化算法^①是一种迭代算法，用于含有隐变量时模型参数的极大似然估计，该算法由Dempster等人于1977年提出
- 类似MLE，EM算法最大化 $X = \{X_1, \dots, X_n\}$ 与 $Z = \{Z_1, \dots, Z_n\}$ 的对数似然 $\log P(X, Z; \theta)$ ，但由于 Z 无法观测，在优化时无法作为定值，因此需要对 Z 求期望

$$\begin{aligned}\theta^{(t+1)} &= \operatorname{argmax}_{\theta} E_Z [\ln P(X, Z; \theta)] \\ &= \operatorname{argmax}_{\theta} \left\{ \sum_Z \ln P(X, Z; \theta) P(Z|X; \theta^{(t)}) \right\} \\ &= \operatorname{argmax}_{\theta} Q(\theta, \theta^{(t)})\end{aligned}$$

给定观测 X 与当前参数估计
 $\theta^{(t)}$ 下隐变量 Z 的条件概率

称为 Q 函数

^①英文为Expectation-Maximization algorithm，简称EM算法。

期望最大化算法

- EM算法迭代求解 $\theta^{(t+1)} = \operatorname{argmax}_{\theta} Q(\theta, \theta^{(t)})$ ，每次迭代分为两步，E步求期望，M步求极大，迭代直至收敛

- E步：参数 $\theta^{(t)}$ 看作已知，推断未知 $Z = \{Z_1, \dots, Z_n\}$ 的分布

$$E_Z[\log P(X, Z; \theta)] = \sum_Z \log P(X, Z; \theta) P(Z|X; \theta^{(t)})$$

E步的关键是计算隐变量 Z 的条件概率 $P(Z_i = z_k | X_i; \theta^{(t)})$ ，
可以理解为 X_i 属于第 k 个成分的“隶属度”

- M步： $Z = \{Z_1, \dots, Z_n\}$ 的分布看作已知，估计未知参数 θ


$$\operatorname{argmax}_{\theta} \sum_Z \log P(X, Z; \theta) P(Z|X; \theta^{(t)})$$

在M步中，E步中求得的“隶属度”看作已知，则 $\log P(X, Z; \theta)$ 可以和MLE一样求极值，区别在于需遍历 Z 的所有可能取值

期望最大化算法

■ EM算法的基本思想

- 所有 $X_1, \dots, X_n$ 都参与 K 个成分的参数 $\theta_1, \dots, \theta_K$ 估计
- 每个 X_i 在 K 个成分上的贡献不同
- 用隶属度加权 $X_1, \dots, X_n$ 估计 $\theta_1, \dots, \theta_K$



期望最大化算法

■ 例：三硬币模型 ($\theta = \{\pi, p, q\}$)

$$\begin{aligned}
 \text{E步: } Q(\theta, \theta^{(t)}) &= \sum_Z P(Z|X; \theta^{(t)}) \log P(X, Z; \theta) \\
 &= \sum_{i=1}^n \sum_{z_i} [P(z_i|x_i; \theta^{(t)}) \log P(x_i, z_i; \theta)] \\
 &= \sum_{i=1}^n [P(z_i = 0|x_i; \theta^{(t)}) \log P(x_i, z_i = 0|\theta) + \\
 &\quad P(z_i = 1|x_i; \theta^{(t)}) \log P(x_i, z_i = 1|\theta)]
 \end{aligned}$$

$$\text{其中} \begin{cases} P(x_i, z_i = 0|\theta) = \pi p^{x_i} (1-p)^{1-x_i} & \text{见第4页} \\ P(x_i, z_i = 1|\theta) = (1-\pi) q^{x_i} (1-q)^{1-x_i} \end{cases} \quad \theta^{(t)} = \{\pi^{(t)}, p^{(t)}, q^{(t)}\} \text{已知}$$

$$\text{计算 } \gamma_i^{(t)} = P(z_i = 1|x_i; \theta^{(t)}) = \frac{P(x_i, z_i = 1|\theta^{(t)})}{P(x_i, z_i = 1|\theta^{(t)}) + P(x_i, z_i = 0|\theta^{(t)})}$$

第*i*次观测来自B的可能性（隶属度）

$$Q(\theta, \theta^{(t)}) =$$

$$\sum_{i=1}^n \left\{ \gamma_i^{(t)} \log[\pi p^{x_i} (1-p)^{1-x_i}] + (1 - \gamma_i^{(t)}) \log[(1-\pi) q^{x_i} (1-q)^{1-x_i}] \right\}$$

期望最大化算法

接上页

M步：对 $Q(\theta, \theta^{(t)})$ 分别求 π, p, q 的偏导设为0

$$\begin{aligned}\frac{\partial Q(\theta, \theta^{(t)})}{\partial \pi} &= \sum_{i=1}^n \frac{\partial}{\partial \pi} \left[\gamma_i^{(t)} \log \pi + (1 - \gamma_i^{(t)}) \log(1 - \pi) \right] \\ &= \sum_{i=1}^n \left[\frac{\gamma_i^{(t)}}{\pi} - \frac{1 - \gamma_i^{(t)}}{1 - \pi} \right] = 0 \quad \Rightarrow \quad \pi^{(t+1)} = \frac{\sum_{i=1}^n \gamma_i^{(t)}}{n}\end{aligned}$$

$$\begin{aligned}\frac{\partial Q(\theta, \theta^{(t)})}{\partial p} &= \sum_{i=1}^n \frac{\partial}{\partial p} \left\{ \gamma_i^{(t)} \log[\pi p^{x_i} (1 - p)^{1-x_i}] \right\} \\ &= \sum_{i=1}^n \frac{\partial}{\partial p} \left\{ \gamma_i^{(t)} [\log \pi + x_i \log p + (1 - x_i) \log(1 - p)] \right\} \\ &= \sum_{i=1}^n \gamma_i^{(t)} \left[\frac{x_i}{p} - \frac{(1-x_i)}{1-p} \right] = 0 \quad \Rightarrow \quad p^{(t+1)} = \frac{\sum_{i=1}^n \gamma_i^{(t)} x_i}{\sum_{i=1}^n \gamma_i^{(t)}}\end{aligned}$$

$$\frac{\partial Q(\theta, \theta^{(t)})}{\partial q} = 0 \quad \Rightarrow \quad q^{(t+1)} = \frac{\sum_{i=1}^n (1 - \gamma_i^{(t)}) x_i}{\sum_{i=1}^n (1 - \gamma_i^{(t)})}$$

期望最大化算法

- 选取参数初始值 $\theta^{(0)} = \{\pi^{(0)}, p^{(0)}, q^{(0)}\}$ ，迭代E步和M步直至收敛
- E步：计算在模型参数 $\theta^{(t)}$ 下观测数据 x_i 来自掷硬币 B 的概率

$$\gamma_i^{(t)} = P(z_i = 1 | x_i; \theta^{(t)}) = \frac{\pi^{(t)}(p^{(t)})^{x_i}(1-p^{(t)})^{1-x_i}}{\pi^{(t)}(p^{(t)})^{x_i}(1-p^{(t)})^{1-x_i} + (1-\pi^{(t)})(q^{(t)})^{x_i}(1-q^{(t)})^{1-x_i}}$$

- M步：计算模型参数新的估计值 $\theta^{(t+1)}$

$$\pi^{(t+1)} = \frac{\sum_{i=1}^n \gamma_i^{(t)}}{n}$$

混合模型每个成分的系数可解释为隶属于该成分的样本比例

$$p^{(t+1)} = \frac{\sum_{i=1}^n \gamma_i^{(t)} x_i}{\sum_{i=1}^n \gamma_i^{(t)}}$$

参数估计的结果形式可解释为用隶属度 $\gamma_i^{(t)}$ 加权的MLE

$$q^{(t+1)} = \frac{\sum_{i=1}^n (1-\gamma_i^{(t)}) x_i}{\sum_{i=1}^n (1-\gamma_i^{(t)})}$$

期望最大化算法

■ 例：高斯混合模型 ($\theta = \{w_k, \mu_k, \sigma_k^2\}_{k=1}^K$)

$$\begin{aligned}\text{E步: } Q(\theta, \theta^{(t)}) &= \sum_Z P(Z|X; \theta^{(t)}) \log P(X, Z; \theta) \\ &= \sum_{i=1}^n \sum_{z_i} [P(z_i|x_i; \theta^{(t)}) \log P(x_i, z_i; \theta)] \\ &= \sum_{i=1}^n \sum_{k=1}^K P(z_i = k|x_i; \theta^{(t)}) \log P(x_i, z_i = k|\theta)\end{aligned}$$

见第4页

$$\text{其中 } P(x_i, z_i = k|\theta) = w_k N(x_i; \mu_k, \sigma_k^2) = w_k \frac{1}{\sqrt{2\pi}\sigma_k} \exp\left(\frac{-(x_i - \mu_k)^2}{2\sigma_k^2}\right)$$

$$\text{计算 } \gamma_{i,k}^{(t)} = P(z_i = k|x_i; \theta^{(t)}) = \frac{P(x_i, z_i = k|\theta^{(t)})}{\sum_{k'=1}^K P(x_i, z_i = k'|\theta^{(t)})}$$

$\theta^{(t)} = \{w_k^{(t)}, \mu_k^{(t)}, \sigma_k^{2(t)}\}$ 已知

第*i*次观测来自第*k*个成分的可能性（隶属度）

$$Q(\theta, \theta^{(t)}) = \sum_{i=1}^n \sum_{k=1}^K \gamma_{i,k}^{(t)} \log \left[w_k \frac{1}{\sqrt{2\pi}\sigma_k} \exp\left(\frac{-(x_i - \mu_k)^2}{2\sigma_k^2}\right) \right]$$

期望最大化算法

接上页

M步：对 $Q(\theta, \theta^{(t)})$ 分别求 w_k, μ_k, σ_k^2 的偏导设为0

注意 w_k 需满足 $\sum_{k=1}^K w_k = 1$ ，使用拉格朗日乘子法

$$\begin{aligned}\frac{\partial Q(\theta, \theta^{(t)}) + \lambda(\sum_{k=1}^K w_k - 1)}{\partial w_k} &= \sum_{i=1}^n \gamma_{i,k}^{(t)} \frac{\partial}{\partial w_k} \log w_k + \frac{\partial}{\partial w_k} \lambda w_k \\ &= \sum_{i=1}^n \frac{\gamma_{i,k}^{(t)}}{w_k} + \lambda = 0 \Rightarrow \sum_{i=1}^n \gamma_{i,k}^{(t)} + \lambda w_k = 0\end{aligned}$$

等式两边同时在 k 上累加可得

$$\sum_{i=1}^n \sum_{k=1}^K \gamma_{i,k}^{(t)} + \lambda \sum_{k=1}^K w_k = 0 \Rightarrow \lambda = -n$$

把 $\lambda = -n$ 回代入 $\sum_{i=1}^n \gamma_{i,k}^{(t)} + \lambda w_k = 0$ 可得 $w_k^{(t+1)} = \frac{\sum_{i=1}^n \gamma_{i,k}^{(t)}}{n}$

期望最大化算法

接上页

M步：对 $Q(\theta, \theta^{(t)})$ 分别求 w_k, μ_k, σ_k^2 的偏导设为0

$$\begin{aligned}\frac{\partial Q(\theta, \theta^{(t)})}{\partial \mu_k} &= \sum_{i=1}^n \gamma_{i,k}^{(t)} \frac{\partial}{\partial \mu_k} \log \left[\exp \left(\frac{-(x_i - \mu_k)^2}{2\sigma_k^2} \right) \right] = - \sum_{i=1}^n \frac{\gamma_{i,k}^{(t)}}{2\sigma_k^2} \frac{\partial}{\partial \mu_k} (x_i - \mu_k)^2 \\ &= \sum_{i=1}^n \frac{\gamma_{i,k}^{(t)}}{2\sigma_k^2} (2\mu_k - 2x_i) = \frac{1}{\sigma_k^2} \left(\sum_{i=1}^n \gamma_{i,k}^{(t)} \mu_k - \sum_{i=1}^n \gamma_{i,k}^{(t)} x_i \right) = 0 \\ \Rightarrow \mu_k^{(t+1)} &= \frac{\sum_{i=1}^n \gamma_{i,k}^{(t)} x_i}{\sum_{i=1}^n \gamma_{i,k}^{(t)}}\end{aligned}$$

$$\frac{\partial Q(\theta, \theta^{(t)})}{\partial \sigma_k^2} = 0 \Rightarrow \sigma_k^{2(t+1)} = \frac{\sum_{i=1}^n \gamma_{i,k}^{(t)} (x_i - \mu_k)^2}{\sum_{i=1}^n \gamma_{i,k}^{(t)}}$$

期望最大化算法

■ 选取参数初始值 $\theta^{(0)} = \{w_k^{(0)}, \mu_k^{(0)}, \sigma_k^{2(0)}\}_{k=1}^K$ ，迭代E步和M步直至收敛

■ E步：计算在模型参数 $\theta^{(t)}$ 下观测数据 x_i 来自第 k 个成分的概率

$$\gamma_{i,k}^{(t)} = P(z_i = k | x_i; \theta^{(t)}) = \frac{P(x_i, z_i = k | \theta^{(t)})}{\sum_{k'=1}^K P(x_i, z_i = k' | \theta^{(t)})}$$

■ M步：计算模型参数新的估计值 $\theta^{(t+1)}$

$$w_k^{(t+1)} = \frac{\sum_{i=1}^n \gamma_{i,k}^{(t)}}{n}$$

混合模型每个成分的系数可解释为隶属于该成分的样本比例


$$\mu_k^{(t+1)} = \frac{\sum_{i=1}^n \gamma_{i,k}^{(t)} x_i}{\sum_{i=1}^n \gamma_{i,k}^{(t)}}$$

参数估计的结果形式可解释为用隶属度 $\gamma_i^{(t)}$ 加权的MLE

$$\sigma_k^{2(t+1)} = \frac{\sum_{i=1}^n \gamma_{i,k}^{(t)} (x_i - \mu_k)^2}{\sum_{i=1}^n \gamma_{i,k}^{(t)}}$$

期望最大化算法

■ 高斯混合模型参数估计过程中的EM算法迭代



本章课后作业

1. 把三硬币模型中 $q^{(t+1)}$ 与高斯混合模型中 $\sigma_k^{2(t+1)}$ 的求解过程补充完整。
2. 假设有三枚硬币，记作 A, B, C ，掷硬币正面朝上的概率分别是 p_A, p_B, p_C ，进行如下掷硬币实验：先从一个盒子中随机摸出一个标有 A 或 B 或 C 的小球（下一次摸球之前放回），根据小球上的标记选择硬币；掷出选择的硬币，正面记作1，反面记作0；独立重复 n 次实验，观测数据记为 $X = \{X_1, \dots, X_n\}$ ，用EM算法求解该问题：1）该问题中隐变量 $Z_1, \dots, Z_n$ 是什么，模型参数集 θ 中包含哪些参数？2）在E步中，基于模型参数 $\theta^{(t)}$ ，写出观测数据 X_i 来自第 k 个硬币的条件概率；3）在M步中，写出估计值 $\theta^{(t+1)}$ 中所有参数的求解过程。
3. 一个身高样本 $X_1, \dots, X_n$ 采集自2岁、10岁、18岁三个年龄组，采集时没有标记分别来自哪个年龄组，请设计一个方案推断出 $X_1, \dots, X_n$ 最有可能来自哪个组。

☺ 拓展阅读：混合模型常被用于解决聚类问题，隐变量 Z_i 可解释为 X_i 属于哪个簇的指示变量，而 $Z_i = k$ 的概率则可解释为 X_i 属于第 k 个簇的隶属度。

The top banner features the Fudan University logo on the left, which includes the university's name in English ('FUDAN UNIVERSITY') and Chinese ('復旦大學') along with the founding year '1905'. To the right of the logo are several interlocking blue gears. Some of these gears contain white icons: a building, a graduation cap, a medical cross, a person silhouette, and an atomic symbol. The background of the banner is light blue with a dark blue curved shape on the far right.

人工智能的数学基础

07 最优化问题

李 斌

复旦大学 计算机科学技术学院

最优化问题

- 人工智能领域广泛应用的极大似然估计（MLE）及其变种，包括最大后验概率（MAP）与期望最大（EM）算法，最终均归结为优化问题，即最大化待估参数的函数

$$\text{MLE: } \max_{\theta} L(\{x_i\}_{i=1}^n; \theta)$$

$$\text{MAP: } \max_{\theta} p(\theta) L(\{x_i\}_{i=1}^n; \theta)$$

$$\text{EM算法: } \max_{\theta} \{\sum_Z \ln P(X, Z; \theta) P(Z|X; \theta^{(t)})\}$$

- 例：

$$\text{一元线性回归: } \min_{w,b} \sum_{i=1}^n (y_i - (wx_i + b))^2$$

$$\text{对数几率回归: } \min_{w,b} \sum_{i=1}^n [-y_i(wx_i + b) + \log(1 + e^{wx_i + b})]$$

第4章27页 $\min_{w,b} (-\log L)$ 化简后可得


最优化问题

- 最优化问题一般可以描述为

$$\underset{\mathbf{x}}{\text{minimize}} f(\mathbf{x})$$

$$\text{subject to } \mathbf{x} \in \mathcal{C}$$


通常minimize简写为min,
subject to简写为s. t.



- $\mathbf{x} = [x_1, x_2, \dots, x_D]^T \in \mathbb{R}^D$ 是**决策变量**
- $f: \mathbb{R}^D \rightarrow \mathbb{R}$ 是**目标函数**
- $\mathcal{C} \subseteq \mathbb{R}^D$ 是**可行域**, 可行域包含的点称为可行解
- 当 $\mathcal{C} = \mathbb{R}^D$ 称为无约束优化问题

最优化问题

- 给定函数 $f: C \rightarrow \mathbb{R}$, 其中 $C \subseteq \mathbb{R}^D$, 若对所有 $\mathbf{x} \in C$ 有 $f(\mathbf{x}^*) \leq f(\mathbf{x})$, 则 f 在 $\mathbf{x}^* \in C$ 有全局最小值; 若存在 $\epsilon > 0$ 对所有 $\mathbf{x} \in C \cap B_\epsilon(\mathbf{x}^*)$ ^① 有 $f(\mathbf{x}^*) \leq f(\mathbf{x})$, 则 f 在 $\mathbf{x}^* \in C$ 有局部最小值, 无等号时为严格局部最小值



- 机器学习中的最优化问题通常描述为带约束的优化问题, 其中 $f(\mathbf{x})$ 、 $g_i(\mathbf{x})$ 、 $h_j(\mathbf{x})$ 是定义在 $\mathbb{R}^D$ 上的函数

$$\begin{aligned} & \min_{\mathbf{x}} f(\mathbf{x}) \quad \text{目标函数通常连续可微} \\ & \text{s. t. } g_i(\mathbf{x}) \leq 0, \quad i = 1, 2, \dots, k \\ & \quad \quad h_j(\mathbf{x}) = 0, \quad j = 1, 2, \dots, l \end{aligned} \quad \begin{array}{l} \text{可行域由不等式} \\ \text{与等式约束定义} \end{array}$$

^① $B_\epsilon(\mathbf{x}^*)$ 以 $\mathbf{x}^*$ 为中心 ϵ 为半径的球。

最优化问题

- 泰勒展开对于分析最优化问题与算法非常重要，目标函数的局部性质可使用线性函数与二次函数之和进行近似




$$f(x) = f(a) + f'(a)(x - a) + \frac{f''(a)}{2!}(x - a)^2 + o(|x - a|^2)$$

$$f(\mathbf{x}) = f(\mathbf{a}) + (\mathbf{x} - \mathbf{a})^\top \nabla f(\mathbf{a}) + \frac{1}{2}(\mathbf{x} - \mathbf{a})^\top \nabla^2 f(\mathbf{a})(\mathbf{x} - \mathbf{a}) + o(\|\mathbf{x} - \mathbf{a}\|^2)$$

函数值在 $\mathbf{a}$
点与 f 匹配

斜率在 $\mathbf{a}$ 点
与 f 匹配

曲率在 $\mathbf{a}$ 点
与 f 匹配



最优化问题

- 局部最优解的一阶条件（**必要条件**）：可微函数 f 在局部最优点 $\mathbf{x}^* \in C$ 的梯度为 $\mathbf{0}$ ，即 $\nabla f(\mathbf{x}^*) = [0, \dots, 0]^\top$ ；反之不一定成立


必要性：任取 $\mathbf{v} \in \mathbb{R}^D$ ，考虑 f 在 $\mathbf{x}^*$ 处的泰勒展开（ $\theta > 0$ ）

$$\begin{aligned} f(\mathbf{x}^* + \theta \mathbf{v}) &= f(\mathbf{x}^*) + \theta \mathbf{v}^\top \nabla f(\mathbf{x}^*) + o(\theta) \\ \Rightarrow \frac{f(\mathbf{x}^* + \theta \mathbf{v}) - f(\mathbf{x}^*)}{\theta} &= \mathbf{v}^\top \nabla f(\mathbf{x}^*) + o(1) \end{aligned}$$

在上式中分别对 θ 取点0处的左、右极限，根据 $\mathbf{x}^*$ 的最优性可知

$$\begin{aligned} \lim_{\theta \rightarrow 0^+} \frac{f(\mathbf{x}^* + \theta \mathbf{v}) - f(\mathbf{x}^*)}{\theta} &= \mathbf{v}^\top \nabla f(\mathbf{x}^*) \geq 0 \\ \lim_{\theta \rightarrow 0^-} \frac{f(\mathbf{x}^* + \theta \mathbf{v}) - f(\mathbf{x}^*)}{\theta} &= \mathbf{v}^\top \nabla f(\mathbf{x}^*) \leq 0 \end{aligned}$$

即 $\mathbf{v}^\top \nabla f(\mathbf{x}^*) = 0$ ，由 $\mathbf{v}$ 的任意性知 $\nabla f(\mathbf{x}^*) = \mathbf{0}$



最优化问题

- 局部最优解的二阶条件（充分条件）：二阶可微函数 f 在驻点 $\mathbf{x}^* \in C$ 的海森矩阵^①为正定 $\mathbf{H}(\mathbf{x}^*) > 0$ （或负定 $\mathbf{H}(\mathbf{x}^*) < 0$ ）

$$\mathbf{H}(\mathbf{x}) = \nabla^2 f(\mathbf{x}) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1 \partial x_1}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_D}(\mathbf{x}) \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_D \partial x_1}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial x_D \partial x_D}(\mathbf{x}) \end{bmatrix}$$

在 $\mathbf{x}^*$ 附近考虑泰勒展开 $f(\mathbf{x}^* + \mathbf{v}) = f(\mathbf{x}^*) + \mathbf{v}^\top \nabla f(\mathbf{x}^*) + \frac{1}{2} \mathbf{v}^\top \nabla^2 f(\mathbf{x}^*) \mathbf{v} + o(\|\mathbf{v}\|^2)$

当一阶必要条件 $\nabla f(\mathbf{x}^*) = 0$ 满足时， $f(\mathbf{x}^* + \mathbf{v}) = f(\mathbf{x}^*) + \frac{1}{2} \mathbf{v}^\top \nabla^2 f(\mathbf{x}^*) \mathbf{v} + o(\|\mathbf{v}\|^2)$

充分性：由 f 在驻点 $\mathbf{x}^*$ 时（ $\nabla f(\mathbf{x}^*) = 0$ ）的二阶展开可得

$$\frac{f(\mathbf{x}^* + \mathbf{v}) - f(\mathbf{x}^*)}{\|\mathbf{v}\|^2} = \frac{\frac{1}{2} \mathbf{v}^\top \nabla^2 f(\mathbf{x}^*) \mathbf{v} + o(\|\mathbf{v}\|^2)}{\|\mathbf{v}\|^2} \geq \frac{1}{2} \lambda_{\min} + o(1)$$

当 $\|\mathbf{v}\|$ 充分小时有 $f(\mathbf{x}^* + \mathbf{v}) \geq f(\mathbf{x}^*)$ 由 $\mathbf{H}(\mathbf{x}^*) > 0$ 可知 $\frac{\mathbf{v}^\top}{\|\mathbf{v}\|} \mathbf{H}(\mathbf{x}^*) \frac{\mathbf{v}}{\|\mathbf{v}\|} \geq \lambda_{\min} > 0$

^① 英文为Hessian Matrix。

最优化问题

- 最优化问题可以按照目标函数和约束函数的形式、解的性质进行分类
 - 线性规划：目标函数和约束函数均为线性函数
 - 非线性规划：目标函数和约束函数中至少有一个为非线性函数
 - 二次规划：目标函数是二次函数而约束函数是线性函数
 - 半定规划：在线性约束下极小化关于半正定矩阵的线性函数
 - 整数规划：变量只能取整数的问题
 - 非光滑优化：包含非光滑函数的问题
 - 无导数优化：不能直接求导数的问题
 - 稀疏优化：最优解只有少量非零元素的问题
 - 低秩矩阵优化：最优解是低秩矩阵的问题
 -

最优化问题

- 例：投资组合优化中，已知股票回报率为随机变量 r_i ，投资于股票的金额比例为 x_i （ $\sum_i x_i = 1$ ），回报为 $r = \sum_i r_i x_i$ ，现要在期望回报不低于 r_0 的条件下最小化收益风险（方差）

期望回报： $E(\sum_i r_i x_i) = \sum_i E(r_i) x_i = \sum_i \mu_i x_i = \boldsymbol{\mu}^\top \mathbf{x}$

收益风险： $Var(\sum_i r_i x_i) = \sum_{i=1}^n x_i^2 Var(r_i) + 2 \sum_{1 \leq i < j \leq n} x_i x_j Cov(r_i, r_j) = \mathbf{x}^\top \boldsymbol{\Sigma} \mathbf{x}$



$$\begin{aligned} \min_{\mathbf{x}} \quad & \frac{1}{2} \mathbf{x}^\top \boldsymbol{\Sigma} \mathbf{x} \quad \text{二次规划问题} \\ \text{s. t.} \quad & \boldsymbol{\mu}^\top \mathbf{x} \geq r_0 \\ & \sum_i x_i = 1 \\ & x_i \geq 0 \end{aligned}$$

凸集

- 定义：若一个集合 $C \subseteq \mathbb{R}^D$ 中任意两点的连线完全在 C 中，则 C 为凸集，即对于任意 $\mathbf{x}_1, \mathbf{x}_2 \in C$ 和任意 $0 \leq \theta \leq 1$ ，有

$$\theta \mathbf{x}_1 + (1 - \theta) \mathbf{x}_2 \in C$$

- 任意多凸集的交集仍是凸集
- 凸集在仿射变换^①后的像仍是凸集



*Figure 2.2 from S. Boyd, L. Vandenberghe

^①仿射函数是最高次数为1的多项式函数，即 $f(\mathbf{x}) = \mathbf{Ax} + b$ 。



凸集

- 满足如下形式的点称为 $\mathbf{x}_1, \dots, \mathbf{x}_n$ 的凸组合

$$\mathbf{x} = \theta_1 \mathbf{x}_1 + \theta_2 \mathbf{x}_2 + \dots + \theta_n \mathbf{x}_n$$

$$\theta_1 + \dots + \theta_n = 1, \theta_1, \dots, \theta_n \geq 0$$




- 集合 S 的所有点的凸组合构成的点集为 S 的凸包^①
- S 的凸包是包含 S 的最小凸集



^①英文为Convex Hull。

凸集

- 例：超平面 $\{\mathbf{x} | \mathbf{a}^T \mathbf{x} = b\}$
- 例：半空间 $\{\mathbf{x} | \mathbf{a}^T \mathbf{x} \leq b\}$
- 例：多面体 $\{\mathbf{x} | \mathbf{A}\mathbf{x} \leq \mathbf{b}, \mathbf{C}\mathbf{x} = \mathbf{d}\}$ 多面体是有限个半空间和超平面的交，由凸集的性质可知其为凸集
- 例：范数球 $\{\mathbf{x} | \|\mathbf{x} - \mathbf{x}_c\| \leq r\} = \{\mathbf{x}_c + r\mathbf{u} | \|\mathbf{u}\| \leq 1\}$
- 例：范数锥 $\{(\mathbf{x}, t) | \|\mathbf{x}\| \leq t\}$




凸函数

- 定义：函数 $f: \mathbb{R}^D \rightarrow \mathbb{R}$ 是凸的，如果 f 的定义域 C 是凸集，且对于任意 $\mathbf{x}, \mathbf{y} \in C$ 和任意 $0 \leq \theta \leq 1$ ，有

$$f(\theta \mathbf{x} + (1 - \theta) \mathbf{y}) \leq \theta f(\mathbf{x}) + (1 - \theta) f(\mathbf{y})$$

- 如果上述不等式当 $\mathbf{x} \neq \mathbf{y}$ 以及 $0 < \theta < 1$ 时严格成立，则称 f 是严格凸的
- 若 f 为凸函数， $-f$ 为凹函数



凸函数

■ 一个函数 $f(\mathbf{x})$ 是凸函数当且仅当其上方图 $\text{epi}(f)$ 是凸集

必要性：若 $f(\mathbf{x})$ 是凸函数，则对任意 $(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2) \in \text{epi}(f)$, $0 \leq \theta \leq 1$

$$\theta y_1 + (1 - \theta)y_2 \geq \theta f(\mathbf{x}_1) + (1 - \theta)f(\mathbf{x}_2) \geq f(\theta \mathbf{x}_1 + (1 - \theta)\mathbf{x}_2)$$

上方图


凸函数

故 $(\theta \mathbf{x}_1 + (1 - \theta)\mathbf{x}_2, \theta y_1 + (1 - \theta)y_2) \in \text{epi}(f)$, $0 \leq \theta \leq 1$

充分性：若 $\text{epi}(f)$ 是凸集，则对任意 $\mathbf{x}_1, \mathbf{x}_2 \in \text{dom}(f)$, $0 \leq \theta \leq 1$

$$(\theta \mathbf{x}_1 + (1 - \theta)\mathbf{x}_2, \theta f(\mathbf{x}_1) + (1 - \theta)f(\mathbf{x}_2)) \in \text{epi}(f)$$

$$\begin{aligned} \Rightarrow f(\theta \mathbf{x}_1 + (1 - \theta)\mathbf{x}_2) \\ \leq \theta f(\mathbf{x}_1) + (1 - \theta)f(\mathbf{x}_2) \end{aligned}$$




凸函数

- 根据**一阶导数**判断函数凸性：设 $f(\mathbf{x})$ 是定义在凸集 $C \subseteq \mathbb{R}^D$ 上且具有连续一阶导数的函数，则 $f(\mathbf{x})$ 在 C 上为凸函数的充要条件是对 C 内任意不同两点 $\mathbf{x}$ 与 $\mathbf{y}$ ，以下不等式恒成立

$$f(\mathbf{y}) \geq f(\mathbf{x}) + (\mathbf{y} - \mathbf{x})^\top \nabla f(\mathbf{x})$$

>时 f 严格凸



必要性：若 f 是凸函数，则对任意 $\mathbf{x}, \mathbf{y} \in \text{dom}(f)$ ， $0 \leq \theta \leq 1$ ，有

$$\theta f(\mathbf{y}) + (1 - \theta)f(\mathbf{x}) \geq f(\mathbf{x} + \theta(\mathbf{y} - \mathbf{x})) \Rightarrow f(\mathbf{y}) - f(\mathbf{x}) \geq \frac{f(\mathbf{x} + \theta(\mathbf{y} - \mathbf{x})) - f(\mathbf{x})}{\theta}$$

当 $\theta \rightarrow 0$ 时由方向导数的性质可得 $(\mathbf{y} - \mathbf{x})^\top \nabla f(\mathbf{x})$

充分性：对任意 $\mathbf{x}, \mathbf{y} \in \text{dom}(f)$ ， $0 \leq \theta \leq 1$ ，定义 $\mathbf{z} = \theta\mathbf{x} + (1 - \theta)\mathbf{y}$ ，应用两次一阶条件

$$\begin{aligned} f(\mathbf{x}) &\geq f(\mathbf{z}) + (\mathbf{x} - \mathbf{z})^\top \nabla f(\mathbf{z}) \\ f(\mathbf{y}) &\geq f(\mathbf{z}) + (\mathbf{y} - \mathbf{z})^\top \nabla f(\mathbf{z}) \end{aligned} \quad \Rightarrow \quad \theta f(\mathbf{x}) + (1 - \theta)f(\mathbf{y}) \geq f(\mathbf{z})$$

上式乘 θ + 下式乘 $(1 - \theta)$


凸函数

- 根据**二阶导数**判断函数凸性：设 $f(\mathbf{x})$ 是定义在凸集 $C \subseteq \mathbb{R}^D$ 上且具有连续二阶导数的函数，则 $f(\mathbf{x})$ 在 C 上为凸函数的充要条件是海森矩阵在 C 上处处半正定


$$\nabla^2 f(\mathbf{x}) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1 \partial x_1}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_D}(\mathbf{x}) \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_D \partial x_1}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial x_D \partial x_D}(\mathbf{x}) \end{bmatrix} \succcurlyeq 0$$

即海森矩阵所有特征值 ≥ 0 ；若 $\nabla^2 f(\mathbf{x}) \succ 0$ 则 f 是严格凸函数


必要性与充分性可基于 f 的二阶泰勒展开通过凸函数的一阶条件、海森矩阵的半正定条件、余项三者的关系证明（略）



正定



不定




半正定

凸函数

- 例： $f(x) = |x|$ 为凸函数
- 例： $f(x) = \log(x)$ 为凹函数
- 例： $f(x) = \exp(-x^2)$ 既不是凸函数也不是凹函数，但取对数后凹

回顾正态分布概率密度函数的形式，进行MLE时取负对数似然即可得凸函数



凸函数


■ 例：基于海森矩阵判断 $f(\mathbf{x}) = x_1^2 + x_2^2 - 2x_1x_2$ 是否是凸函数

计算梯度与海森矩阵

$$\nabla f(\mathbf{x}) = \begin{bmatrix} 2x_1 - 2x_2 \\ 2x_2 - 2x_1 \end{bmatrix} \quad \nabla^2 f(\mathbf{x}) = \begin{bmatrix} 2 & -2 \\ -2 & 2 \end{bmatrix}$$

对任意 $\mathbf{v} \neq \mathbf{0}$

$$\begin{aligned} \mathbf{v}^\top \begin{bmatrix} 2 & -2 \\ -2 & 2 \end{bmatrix} \mathbf{v} &= \mathbf{v}^\top \begin{bmatrix} 2v_1 - 2v_2 \\ -2v_1 + 2v_2 \end{bmatrix} \\ &= 2v_1^2 - 2v_1v_2 - 2v_1v_2 + 2v_2^2 \\ &= 2(v_1^2 - 2v_1v_2 + v_2^2) \\ &= 2(v_1 - v_2)^2 \geq 0 \end{aligned}$$



凸函数

- 例：假设 f 为凸函数， $\mathbf{x}_1, \dots, \mathbf{x}_n \in \text{dom}(f)$ ， $\lambda_1, \dots, \lambda_n \geq 0$ 且 $\sum_{i=1}^n \lambda_i = 1$ ，证明Jensen不等式

$$f(\sum_{i=1}^n \lambda_i \mathbf{x}_i) \leq \sum_{i=1}^n \lambda_i f(\mathbf{x}_i) \quad \begin{array}{l} \text{当 } n=2 \text{ 时满足凸函数的定义:} \\ f(\theta \mathbf{x} + (1-\theta)\mathbf{y}) \leq \theta f(\mathbf{x}) + (1-\theta)f(\mathbf{y}) \end{array}$$

由于 $\lambda_1, \dots, \lambda_n \geq 0$ 且 $\sum_{i=1}^n \lambda_i = 1$ ，可以把 $\mathbf{x}$ 看作有 n 个取值的离散型随机变量，因此相当于证 $f(E[\mathbf{x}]) \leq E[f(\mathbf{x})]$ 对于连续性随机变量同样成立

由 f 为凸函数可知 $f(\mathbf{x}) \geq f(\mathbf{x}_0) + (\mathbf{x} - \mathbf{x}_0)^\top \nabla f(\mathbf{x}_0)$ ，令 $\mathbf{x}_0 = E[\mathbf{x}]$ 可得


$$f(\mathbf{x}) \geq f(E[\mathbf{x}]) + (\mathbf{x} - E[\mathbf{x}])^\top \nabla f(\mathbf{x}_0)$$

不等式两边求期望

$$\begin{aligned} E[f(\mathbf{x})] &\geq E[f(E[\mathbf{x}]) + (\mathbf{x} - E[\mathbf{x}])^\top \nabla f(\mathbf{x}_0)] \\ &= f(E[\mathbf{x}]) + [(E[\mathbf{x}] - E[\mathbf{x}])^\top \nabla f(\mathbf{x}_0)] \\ &= f(E[\mathbf{x}]) \end{aligned}$$

凸函数

- 凸函数的非负加权和仍为凸函数，即有凸函数 $f_1, \dots, f_n$ ，权重 $w_1, \dots, w_n \geq 0$ ，则 $w_1 f_1 + \dots + w_n f_n$ 仍为凸函数
- 凸函数 g 与仿射函数 f 复合后 $h = g \circ f$ 为凸函数
$$h(\theta \mathbf{x} + (1 - \theta)\mathbf{y}) = g(f(\theta \mathbf{x} + (1 - \theta)\mathbf{y})) = g(\theta f(\mathbf{x}) + (1 - \theta)f(\mathbf{y})) \\ \leq \theta g(f(\mathbf{x})) + (1 - \theta)g(f(\mathbf{y})) = \theta h(\mathbf{x}) + (1 - \theta)h(\mathbf{y})$$
- 凸函数 $f_1, \dots, f_n$ 逐点取大 $g(\mathbf{x}) = \max\{f_1(\mathbf{x}), \dots, f_n(\mathbf{x})\}$ 仍为凸函数




凸优化问题

- “优化问题的分水岭不是线性和非线性，而是凸和非凸”——《凸优化》作者Stephen Boyd
- 凸优化问题是目标函数 $f(\mathbf{x})$ 和约束函数 $g_i(\mathbf{x})$ 为**凸函数**，约束函数 $h_j(\mathbf{x})$ 为仿射函数的带约束最优化问题
- 对于凸优化问题，任何局部最小值都是**全局最小值**，

假设存在 $\mathbf{y} \in \text{dom}(f)$ 满足 $f(\mathbf{y}) < f(\mathbf{x}^*)$ ，令 $\mathbf{z} = \theta\mathbf{x}^* + (1 - \theta)\mathbf{y}$ ， $0 \leq \theta \leq 1$ ，选择 θ 足够接近1使 $\|\mathbf{z} - \mathbf{x}^*\| \leq \epsilon$ ，由于 f 为凸函数可得 $f(\mathbf{z}) < f(\mathbf{x}^*)$ ，与 $f(\mathbf{x}^*)$ 为局部最小值矛盾

- 严格凸函数最多只有一个最小值

可以无最优解，
例如指数函数



凸优化问题

- 例：假设 f 为凸函数，证明 $\mathbf{x}^* \in \text{dom}(f)$ 是最优解的充要条件是对任意 $\mathbf{x} \in \text{dom}(f)$ 满足 $\nabla f(\mathbf{x}^*)^\top (\mathbf{x} - \mathbf{x}^*) \geq 0$

充分性：由 f 是凸函数可知 $f(\mathbf{x}) \geq f(\mathbf{x}^*) + \nabla f(\mathbf{x}^*)^\top (\mathbf{x} - \mathbf{x}^*)$

由条件 $\nabla f(\mathbf{x}^*)^\top (\mathbf{x} - \mathbf{x}^*) \geq 0$ 可得 $f(\mathbf{x}^*) + \nabla f(\mathbf{x}^*)^\top (\mathbf{x} - \mathbf{x}^*) \geq f(\mathbf{x}^*)$

对任意 $\mathbf{x} \in \text{dom}(f)$ ， $f(\mathbf{x}) \geq f(\mathbf{x}^*)$

必要性：使用反证法，假设 $\exists \mathbf{x}' \in \text{dom}(f)$ 使得 $\nabla f(\mathbf{x}^*)^\top (\mathbf{x}' - \mathbf{x}^*) < 0$

对 f 在 $\mathbf{x}^*$ 附近泰勒展开， $0 < \theta < 1$

$$f(\mathbf{x}^* + \theta(\mathbf{x}' - \mathbf{x}^*)) = f(\mathbf{x}^*) + \theta \nabla f(\mathbf{x}^*)^\top (\mathbf{x}' - \mathbf{x}^*) + o(\theta \|\mathbf{x}' - \mathbf{x}^*\|)$$

$$\frac{f(\mathbf{x}^* + \theta(\mathbf{x}' - \mathbf{x}^*)) - f(\mathbf{x}^*)}{\theta} = \nabla f(\mathbf{x}^*)^\top (\mathbf{x}' - \mathbf{x}^*) + \frac{o(\theta \|\mathbf{x}' - \mathbf{x}^*\|)}{\theta}$$

当 $\theta \rightarrow 0$ 时上式右边小于0，与 $\mathbf{x}^*$ 为最优解矛盾

凸优化问题

■ 例：对数几率回归为凸优化问题

$$\min_{w,b} \sum_{i=1}^n [-y_i(wx_i + b) + \log(1 + e^{wx_i+b})]$$

令 $f_i(w, b) = -y_i(wx_i + b) + \log(1 + e^{wx_i+b})$ ，计算梯度与海森矩阵

$$\nabla f_i(w, b) = \begin{bmatrix} -y_i x_i + \frac{x_i e^{wx_i+b}}{1+e^{wx_i+b}} \\ -y_i + \frac{e^{wx_i+b}}{1+e^{wx_i+b}} \end{bmatrix} \quad \nabla^2 f_i(w, b) = \begin{bmatrix} \frac{x_i^2 e^{wx_i+b}}{(1+e^{wx_i+b})^2} & \frac{x_i e^{wx_i+b}}{(1+e^{wx_i+b})^2} \\ \frac{x_i e^{wx_i+b}}{(1+e^{wx_i+b})^2} & \frac{1 e^{wx_i+b}}{(1+e^{wx_i+b})^2} \end{bmatrix}$$

对任意 $\mathbf{v} \neq \mathbf{0}$,

$$\mathbf{v}^\top \begin{bmatrix} x_i^2 & x_i \\ x_i & 1 \end{bmatrix} \mathbf{v} = \mathbf{v}^\top \begin{bmatrix} x_i^2 v_1 + x_i v_2 \\ x_i v_1 + v_2 \end{bmatrix} = x_i^2 v_1^2 + 2x_i v_1 v_2 + v_2^2 = (x_i v_1 + v_2)^2 \geq 0$$

由于 $\frac{e^{wx_i+b}}{(1+e^{wx_i+b})^2} > 0$ ，因此 $\nabla^2 f_i(w, b) \succcurlyeq 0$ ；由凸函数性质可知 $\sum_{i=1}^n f_i(w, b)$ 为凸

二次规划问题




- 二次函数^①是机器学习中较为常见的目标函数（ $\mathbf{A} \in \mathbb{R}^{D \times D}$ 为满秩矩阵， $\mathbf{b} \in \mathbb{R}^D$ ， $c \in \mathbb{R}$ ）

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x} + \mathbf{b}^\top \mathbf{x} + c$$


假设 $\mathbf{A}$ 为对称矩阵，若不是可用 $\tilde{\mathbf{A}} = \frac{1}{2}(\mathbf{A} + \mathbf{A}^\top)$ 替代， $\mathbf{x}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top \tilde{\mathbf{A}} \mathbf{x}$

梯度为 $\nabla f(\mathbf{x}) = 2\mathbf{A}\mathbf{x} + \mathbf{b} \in \mathbb{R}^D$ ，海森矩阵为 $\nabla^2 f(\mathbf{x}) = 2\mathbf{A} \in \mathbb{R}^{D \times D}$

由于 $\mathbf{A}$ 满秩，因此存在唯一驻点 $\mathbf{x}^*$ 使 $\nabla f(\mathbf{x}^*) = 2\mathbf{A}\mathbf{x}^* + \mathbf{b} = \mathbf{0} \Rightarrow \mathbf{x}^* = -\frac{1}{2}\mathbf{A}^{-1}\mathbf{b}$



$\mathbf{A}$ 满秩有正
负特征值



$\mathbf{A}$ 非满秩

^①英文为Quadratic Function。

二次规划问题

- 例：线性回归模型为凸二次规划问题

$$\min_{w,b} \sum_{i=1}^n (y_i - (wx_i + b))^2$$

基于MLE推导而得的目标函数

令 $\mathbf{w} = \begin{bmatrix} w \\ b \end{bmatrix}$, $\mathbf{x}_i = \begin{bmatrix} x_i \\ 1 \end{bmatrix}$, $\mathbf{y} = [y_1, \dots, y_n]^\top$, $\mathbf{X} = [\mathbf{x}_1, \dots, \mathbf{x}_n]^\top$, 原目标函数可写为 $\sum_{i=1}^n (y_i - \mathbf{w}^\top \mathbf{x}_i)^2 = \|\mathbf{y} - \mathbf{X}\mathbf{w}\|^2 = (\mathbf{y} - \mathbf{X}\mathbf{w})^\top (\mathbf{y} - \mathbf{X}\mathbf{w})$, 整理可得

$$\min_{\mathbf{w}} \mathbf{w}^\top \mathbf{X}^\top \mathbf{X} \mathbf{w} - 2\mathbf{w}^\top \mathbf{X}^\top \mathbf{y} + \mathbf{y}^\top \mathbf{y}$$

上式为二次规划问题, 假设 $\mathbf{X}^\top \mathbf{X} \succ 0$, 则令其梯度为 $\mathbf{0}$ 即可求出最优解

$$\nabla f(\mathbf{w}) = 2\mathbf{X}^\top \mathbf{X} \mathbf{w} - 2\mathbf{X}^\top \mathbf{y} = \mathbf{0}$$

$$\Rightarrow \mathbf{w} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

实际应用中 $\mathbf{X}^\top \mathbf{X} \succ 0$ 不一定成立, 可通过MAP推导而得的目标函数 ($\mathbf{X}^\top \mathbf{X}$ 会有何不同?) 进行求解

本章课后作业

1. 考虑函数 $f(x) = 2x_1^2 + x_2^2 - 2x_1x_2 + 2x_1^3 + x_1^4$ ，求出其所有驻点，并判断它们是否为局部最优点（极小或极大）、鞍点或全局最优点。
2. 使用凸函数的定义证明 $f(x) = |x|$ 为凸函数。
3. 使用凸函数二阶条件证明：1. quadratic-over-linear 函数 $f(x, y) = \frac{x^2}{y}$ 是 $\{(x, y) | y > 0\}$ 上的凸函数；2. ln-sum-exp 函数 $f(x_1, \dots, x_n) = \ln \sum_{i=1}^n \exp x_i$ 是凸函数。
4. 如果正值函数 f 满足 $\log f$ 是凸函数，则 f 称为对数凸函数，证明多元正态分布概率密度函数 $f(\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^D |\Sigma|}} \exp \left[-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right]$ 为对数凹函数（提示：证明需用到协方差矩阵 Σ 的特点）。
5. 参考通过MLE推导所得的线性回归模型的凸二次规划求解过程，对通过MAP推导所得的目标函数求其最优解，并比较两者二次项系数矩阵（即 $\mathbf{x}^\top \mathbf{A} \mathbf{x} + \mathbf{b}^\top \mathbf{x} + c$ 中的 $\mathbf{A}$ ）的区别，回答MAP为何能够解决MLE非满秩的问题。

☺ 拓展阅读：在最优化问题的判别与求解过程中经常会涉及矩阵运算，例如求导等，可参考《The Matrix Cookbook》

（<https://www.math.uwaterloo.ca/~hwolkowi/matrixcookbook.pdf>）。

The top banner features the Fudan University logo on the left, which includes the university's name in English ('FUDAN UNIVERSITY') and Chinese ('復旦大學') along with the founding year '1905'. To the right of the logo are several interlocking blue gears. Some of these gears contain white icons: a building, a graduation cap, a medical cross, a person silhouette, and an atomic symbol. The background of the banner is a light blue gradient that transitions into a dark blue curved shape on the far right.

人工智能的数学基础

08 梯度下降法

李 斌

复旦大学 计算机科学技术学院

迭代下降

- 例：假设 $f: \mathbb{R}^2 \rightarrow \mathbb{R}$ 为地理坐标 (x_1, x_2) 到山脉海拔 y 的映射，从任意一点出发到达山谷最低点： $\operatorname{argmin} f(\mathbf{x})$
- 盲人下山：通过脚下的坡度来判断下山的**方向** $\mathbf{d}$ 和**步长** α ，走一步判断一次直到到达谷底（**迭代下降**）



迭代下降

■ 迭代下降的一般算法如下

算法：迭代下降

1. 起始坐标 $\mathbf{x}^{[0]} \in \mathbb{R}^D$, $t = 0$
 2. **while** 终止条件未达到 **do**
 3. 选择当前坐标 $\mathbf{x}^{[t]}$ 处的下降方向 $\mathbf{d}^{[t]}$
 4. 选择步长 $\alpha^{[t]}$ 计算 $\mathbf{x}^{[t]} + \alpha^{[t]} \mathbf{d}^{[t]}$ 满足 $f(\mathbf{x}^{[t]} + \alpha^{[t]} \mathbf{d}^{[t]}) < f(\mathbf{x}^{[t]})$
 5. 更新坐标 $\mathbf{x}^{[t+1]} = \mathbf{x}^{[t]} + \alpha^{[t]} \mathbf{d}^{[t]}$
 6. $t \leftarrow t + 1$
 7. **end while**
-




■ 关键问题：如何选择 $\mathbf{d}^{[t]}$ 和 $\alpha^{[t]}$ ？

梯度下降法

- 定义：假设 $f: \mathbb{R}^D \rightarrow \mathbb{R}$ 连续可微，若 $\mathbf{d} \in \mathbb{R}^D$ 能使 $\mathbf{d}^\top \nabla f(\mathbf{x}) < 0$ 则称其为在点 $\mathbf{x}$ 处的下降方向
- 梯度 $\nabla f(\mathbf{x})$ 方向为上升最快的方向， $-\nabla f(\mathbf{x})$ 为下降最快的方向
- 若迭代下降中 $\mathbf{d}^{[t]} = -\nabla f(\mathbf{x}^{[t]})$ 称为**梯度下降**

$$\mathbf{x}^{[t+1]} = \mathbf{x}^{[t]} - \alpha^{[t]} \nabla f(\mathbf{x}^{[t]})$$

$-\nabla f(\mathbf{x})$ 与 $\mathbf{d}^\top$ 之间的角度 $\in (90^\circ, 270^\circ)$



梯度下降法

- 例：使用梯度下降法优化对数几率回归模型参数

$$\min_{w,b} \sum_{i=1}^n [-y_i(wx_i + b) + \log(1 + e^{wx_i+b})]$$

令 $\mathbf{w} = \begin{bmatrix} w \\ b \end{bmatrix}$, $\mathbf{x}_i = \begin{bmatrix} x_i \\ 1 \end{bmatrix}$, $\mathbf{y} = [y_1, \dots, y_n]^\top$, $\mathbf{X} = [\mathbf{x}_1, \dots, \mathbf{x}_n]^\top$, 原目标函数可写为

$$\min_{\mathbf{w}} \sum_{i=1}^n -y_i \mathbf{w}^\top \mathbf{x}_i + \log(1 + e^{\mathbf{w}^\top \mathbf{x}_i})$$

目标函数的梯度

$$\nabla f(\mathbf{w}) = \frac{\partial \left\{ \sum_{i=1}^n -y_i \mathbf{w}^\top \mathbf{x}_i + \log(1 + e^{\mathbf{w}^\top \mathbf{x}_i}) \right\}}{\partial \mathbf{w}} = \sum_{i=1}^n \left[\mathbf{x}_i \left(\frac{e^{\mathbf{w}^\top \mathbf{x}_i}}{1 + e^{\mathbf{w}^\top \mathbf{x}_i}} - y_i \right) \right]$$

梯度下降参数更新公式: $\mathbf{w}^{[t+1]} = \mathbf{w}^{[t]} - \alpha^{[t]} \nabla f(\mathbf{w}^{[t]})$

梯度下降法

- 假设 $f: \mathbb{R}^D \rightarrow \mathbb{R}$ 可微且为凸函数，全局最优解 $\mathbf{x}^*$ 存在， ∇f 为 Lipschitz 连续，即对任意 $\mathbf{x}, \mathbf{y} \in \text{dom}(f)$ 有 $\|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\| \leq L\|\mathbf{x} - \mathbf{y}\|$ ^①

直观理解为 ∇f 变化不是太快

- 定理（梯度下降的收敛性）：步长 $\alpha \leq \frac{1}{L}$ 的梯度下降以 $O\left(\frac{1}{t}\right)$ 收敛，即


$$f(\mathbf{x}^{[t]}) - f(\mathbf{x}^*) \leq \frac{\|\mathbf{x}^{[0]} - \mathbf{x}^*\|^2}{2\alpha t}$$

- 证明：
- 1、 $f(\mathbf{x}^{[t]})$ 每轮迭代严格下降： $f(\mathbf{x}^{[t+1]}) \leq f(\mathbf{x}^{[t]}) - \frac{\alpha}{2} \|\nabla f(\mathbf{x}^{[t]})\|^2$
 - 2、每轮误差界： $f(\mathbf{x}^{[t+1]}) - f(\mathbf{x}^*) \leq \frac{1}{2\alpha} (\|\mathbf{x}^{[t]} - \mathbf{x}^*\|^2 - \|\mathbf{x}^{[t+1]} - \mathbf{x}^*\|^2)$
 - 3、使用裂项求和完成证明


^①满足该性质的函数 f 称为 L -smooth。

步长控制


- 在迭代下降过程中，不仅要选择下降方向 $\mathbf{d}^{[t]}$ ，还要选择步长 $\alpha^{[t]}$
- 最简单的策略即固定步长： $\alpha^{[t]} = \alpha > 0$ ，但 α 太小会导致收敛很慢， α 太大则会导致难以收敛
- 自适应步长 $\alpha^{[t]}$ 具有更好的收敛性



α 太小收敛很慢



α 太大难以收敛，在极值点附近来回跳



自适应步长 $\alpha^{[t]}$ 更快收敛


步长控制

- 精确线搜索：在每一步迭代中使用最优步长

$$\alpha^{[t]} = \arg \min_{\alpha \in \mathbb{R}_{\geq 0}} f(\mathbf{x}^{[t]} + \alpha \mathbf{d}^{[t]})$$

- 当上式中 $\mathbf{d}^{[t]} = -\nabla f(\mathbf{x}^{[t]})$ 时即为**最速下降法**

最速下降法每次更新的轨迹都和上一次垂直，且只要 $\nabla f(\mathbf{x}^{[t]}) \neq \mathbf{0}$ ，肯定会下降





步长控制


- 精确线搜索每一步迭代都需要解一个单变量优化问题，计算量大且不一定有效，因此可以不需要最优步长，仅需“足够好”的步长
- 控制步长的一个比较自然的想法是让 $\alpha^{[t]}$ 随时间衰减
- 例：使用梯度下降法求如下函数的最小值

$$f(x) = \begin{cases} \frac{1}{2}x^2, & \text{if } |x| \leq \delta \\ \delta \left(|x| - \frac{1}{2}\delta \right), & \text{otherwise} \end{cases}$$

$\alpha^{[t]} = \frac{10}{t}$ 很快收敛



曲率与步长



- 回顾使用二阶泰勒展开式近似平滑函数的局部特性




$$f(\mathbf{x}) \approx f(\mathbf{a}) + (\mathbf{x} - \mathbf{a})^\top \nabla f(\mathbf{a}) + \frac{1}{2} (\mathbf{x} - \mathbf{a})^\top \nabla^2 f(\mathbf{a}) (\mathbf{x} - \mathbf{a})$$

函数值在 $\mathbf{a}$
点与 f 匹配

斜率在 $\mathbf{a}$ 点
与 f 匹配

曲率在 $\mathbf{a}$ 点
与 f 匹配

- 可通过观察海森矩阵 $\mathbf{H} = \nabla^2 f(\mathbf{x}^{[t]})$ 讨论曲率对于梯度下降步长的影响
- $\mathbf{H}$ 的特征向量 $\mathbf{v}_{\max}$ 和 $\mathbf{v}_{\min}$ 分别指向曲率最大和最小的方向，如果 $\mathbf{H}$ 的条件数 $\frac{|\lambda_{\max}|}{|\lambda_{\min}|}$ 很大则称 $\mathbf{H}$ 为病态的



曲率与步长

- 在 $\mathbf{x}'$ 附近对 f 二阶泰勒展开 ($\mathbf{g} = \nabla f$) 可得

$$f(\mathbf{x}) \approx f(\mathbf{x}') + (\mathbf{x} - \mathbf{x}')^\top \mathbf{g} + \frac{1}{2}(\mathbf{x} - \mathbf{x}')^\top \mathbf{H}(\mathbf{x} - \mathbf{x}')$$

- 把梯度迭代 $\mathbf{x} = \mathbf{x}' - \alpha \mathbf{g}$ 代入上式可得

$$f(\mathbf{x}' - \alpha \mathbf{g}) \approx f(\mathbf{x}') - \alpha \mathbf{g}^\top \mathbf{g} + \frac{1}{2} \alpha^2 \mathbf{g}^\top \mathbf{H} \mathbf{g}$$



- 若 $\mathbf{g}^\top \mathbf{H} \mathbf{g} > 0$ ，可求解关于 α 的二次函数最优解

$$\alpha^* = \frac{\mathbf{g}^\top \mathbf{g}}{\mathbf{g}^\top \mathbf{H} \mathbf{g}} = \begin{cases} \lambda_{\max}^{-1} & \text{若梯度}\mathbf{g}\text{指向}\mathbf{v}_{\max}, \text{此时步长太大会有问题} \\ \lambda_{\min}^{-1} & \text{若梯度}\mathbf{g}\text{指向}\mathbf{v}_{\min}, \text{此时步长太小会有问题} \end{cases}$$

理想情况下，沿 $\mathbf{v}_{\min}$ 步长应大，沿 $\mathbf{v}_{\max}$ 步长应小，但是梯度下降仅考虑斜率而未考虑曲率

多峰性与鞍点


- 若目标函数为多峰函数^①（例如训练神经网络的损失函数），则优化结果依赖于起始点的选择



^①英文为Multimodel Function，也有译为多模函数。

多峰性与鞍点

- 初始点微小的差异都能导致迭代到不同的极小点，甚至导致不收敛



多峰性与鞍点




■ 梯度下降法有可能会困在鞍点无法逃离

■ 例： $f(x_1, x_2) = x_1^2 - x_2^2$

$$\nabla f(\mathbf{x}) = \begin{bmatrix} 2x_1 \\ -2x_2 \end{bmatrix}$$

$$\mathbf{H} = \nabla^2 f(\mathbf{x}) = \begin{bmatrix} 2 & 0 \\ 0 & -2 \end{bmatrix}$$

沿着 x_1 方向曲率为正 ($\lambda_1 = 2$) ,
沿着 x_2 方向曲率为负 ($\lambda_2 = -2$)




动量梯度下降

- 梯度下降法容易受到病态问题（不同方向曲率相差太大）的影响导致优化路径来回震荡，以及受到鞍点的影响减缓收敛甚至困于鞍点
- 动量梯度下降主要思想：引入“速度” $\mathbf{v}$ ，如果梯度方向持续指向相同就加速，如果梯度方向反转就减速

$$\mathbf{x}^{[t+1]} = \mathbf{x}^{[t]} + \mathbf{v}^{[t+1]}, \text{ 其中 } \mathbf{v}^{[t+1]} = \phi \mathbf{v}^{[t]} - \alpha \nabla f(\mathbf{x}^{[t]}), \phi \in [0,1)$$

ϕ 通常取值0.5, 0.9, 取值为0时即为梯度下降法



动量梯度下降

$$\mathbf{v}^{[1]} = \phi \mathbf{v}^{[0]} - \alpha \nabla f(\mathbf{x}^{[0]})$$

$$\mathbf{x}^{[1]} = \mathbf{x}^{[0]} + \phi \mathbf{v}^{[0]} - \alpha \nabla f(\mathbf{x}^{[0]})$$

$$\mathbf{v}^{[2]} = \phi \mathbf{v}^{[1]} - \alpha \nabla f(\mathbf{x}^{[1]}) = \phi \left(\phi \mathbf{v}^{[0]} - \alpha \nabla f(\mathbf{x}^{[0]}) \right) - \alpha \nabla f(\mathbf{x}^{[1]})$$

$$\mathbf{x}^{[2]} = \mathbf{x}^{[1]} + \phi \left(\phi \mathbf{v}^{[0]} - \alpha \nabla f(\mathbf{x}^{[0]}) \right) - \alpha \nabla f(\mathbf{x}^{[1]})$$

$$\mathbf{v}^{[3]} = \phi \mathbf{v}^{[2]} - \alpha \nabla f(\mathbf{x}^{[2]})$$

$$= \phi \left(\phi \left(\phi \mathbf{v}^{[0]} - \alpha \nabla f(\mathbf{x}^{[0]}) \right) - \alpha \nabla f(\mathbf{x}^{[1]}) \right) - \alpha \nabla f(\mathbf{x}^{[2]})$$

$$\mathbf{x}^{[3]} = \mathbf{x}^{[2]} + \phi \left(\phi \left(\phi \mathbf{v}^{[0]} - \alpha \nabla f(\mathbf{x}^{[0]}) \right) - \alpha \nabla f(\mathbf{x}^{[1]}) \right) - \alpha \nabla f(\mathbf{x}^{[2]})$$

$$= \mathbf{x}^{[2]} + \phi^3 \mathbf{v}^{[0]} - \phi^2 \alpha \nabla f(\mathbf{x}^{[0]}) - \phi \alpha \nabla f(\mathbf{x}^{[1]}) - \alpha \nabla f(\mathbf{x}^{[2]})$$

$$= \mathbf{x}^{[2]} - \alpha \left(\phi^2 \nabla f(\mathbf{x}^{[0]}) + \phi^1 \nabla f(\mathbf{x}^{[1]}) + \phi^0 \nabla f(\mathbf{x}^{[2]}) \right) + \phi^3 \mathbf{v}^{[0]}$$

$$\mathbf{x}^{[t+1]} = \mathbf{x}^{[t]} - \alpha \sum_{i=0}^t \phi^i \nabla f(\mathbf{x}^{[t-i]}) + \phi^{t+1} \mathbf{v}^{[0]}$$

当前前进方向为此前梯度的加权和，权重随间隔时间步衰减

动量梯度下降

- 例：假设动量梯度下降每一步梯度相同都为 $\nabla f(\mathbf{x}^{[t]})$ ， $\phi = 0.9$ ，比较当 $t \rightarrow \infty$ 时步长较之于原始步长 α 的变化情况

由上页知

$$\mathbf{x}^{[t+1]} = \mathbf{x}^{[t]} - \alpha \sum_{i=0}^t \phi^i \nabla f(\mathbf{x}^{[t-i]}) + \phi^{t+1} \mathbf{v}^{[0]}$$

由于梯度都为 $\nabla f(\mathbf{x}^{[t]})$ ，代入上式

$$\begin{aligned} \mathbf{x}^{[t+1]} &= \mathbf{x}^{[t]} - \alpha \nabla f(\mathbf{x}^{[t]}) \sum_{i=0}^t \phi^i + \phi^{t+1} \mathbf{v}^{[0]} \\ &= \mathbf{x}^{[t]} - \alpha \nabla f(\mathbf{x}^{[t]}) \frac{1-\phi^{t+1}}{1-\phi} + \phi^{t+1} \mathbf{v}^{[0]} \quad \text{等比数列求和} \\ &\Rightarrow \mathbf{x}^{[t]} - \alpha \nabla f(\mathbf{x}^{[t]}) \frac{1}{1-\phi} \quad t \rightarrow \infty \text{求极限} \end{aligned}$$

动量沿着 $-\nabla f(\mathbf{x}^{[t]})$ 方向不断加速最终步长为 $\frac{\alpha}{1-\phi}$ ，代入 $\phi = 0.9$ 可得 10α


动量梯度下降

■ 动量在梯度下降中所起的作用


假设 $\mathbf{v}^{[0]} = 0$ ，由前页可知

$$\begin{aligned}\mathbf{v}^{[3]} &= \phi \left(\phi \left(\phi \mathbf{v}^{[0]} - \alpha \nabla f(\mathbf{x}^{[0]}) \right) - \alpha \nabla f(\mathbf{x}^{[1]}) \right) - \alpha \nabla f(\mathbf{x}^{[2]}) \\ &= -\phi^2 \alpha \nabla f(\mathbf{x}^{[0]}) - \phi \alpha \nabla f(\mathbf{x}^{[1]}) - \alpha \nabla f(\mathbf{x}^{[2]})\end{aligned}$$

如果梯度方向持续
指向相同就加速




如果梯度方向反转就减速



动量梯度下降



■ 例： $f(x_1, x_2) = \frac{x_1^2}{2} + 10x_2^2$ ，假设 $\mathbf{x}^{[0]} = \begin{bmatrix} 10 \\ 1 \end{bmatrix}$ ， $\alpha = 0.1$

相较于动量梯度下降，梯度下降（黑线）表现出明显的之字形优化轨迹；但如果动量过大（红线），可能会错失最小值点



动量梯度下降

■ 例： $f(x_1, x_2) = x_1^2 - x_2^2$ ，假设 $\mathbf{x}^{[0]} = \begin{bmatrix} -0.5 \\ 0.001 \end{bmatrix}$ ， $\alpha = 0.1$



梯度下降法在鞍点处会减缓（梯度消失）；但动量梯度下降能够冲出鞍点继续下降

随机梯度下降

- 回顾对数几率回归模型中的优化问题

$$\min_{w,b} \sum_{i=1}^n f_i(w, b)$$

其中 $f_i(w, b) = -y_i(wx_i + b) + \log(1 + e^{wx_i + b})$ 为每一个训练样本对 (x_i, y_i) 上的损失

- 在人工智能中，优化模型参数（即训练模型）的目标函数 $f: \mathbb{R}^D \rightarrow \mathbb{R}$ 很多具有这种加性形式

$$f(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n f_i(\mathbf{x})$$

注意这里的 $\mathbf{x}$ 为决策变量，不是训练样本，对应于上式中的 (w, b)

- 当 n 很大时， $\nabla f(\mathbf{x})$ 的计算开销将会非常大

随机梯度下降

- 随机梯度下降：使用梯度的随机子集 $S \subset \{1, 2, \dots, n\}$ 近似梯度

$$\nabla f(\mathbf{x}) = \frac{1}{|S|} \sum_{i \in S} \nabla f_i(\mathbf{x})$$



算法：随机梯度下降

1. 初始化 $\mathbf{x}^{[0]} \in \mathbb{R}^D$, $t = 0$
2. **while** 终止条件未达到 **do**
3. 随机打乱索引并分为 K 个大小为 m 的 minibatch $S_1, \dots, S_K$
4. **for** $k \in \{1, \dots, K\}$ **do**
5. 基于 S_k 计算近似梯度 $\hat{\mathbf{d}}^{[t]} \leftarrow \frac{1}{m} \sum_{i \in S_k} \nabla f_i(\mathbf{x}^{[t]})$
6. 更新梯度 $\mathbf{x}^{[t+1]} = \mathbf{x}^{[t]} - \alpha \hat{\mathbf{d}}^{[t]}$
7. $t \leftarrow t + 1$
8. **end for**
9. **end while**

随机梯度下降

- 随机梯度下降最简单情形是 $m = 1$ ，此时近似梯度 $\hat{\mathbf{d}}^{[t]} = \nabla f_i(\mathbf{x}^{[t]})$ 可能指向非最优方向，甚至可能是非下降方向
- 若随机子集 S 是总体的简单随机样本，则近似梯度 $\hat{\mathbf{d}} = \nabla f_i(\mathbf{x})$ 是梯度 $\mathbf{d} = \nabla f(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\mathbf{x})$ 的一个**无偏估计**



$$E_i[\nabla f_i(\mathbf{x})] = \sum_{i=1}^n \nabla f_i(\mathbf{x}) \cdot \frac{1}{n} = \nabla f(\mathbf{x})$$



随机梯度下降从单步来看可能不是最优的，但平均位移（黑线）朝着正确的方向

随机梯度下降

- 随机梯度下降的梯度更新更快，但也更具有随机性，从而收敛性也因此受到影响，可通过提升minibatch的大小 m 与减小步长 α 缓解
- m 越大，对 $\nabla f(\mathbf{x})$ 近似越准确，方差 $\frac{1}{n} \sum_{i=1}^n \|\nabla f_i(\mathbf{x}) - \nabla f(\mathbf{x})\|^2$ 越小，指向错误方向的风险也越小
- α 越小，走向潜在错误方向的步长越小，从而高方差的作用也越小



随机梯度下降

- 随机梯度下降同样也可以配合动量使用

算法：动量随机梯度下降

1. 初始化 $\mathbf{x}^{[0]} \in \mathbb{R}^D$, $t = 0$
2. **while** 终止条件未达到 **do**
3. 随机打乱索引并分为 K 个大小为 m 的 minibatch $S_1, \dots, S_K$
4. **for** $k \in \{1, \dots, K\}$ **do**
5. 基于 S_k 计算近似梯度 $\hat{\mathbf{d}}^{[t]} \leftarrow \frac{1}{m} \sum_{i \in S_k} \nabla f_i(\mathbf{x}^{[t]})$
6. $\mathbf{v}^{[t+1]} = \phi \mathbf{v}^{[t]} - \alpha \hat{\mathbf{d}}^{[t]}$
7. 更新梯度 $\mathbf{x}^{[t+1]} = \mathbf{x}^{[t]} + \mathbf{v}^{[t+1]}$
8. $t \leftarrow t + 1$
9. **end for**
10. **end while**

本章课后作业

1. 使用梯度下降法优化线性回归模型参数 $\mathbf{w} = \begin{bmatrix} w \\ b \end{bmatrix}$, 即 $\min_{\mathbf{w}} \sum_{i=1}^n (y_i - (wx_i + b))^2$, 写出 $\mathbf{w}^{[t]}$ 的迭代公式。
2. 假设 $f: \mathbb{R}^D \rightarrow \mathbb{R}$ 可微且 ∇f 为 Lipschitz 连续 $\|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\| \leq L\|\mathbf{x} - \mathbf{y}\|$, 证明对任意 $\mathbf{x}, \mathbf{y} \in \text{dom}(f)$, $f(\mathbf{x})$ 有二次上界: $f(\mathbf{y}) \leq f(\mathbf{x}) + (\mathbf{y} - \mathbf{x})^\top \nabla f(\mathbf{x}) + \frac{L}{2} \|\mathbf{y} - \mathbf{x}\|^2$ 。
3. 写出使用最速下降法解二次规划问题 $f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x} + \mathbf{b}^\top \mathbf{x} + c$ 的迭代公式 (需要写出步长 $\alpha^{[t]}$ 的表达式)
4. 基于曲率与步长对梯度下降法的影响, 讨论以下陈述是否正确并给出理由 (假设 $\mathbf{v}_{\max}$ 和 $\mathbf{v}_{\min}$ 分别对应海森矩阵 $\mathbf{H}$ 曲率最大与最小的方向): 理想的下降方向应当沿着 $\mathbf{v}_{\min}$ 采取较大步长、沿着 $\mathbf{v}_{\max}$ 采用较小步长, 但实际上梯度却几乎仅指向 $\mathbf{v}_{\max}$ 。
5. 对函数 $f(x_1, x_2) = \frac{x_1^2}{2} + 10x_2^2$ 分别使用梯度下降与动量梯度下降计算 $\mathbf{x}^{[t]}, t = 1, \dots, 10$ 并进行比较, 假设 $\mathbf{x}^{[0]} = \begin{bmatrix} 5 \\ 1 \end{bmatrix}$, $\alpha = 0.1$, $\phi = 0.5$ 。

☺ 拓展阅读: “Why Momentum Really Works”
(<https://distill.pub/2017/momentum/>)。

The top banner features the Fudan University logo on the left, which includes the university's name in English ('FUDAN UNIVERSITY') and Chinese ('復旦大學') along with the founding year '1905'. To the right of the logo are several interlocking blue gears. Some of these gears contain white icons: a building, a graduation cap, a medical bag with a cross, a person silhouette, and an atomic symbol. The background of the banner is light blue with a dark blue curved shape on the far right.

人工智能的数学基础

09 其他迭代下降法

李 斌



复旦大学 计算机科学技术学院

牛顿法

- 梯度下降法的基本策略是沿一阶最速下降方向迭代：

$$\mathbf{x}^{[t+1]} = \mathbf{x}^{[t]} - \alpha^{[t]} \nabla f(\mathbf{x}^{[t]})$$

- 梯度下降法虽然只需用到一阶信息（斜率），但当 $\nabla^2 f(\mathbf{x}^{[t]})$ 的条件数较大时，收敛速度比较缓慢
- 能否考虑使用**二阶信息**（曲率）改进下降方向？




牛顿法

- 牛顿法^①：是一种在实数域和复数域上近似求解方程的方法，使用函数 $f(\mathbf{x})$ 的泰勒级数的前面几项来寻找方程 $f(\mathbf{x}) = 0$ 的根
- 使用牛顿法寻找连续可微函数 $f: \mathbb{R} \rightarrow \mathbb{R}$ 的根

考虑 f 在 $x^{[t]}$ 处的泰勒展开 $f(x) \approx f(x^{[t]}) + f'(x^{[t]})(x - x^{[t]})$

求解 $f(x^{[t]}) + f'(x^{[t]})(x - x^{[t]}) = 0$ 可得

$$x^{[t+1]} = x^{[t]} - \frac{f(x^{[t]})}{f'(x^{[t]})}$$



^①又称为牛顿-拉弗森方法，英文为Newton-Raphson method。

牛顿法

- 导出方法一：把牛顿法用于求解最优化问题，即寻找连续二次可微凸函数 $f: \mathbb{R} \rightarrow \mathbb{R}$ 的最小值，相当于寻找其导函数的根 $f'(x) = 0$


$$x^{[t+1]} = x^{[t]} - \frac{f'(x^{[t]})}{f''(x^{[t]})}$$

自适应步长，导函数斜率小步长大，斜率大步长小

- 当 $f: \mathbb{R}^D \rightarrow \mathbb{R}$ 时，求解 $\nabla f(\mathbf{x}^{[t]}) + \nabla^2 f(\mathbf{x}^{[t]})(\mathbf{x} - \mathbf{x}^{[t]}) = 0$ 可得牛顿法用于求解最优化问题时的迭代公式

$$\mathbf{x}^{[t+1]} = \mathbf{x}^{[t]} - \nabla^2 f(\mathbf{x}^{[t]})^{-1} \nabla f(\mathbf{x}^{[t]})$$

由 $\nabla^2 f(\mathbf{x}^{[t]})$ 的正定性可知，除非 $\nabla f(\mathbf{x}^{[t]}) = 0$ ，否则就有 $-\nabla f(\mathbf{x}^{[t]})^\top \nabla^2 f(\mathbf{x}^{[t]})^{-1} \nabla f(\mathbf{x}^{[t]}) < 0$ ，即牛顿迭代每步都是下降方向；牛顿法根据 $\mathbf{x}^{[t]}$ 处的局部几何特性自适应方向



牛顿法

- 导出方法二：牛顿法用于求解最优化问题时的迭代公式也可通过最小化 f 的二阶泰勒近似得到
- 假设函数 f 在 $\mathbf{x}^{[t]} \in \text{dom}(f)$ 处为凸且二次可微， $\nabla^2 f(\mathbf{x}^{[t]}) \succ 0$ 可逆，考虑 f 在 $\mathbf{x}^{[t]}$ 处的二阶泰勒近似

$$f(\mathbf{x}^{[t]} + \mathbf{d}) \approx f(\mathbf{x}^{[t]}) + \nabla f(\mathbf{x}^{[t]})^\top \mathbf{d} + \frac{1}{2} \mathbf{d}^\top \nabla^2 f(\mathbf{x}^{[t]}) \mathbf{d}$$

将上式右边看作 $\mathbf{d}$ 的二次函数并求其最小值

$$\mathbf{d}^* = \underset{\mathbf{d} \in \mathbb{R}^D}{\operatorname{argmin}} \left\{ f(\mathbf{x}^{[t]}) + \nabla f(\mathbf{x}^{[t]})^\top \mathbf{d} + \frac{1}{2} \mathbf{d}^\top \nabla^2 f(\mathbf{x}^{[t]}) \mathbf{d} \right\}$$

$$\nabla f(\mathbf{x}^{[t]}) + \nabla^2 f(\mathbf{x}^{[t]}) \mathbf{d} = 0 \quad \Rightarrow \quad \mathbf{d}^* = -\nabla^2 f(\mathbf{x}^{[t]})^{-1} \nabla f(\mathbf{x}^{[t]})$$

牛顿方程牛顿方向

$$\text{由上可得 } \mathbf{x}^{[t+1]} = \mathbf{x}^{[t]} + \mathbf{d}^* = \mathbf{x}^{[t]} - \nabla^2 f(\mathbf{x}^{[t]})^{-1} \nabla f(\mathbf{x}^{[t]})$$

牛顿法


- 例：对比梯度下降法（黑线）与牛顿法（蓝线）的优化路径

$$f(x_1, x_2) = \frac{1}{2}(10x_1^2 + x_2^2) + 5 \log(1 + \exp(-x_1 - x_2))$$

$$\nabla f(x_1, x_2) = \begin{bmatrix} 10x_1 - \frac{5}{1+a} \\ x_2 - \frac{5}{1+a} \end{bmatrix}$$

$$\nabla^2 f(x_1, x_2) = \begin{bmatrix} 10 + \frac{5a}{(1+a)^2} & \frac{5a}{(1+a)^2} \\ \frac{5a}{(1+a)^2} & 1 + \frac{5a}{(1+a)^2} \end{bmatrix}$$

其中 $a = \exp(x_1 + x_2)$



牛顿法

- 对于二次型凸函数（ $\mathbf{A}$ 满秩），从任意起始点 $\mathbf{x}^{[0]} \in \mathbb{R}^D$ 开始，使用牛顿法可以一步到达极小点，即 $\mathbf{x}^{[1]} = \mathbf{x}^*$


$$f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^\top \mathbf{A}\mathbf{x} - \mathbf{b}^\top \mathbf{x} + c$$

梯度为 $\nabla f(\mathbf{x}) = \mathbf{A}\mathbf{x} - \mathbf{b}$ ，海森矩阵为 $\nabla^2 f(\mathbf{x}) = \mathbf{A}$

（由于 $\mathbf{A}$ 满秩，可知 $\nabla f(\mathbf{x}) = \mathbf{0}$ 时有唯一全局最小值，此时 $\mathbf{x}^* = \mathbf{A}^{-1}\mathbf{b}$ ）

把 $\nabla f(\mathbf{x})$ 和 $\nabla^2 f(\mathbf{x})$ 代入牛顿迭代公式

$$\begin{aligned}\mathbf{x}^{[1]} &= \mathbf{x}^{[0]} - \nabla^2 f(\mathbf{x}^{[0]})^{-1} \nabla f(\mathbf{x}^{[0]}) \\ &= \mathbf{x}^{[0]} - \mathbf{A}^{-1}(\mathbf{A}\mathbf{x}^{[0]} - \mathbf{b}) \\ &= \mathbf{A}^{-1}\mathbf{b} = \mathbf{x}^*\end{aligned}$$



牛顿法

- 例：使用牛顿法求解 $f(x_1, x_2) = \frac{3}{2}x_1^2 + \frac{1}{2}x_2^2 - x_1x_2 - x_1$ 的极值，假设初始点 $\mathbf{x}^{[0]} = \begin{bmatrix} -2 \\ 4 \end{bmatrix}$

梯度为 $\nabla f(\mathbf{x}) = \begin{bmatrix} 3x_1 - x_2 - 1 \\ -x_1 + x_2 \end{bmatrix}$ ，带入 $\mathbf{x}^{[0]} = \begin{bmatrix} -2 \\ 4 \end{bmatrix}$ 可得 $\nabla f(\mathbf{x}^{[0]}) = \begin{bmatrix} -11 \\ 6 \end{bmatrix}$

海森矩阵为 $\nabla^2 f(\mathbf{x}^{[0]}) = \begin{bmatrix} 3 & -1 \\ -1 & 1 \end{bmatrix} \succ 0$

把 $\nabla f(\mathbf{x}^{[0]})$ 和 $\nabla^2 f(\mathbf{x}^{[0]})$ 代入牛顿迭代公式

$$\begin{aligned}\mathbf{x}^{[1]} &= \mathbf{x}^{[0]} - \nabla^2 f(\mathbf{x}^{[0]})^{-1} \nabla f(\mathbf{x}^{[0]}) \\ &= \begin{bmatrix} -2 \\ 4 \end{bmatrix} - \begin{bmatrix} 3 & -1 \\ -1 & 1 \end{bmatrix}^{-1} \begin{bmatrix} -11 \\ 6 \end{bmatrix} = \begin{bmatrix} -2 \\ 4 \end{bmatrix} - \begin{bmatrix} -\frac{5}{2} \\ \frac{7}{2} \end{bmatrix} = \begin{bmatrix} \frac{1}{2} \\ \frac{1}{2} \end{bmatrix}\end{aligned}$$

此时 $\nabla f(\mathbf{x}^{[1]}) = \begin{bmatrix} \frac{3}{2} - \frac{1}{2} - 1 \\ -\frac{1}{2} + \frac{1}{2} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$ ，又 $\nabla^2 f(\mathbf{x}) \succ 0$ ，即 $\mathbf{x}^{[1]}$ 为 f 的全局最小点


牛顿法

- 仿射不变性是牛顿法的一个重要性质，给定函数 f 和非奇异矩阵 $\mathbf{A} \in \mathbb{R}^{D \times D}$ ，令 $\mathbf{x} = \mathbf{A}\mathbf{y}$ 且 $g(\mathbf{y}) = f(\mathbf{A}\mathbf{y})$ ，则函数 g 上的牛顿迭代公式为

$$\begin{aligned}\mathbf{y}^{[t+1]} &= \mathbf{y}^{[t]} - \nabla^2 g(\mathbf{y}^{[t]})^{-1} \nabla g(\mathbf{y}^{[t]}) \\ &= \mathbf{y}^{[t]} - [\mathbf{A}^\top \nabla^2 f(\mathbf{x}^{[t]}) \mathbf{A}]^{-1} \mathbf{A}^\top \nabla f(\mathbf{x}^{[t]}) \\ &= \mathbf{y}^{[t]} - \mathbf{A}^{-1} \nabla^2 f(\mathbf{x}^{[t]})^{-1} \nabla f(\mathbf{x}^{[t]})\end{aligned}$$

$$\Rightarrow \mathbf{A}\mathbf{y}^{[t+1]} = \mathbf{A}\mathbf{y}^{[t]} - \nabla^2 f(\mathbf{x}^{[t]})^{-1} \nabla f(\mathbf{x}^{[t]})$$

$$\Rightarrow \mathbf{x}^{[t+1]} = \mathbf{x}^{[t]} - \nabla^2 f(\mathbf{x}^{[t]})^{-1} \nabla f(\mathbf{x}^{[t]})$$



- 如果坐标轴处于不同尺度，梯度下降法会受到影响，而牛顿法则可以自适应

回顾第八章中的曲率与步长，例如 $f(x_1, x_2) = x_1^2 + \frac{x_2^2}{4}$

牛顿法的收敛性

- 假设函数 $f: \mathbb{R}^D \rightarrow \mathbb{R}$ 二阶连续可微，且海森矩阵在最优点 $\mathbf{x}^*$ 的一个邻域 $N_\delta(\mathbf{x}^*)$ 内是Lipschitz连续的，即对任意 $\mathbf{x}, \mathbf{y} \in N_\delta(\mathbf{x}^*)$ 存在常数 $L > 0$ 使得 $\|\nabla^2 f(\mathbf{x}) - \nabla^2 f(\mathbf{y})\| \leq L\|\mathbf{x} - \mathbf{y}\|$
- 定理（牛顿法的收敛性）：如果上述函数 $f(\mathbf{x})$ 在最优点 $\mathbf{x}^*$ 处满足 $\nabla f(\mathbf{x}^*) = 0$ ， $\nabla^2 f(\mathbf{x}^*) \succ 0$ ，则对于牛顿法有如下结论：如果 $\mathbf{x}^{[0]}$ 离 $\mathbf{x}^*$ 足够近，则
 - 1、迭代点列 $\{\mathbf{x}^{[t]}\}$ Q-二次收敛到 $\mathbf{x}^*$
 - 2、 $\{\|\nabla f(\mathbf{x}^{[t]})\|\}$ Q-二次收敛到0
- 因此牛顿法有很好的局部收敛性

① Q-二次收敛是指，对于序列 $\{\mathbf{x}_k\}$ ， $0 < \lim_{k \rightarrow \infty} \frac{\|\mathbf{x}_{k+1} - \mathbf{x}^*\|}{\|\mathbf{x}_k - \mathbf{x}^*\|^2} < \infty$ 。

牛顿法

- **几何解释：** 牛顿法每步迭代相当于在当前位置 $\mathbf{x}^{[t]}$ 拟合一个抛物面，使其与 $f(\mathbf{x}^{[t]})$ 具有相同的斜率与曲率，然后寻找抛物面的极值点作为更新位置 $\mathbf{x}^{[t+1]}$
- 牛顿法收敛速度非常快，但实际应用中具有**局限性**，应用时常以梯度类算法先求得较低精度的解，后用牛顿法加速

1、 $\mathbf{x}^{[0]}$ 需要距离最优解充分近


初始点离最优值点较远时候迭代不稳定（局部收敛性），因而算法可能不收敛

2、 $\nabla^2 f(\mathbf{x}^*)$ 需为正定矩阵

若非正定，牛顿方向可能并非下降方向，可能前进至极大点或鞍点

3、计算与存储复杂度很高

需要求海森矩阵的逆 $O(D^3)$ 与存储海森矩阵 $O(D^2)$



割线法

- 割线法^①：是一种求根算法，它使用一系列割线的根逼近函数 $f(\mathbf{x})$ 的根，可以认为是牛顿法的近似

回顾牛顿法的迭代公式 $x^{[t+1]} = x^{[t]} - \frac{f(x^{[t]})}{f'(x^{[t]})}$


使用有限差分近似 f 在 $x^{[t]}$ 的导数

$$f'(x^{[t]}) \approx \frac{f(x^{[t]}) - f(x^{[t-1]})}{x^{[t]} - x^{[t-1]}}$$

由泰勒展开 $f(x) \approx f(x^{[t]}) + f'(x^{[t]})(x - x^{[t]})$ 得到

把上式代入牛顿法迭代公式可得：

$$x^{[t+1]} = x^{[t]} - f(x^{[t]}) \frac{x^{[t]} - x^{[t-1]}}{f(x^{[t]}) - f(x^{[t-1]})}$$



^①英文为Secant method。

割线法

- 与牛顿法用于求解最优化问题类似，使用割线法寻找连续可微函数 $f: \mathbb{R} \rightarrow \mathbb{R}$ 的最小值，即相当于寻找其导函数的根 $f'(x) = 0$

$$x^{[t+1]} = x^{[t]} - f'(x^{[t]}) \frac{x^{[t]} - x^{[t-1]}}{f'(x^{[t]}) - f'(x^{[t-1]})}$$

无需二阶导数的（近似）
牛顿优化算法

把有限差分用于近似 f''

$$f''(x^{[t]}) \approx \frac{f'(x^{[t]}) - f'(x^{[t-1]})}{x^{[t]} - x^{[t-1]}} = B^{[t]}$$

- 当 $f: \mathbb{R}^D \rightarrow \mathbb{R}$ ，对称矩阵 $\mathbf{B}^{[t]} \in \mathbb{R}^{D \times D}$ 满足 $\nabla f(\mathbf{x}^{[t]}) - \nabla f(\mathbf{x}^{[t-1]}) = \mathbf{B}^{[t]}(\mathbf{x}^{[t]} - \mathbf{x}^{[t-1]})$ 时，割线法用于求解最优化问题时的迭代公式

$$\mathbf{x}^{[t+1]} = \mathbf{x}^{[t]} - \mathbf{B}^{[t]-1} \nabla f(\mathbf{x}^{[t]})$$

割线法

■ 对比

$$\text{牛顿法: } \mathbf{x}^{[t+1]} = \mathbf{x}^{[t]} - \nabla^2 f(\mathbf{x}^{[t]})^{-1} \nabla f(\mathbf{x}^{[t]})$$

$$\text{割线法: } \mathbf{x}^{[t+1]} = \mathbf{x}^{[t]} - \mathbf{B}^{[t]}^{-1} \nabla f(\mathbf{x}^{[t]})$$

■ 若 f 连续二次可微，由割线条件与泰勒一阶近似 $\nabla f(\mathbf{x}^{[t]})$ 可得

$$\mathbf{B}^{[t]}(x^{[t]} - x^{[t-1]}) = \nabla f(\mathbf{x}^{[t]}) - \nabla f(\mathbf{x}^{[t-1]}) \approx \nabla^2 f(\mathbf{x}^{[t]})(x^{[t]} - x^{[t-1]})$$

■ 上式意味着若 $\mathbf{B}^{[t]} \approx \nabla^2 f(\mathbf{x}^{[t]})$ ，割线法可以近似牛顿法

$D = 1$ 时，有唯一 $H^{[t]}$ 满足割线条件

$D > 1$ 时，割线条件 $\nabla f(\mathbf{x}^{[t]}) - \nabla f(\mathbf{x}^{[t-1]}) = \mathbf{B}^{[t]}(x^{[t]} - x^{[t-1]})$ 有无数解

欠定方程组

坐标下降法

- 梯度下降法和牛顿法均需计算目标函数关于决策变量的导数，坐标下降法是一类典型的无导数优化法
- 其核心思想是将多元目标函数的优化问题转化为多个一元目标函数的优化问题，从而实现复杂优化问题的简化求解
- 当目标函数 $f: \mathbb{R}^D \rightarrow \mathbb{R}$ 不可微时可以使用坐标方向作为下降方向，每轮迭代更新一个坐标方向，同时保持其它坐标方向不变


顺序可随机

选择 $d^{[t]} \in \{1, \dots, D\}$, $\mathbf{x}^{[t+1]} = \mathbf{x}^{[t]} + \alpha^{[t]} \mathbf{e}_{d^{[t]}}$

其中 $\alpha^{[t]} = \arg \min_{\alpha \in \mathbb{R}_{\geq 0}} f(\mathbf{x}^{[t]} + \alpha \mathbf{e}_{d^{[t]}})$

精确线搜索

每次只选择一个分量进行
优化（一元目标函数），
其余分量均固定





坐标下降法

- 目标函数 $f(\mathbf{x})$ 可分解为如下形式，且 $g(\mathbf{x})$ 为可微凸函数， $h_d(x_d)$ 均为凸函数，则坐标下降法求得的解一定是原多元目标函数的最优解

$$f(\mathbf{x}) = g(\mathbf{x}) + \sum_d^D h_d(x_d)$$

- 对于一般凸函数坐标下降法可能不收敛于原目标函数全局最优解



坐标下降法

- 例：使用坐标下降法优化带 L_1 正则化的线性回归模型参数

$$\min_{\mathbf{w}} f(\mathbf{w}) = \min_{\mathbf{w}} \frac{1}{2} \|\mathbf{y} - \mathbf{X}\mathbf{w}\|^2 + \lambda \|\mathbf{w}\|_1$$

$$f(\mathbf{w}) \text{ 可写为 } f(\mathbf{w}) = \frac{1}{2} \mathbf{w}^\top \mathbf{X}^\top \mathbf{X} \mathbf{w} + \frac{1}{2} \mathbf{y}^\top \mathbf{y} - \mathbf{w}^\top \mathbf{X}^\top \mathbf{y} + \lambda \|\mathbf{w}\|_1$$

$$\begin{aligned} \text{假设 } \mathbf{X}^\top \mathbf{X} = \mathbf{I} \quad &= \frac{1}{2} \mathbf{w}^\top \mathbf{w} + \frac{1}{2} \mathbf{y}^\top \mathbf{y} + \sum_{d=1}^D (-w_d \mathbf{x}_d^\top \mathbf{y} + \lambda |w_d|) \end{aligned}$$

由于 $|w_d|$ 不可微，需要分情况讨论：

$$w_d > 0 \text{ 时, 则 } \frac{\partial f(\mathbf{w})}{\partial w_d} = w_d - \mathbf{x}_d^\top \mathbf{y} + \lambda = 0 \Rightarrow w_d^* = \mathbf{x}_d^\top \mathbf{y} - \lambda$$

$$w_d < 0 \text{ 时, 则 } \frac{\partial f(\mathbf{w})}{\partial w_d} = w_d - \mathbf{x}_d^\top \mathbf{y} - \lambda = 0 \Rightarrow w_d^* = \mathbf{x}_d^\top \mathbf{y} + \lambda$$

本章课后作业

1. 使用牛顿法优化对数几率回归模型参数 $\min_{w,b} \sum_{i=1}^n [-y_i(wx_i + b) + \log(1 + e^{wx_i+b})]$, 写出迭代公式。
2. 证明牛顿法为拟牛顿法（满足割线条件 $\nabla f(\mathbf{x}^{[t]}) - \nabla f(\mathbf{x}^{[t-1]}) = \mathbf{H}^{[t]}(\mathbf{x}^{[t]} - \mathbf{x}^{[t-1]})$ ）当且仅当 f 为二次型函数，即 $f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^\top \mathbf{A}\mathbf{x} - \mathbf{b}^\top \mathbf{x} + c$ （ $\mathbf{A}$ 满秩）。
3. 第23页例题中若直接使用 $\mathbf{X}^\top \mathbf{X}$ （不简化为 $\mathbf{I}$ ），写出使用坐标下降法优化带 L_1 正则化的线性回归模型参数的迭代公式，

The top banner features the Fudan University logo on the left, which includes the university's name in English ('FUDAN UNIVERSITY') and Chinese ('復旦大學'), along with the founding year '1905'. To the right of the logo are several interlocking blue gears. Some of these gears contain white icons: a building, a graduation cap, a medical cross, a person silhouette, and an atomic symbol. The background of the banner is light blue, transitioning to a dark blue curved shape on the far right.

人工智能的数学基础

10 约束优化


李 斌

复旦大学 计算机科学技术学院

约束优化问题

- 回顾第七章中约束优化问题的一般描述

$$\begin{aligned} & \min_{\mathbf{x}} f(\mathbf{x}) \\ \text{s.t. } & g_i(\mathbf{x}) \leq 0, \quad i = 1, 2, \dots, k \\ & h_j(\mathbf{x}) = 0, \quad j = 1, 2, \dots, l \end{aligned}$$




- $\mathbf{x} = [x_1, x_2, \dots, x_D]^T \in \mathbb{R}^D$ 是 **决策变量**
- $f: \mathbb{R}^D \rightarrow \mathbb{R}$ 是 **目标函数**
- 满足约束条件的 $\mathbf{x}$ 集合 C 称为 **可行域**

$$C = \{\mathbf{x} \in \mathbb{R}^D \mid g_i(\mathbf{x}) \leq 0, h_j(\mathbf{x}) = 0 \forall i, j\}$$

约束优化问题


■ Lasso Regression^①

$$\begin{aligned} \min_{\mathbf{w}} \quad & \frac{1}{n} \sum_{i=1}^n (y_i - \mathbf{w}^\top \mathbf{x}_i)^2 \\ \text{s.t.} \quad & \|\mathbf{w}\|_1 \leq \lambda \end{aligned}$$



■ Ridge Regression


$$\begin{aligned} \min_{\mathbf{w}} \quad & \frac{1}{n} \sum_{i=1}^n (y_i - \mathbf{w}^\top \mathbf{x}_i)^2 \\ \text{s.t.} \quad & \|\mathbf{w}\|_2 \leq \lambda \end{aligned}$$



^①Least Absolute Shrinkage and Selection Operator，即最小绝对值收缩和选择算子。

带约束的凸优化问题

- 约束优化问题中的特例是凸优化问题
- 线性规划（LP）：目标函数 f 和所有约束 g_i 、 h_j 都为线性函数
- 二次规划（QP）：目标函数 f 为二次函数，约束 g_i 、 h_j 为线性函数
- 二次锥规划（SOCP）
- 半定规划（SDP）



线性规划问题

- 线性规划问题可以写成标准形式

$$\begin{aligned} & \max_{\mathbf{x}} \mathbf{c}^T \mathbf{x} \\ \text{s. t. } & \mathbf{Ax} \leq \mathbf{b} \\ & \mathbf{x} \geq 0 \end{aligned}$$

每个维度均满足不等式约束；如果是等式约束可以把 $\mathbf{a}_i^T \mathbf{x} = b_i$ 换成 $\mathbf{a}_i^T \mathbf{x} \geq b_i$ 且 $\mathbf{a}_i^T \mathbf{x} \leq b_i$


- 例：

$$\begin{aligned} & \min_{\mathbf{x}} -x_1 - x_2 \\ \text{s. t. } & x_1 + 2x_2 \leq 1 \\ & 2x_1 + x_2 \leq 1 \\ & x_1, x_2 \geq 0 \end{aligned}$$

$$\begin{aligned} & \max_{\mathbf{x}} [1 \ 1] \mathbf{x} \\ \text{s. t. } & \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix} \mathbf{x} \leq \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\ & \mathbf{x} \geq 0 \end{aligned}$$


线性规划问题

- 线性规划问题通常可用单纯形法或内点法求解，当只有两个决策变量时可用图解法求解
- （接上例）目标函数 $\mathbf{c}^T \mathbf{x}$ 的等高线形成一系列超平面， $\mathbf{c}$ 为梯度且垂直于等高线，最优化问题的解为能够与多边形接触到的最高等高线与其接触点




线性规划问题


- 线性规划问题中每一个不等式约束定义了一个半空间，满足所有不等式约束的点可以形成一个多面体，即可行域，可行域可能有三种情况
- 线性规划问题的最优解为可行域形成的凸多面体的角或面



可行域为空集
无最优解





可行域无上界
无最优解



可行域有界
至少有一个最优解

对偶

- 对偶^①理论在约束优化中发挥重要作用，可用于寻找原始带约束优化问题的下界，在特定条件下这些下界正好对应于最优解
- 在实际应用中，求解对偶问题可能比求解原始问题更高效，因此可以通过求解对偶问题来求得原始问题的解



^①英文为Duality。

线性规划对偶

- 例：一家烘焙店出售50元的巧克力蛋糕和80元的芝士蛋糕，这两款蛋糕含有下表所示成分，一位顾客想确保获得6单位巧克力、10单位糖和8单位芝士的同时最小化支出，问两款蛋糕分别买几份？

	巧克力	糖	芝士
巧克力蛋糕	3	2	2
芝士蛋糕	0	4	5

上述问题可以形式化为线性规划问题：

$$\begin{aligned} \min_{\mathbf{x}} \quad & 50x_1 + 80x_2 \\ \text{s.t.} \quad & 3x_1 \geq 6 \\ & 2x_1 + 4x_2 \geq 10 \\ & 2x_1 + 5x_2 \geq 8 \\ & x_1, x_2 \geq 0 \end{aligned}$$

该问题可直接求解，
例如使用图解法

线性规划对偶

- （接上例）烘焙店店长通知供货商他想购买至少6单位巧克力、10单位糖和8单位芝士以满足顾客的要求，而供货商则思考他如何给巧克力、糖和芝士定价 $\alpha_1, \alpha_2, \alpha_3$ 能够

1) 最大化收益

$$\max_{\alpha} 6\alpha_1 + 10\alpha_2 + 8\alpha_3$$

2) 保证店长从他这购买的原料成本不超过出售价格

$$3\alpha_1 + 2\alpha_2 + 2\alpha_3 \leq 50 \text{ (巧克力蛋糕)}$$

$$4\alpha_2 + 5\alpha_3 \leq 80 \text{ (芝士蛋糕)}$$

- 上述问题即为原问题的**对偶问题**， $\alpha_1, \alpha_2, \alpha_3$ 称为对偶变量

线性规划对偶

- 对偶的直观理解：最小化问题可以考虑目标函数的下界，如何得到上述问题的下界？

$$\begin{array}{ll}\min_{\mathbf{x}} & 50x_1 + 80x_2 \\ \text{s.t.} & 3x_1 \geq 6 \quad \times 5 \\ & 2x_1 + 4x_2 \geq 10 \quad \times 5 \\ & 2x_1 + 5x_2 \geq 8 \quad \times 12 \\ & x_1, x_2 \geq 0\end{array}$$

对三个不等式约束乘上系数并相加可得一个下界

$$5(3x_1) + 5(2x_1 + 4x_2) + 12(2x_1 + 5x_2) \geq 5 \times 6 + 5 \times 10 + 12 \times 8$$

$$49x_1 + 80x_2 \geq 176$$

因为 $x_1 \geq 0$

$$50x_1 + 80x_2 \geq 49x_1 + 80x_2 \geq 176$$

线性规划对偶

- （接上页）该下界并不是最好的，为了**最大化**下界，可把系数5, 5, 12替换为 $\alpha_1, \alpha_2, \alpha_3$ ，此时

$$\begin{aligned} 50x_1 + 80x_2 &\geq \alpha_1(3x_1) + \alpha_2(2x_1 + 4x_2) + \alpha_3(2x_1 + 5x_2) \\ &= (3\alpha_1 + 2\alpha_2 + 2\alpha_3)x_1 + (4\alpha_2 + 5\alpha_3)x_2 \end{aligned}$$

为了使第一个不等号成立，需满足 $3\alpha_1 + 2\alpha_2 + 2\alpha_3 \leq 50$ 、 $4\alpha_2 + 5\alpha_3 \leq 80$

$$\geq 6\alpha_1 + 10\alpha_2 + 8\alpha_3$$

- 即可导出对偶问题

$$\begin{aligned} \max_{\alpha} \quad & 6\alpha_1 + 10\alpha_2 + 8\alpha_3 \\ \text{s.t.} \quad & 3\alpha_1 + 2\alpha_2 + 2\alpha_3 \leq 50 \\ & 4\alpha_2 + 5\alpha_3 \leq 80 \\ & \alpha \geq 0 \end{aligned}$$

线性规划对偶

原始问题 (Primal)

$$\begin{aligned} \min_{\mathbf{x}} \quad & \mathbf{c}^\top \mathbf{x} \\ \text{s.t.} \quad & \mathbf{Ax} \geq \mathbf{b} \\ & \mathbf{x} \geq 0 \end{aligned}$$

对偶问题 (Dual)

$$\begin{aligned} \max_{\alpha} \quad & \alpha^\top \mathbf{b} \\ \text{s.t.} \quad & \alpha^\top \mathbf{A} \leq \mathbf{c}^\top \\ & \alpha \geq 0 \end{aligned}$$

- 弱对偶性：对偶函数的值始终是原始问题目标函数的一个下界

$$g(\alpha) = \alpha^\top \mathbf{b} \leq \alpha^\top \mathbf{Ax} \leq \mathbf{c}^\top \mathbf{x} = f(\mathbf{x})$$

- 强对偶性：若一个线性规划问题有最优解，则其对偶问题有最优解，且最优值相等，即 $\mathbf{c}^\top \mathbf{x}^* = \alpha^{*\top} \mathbf{b}$
- 此时可通过解决对偶问题求解原始问题，尤其是当原始问题有很多约束和很少变量，可以显著提升求解效率

线性规划对偶

- 线性规划问题还可以有其他形式的定义，例如带有等式约束

$$\begin{aligned} \min_{\mathbf{x}} \quad & \mathbf{c}^\top \mathbf{x} \\ \text{s. t.} \quad & \mathbf{Ax} \leq \mathbf{b} \\ & \mathbf{Gx} = \mathbf{h} \end{aligned}$$

- 类似地，也可通过原始问题的下界导出对应的对偶问题

$$\begin{aligned} \max_{\alpha, \beta} \quad & -\mathbf{b}^\top \alpha - \mathbf{h}^\top \beta \\ \text{s. t.} \quad & -\mathbf{A}^\top \alpha - \mathbf{G}^\top \beta = \mathbf{c} \\ & \alpha \geq 0 \end{aligned}$$

$$\alpha^\top \times \text{原始问题不等式约束} + \beta^\top \times \text{原始问题等式约束} \leq 0$$

线性规划对偶

- 上页的线性规划问题形式提供了另一个视角，建立起了线性规划对偶与更为一般的**拉格朗日对偶**之间的联系

$$\mathbf{c}^\top \mathbf{x} \geq \mathbf{c}^\top \mathbf{x} + \boldsymbol{\alpha}^\top (\mathbf{A}\mathbf{x} - \mathbf{b}) + \boldsymbol{\beta}^\top (\mathbf{G}\mathbf{x} - \mathbf{h}) = \mathcal{L}(\mathbf{x}, \boldsymbol{\alpha}, \boldsymbol{\beta})$$

- 若 S 为原始问题的可行域， $f(\mathbf{x}^*)$ 为原始问题的最优值，则对于 $\boldsymbol{\alpha} \geq 0$ 与任意 $\boldsymbol{\beta}$ ，以下弱对偶性成立

$$f(\mathbf{x}^*) \geq \min_{\mathbf{x} \in S} \mathcal{L}(\mathbf{x}, \boldsymbol{\alpha}, \boldsymbol{\beta}) \geq \min_{\mathbf{x}} \mathcal{L}(\mathbf{x}, \boldsymbol{\alpha}, \boldsymbol{\beta}) = g(\boldsymbol{\alpha}, \boldsymbol{\beta})$$

- 以上表明 $g(\boldsymbol{\alpha}, \boldsymbol{\beta})$ 是 $f(\mathbf{x}^*)$ 的下界，称为拉格朗日对偶函数

$$g(\boldsymbol{\alpha}, \boldsymbol{\beta}) = \begin{cases} -\mathbf{b}^\top \boldsymbol{\alpha} - \mathbf{h}^\top \boldsymbol{\beta}, & \text{若 } \mathbf{c} = -\mathbf{A}^\top \boldsymbol{\alpha} - \mathbf{G}^\top \boldsymbol{\beta} \\ -\infty, & \text{否则} \end{cases}$$

非线性约束规划

- 约束优化问题的一般形式，其中 f, g_i, h_j 均可为非线性函数

$$\begin{aligned} & \min_{\mathbf{x}} f(\mathbf{x}) \\ \text{s. t. } & g_i(\mathbf{x}) \leq 0, \quad i = 1, 2, \dots, k \\ & h_j(\mathbf{x}) = 0, \quad j = 1, 2, \dots, l \end{aligned}$$

- 例：直接求解

$$\begin{aligned} & \min_x 2 - x^2 \\ \text{s. t. } & x - 1 = 0 \end{aligned}$$

$$x^* = 1, f(x^*) = 1$$

$$\begin{aligned} & \min_{\mathbf{x}} -2 + x_1^2 + 2x_2^2 \\ \text{s. t. } & x_1^2 + x_2^2 - 1 = 0 \end{aligned}$$

$$\mathbf{x}^* = \begin{bmatrix} \pm 1 \\ 0 \end{bmatrix}, f(\mathbf{x}^*) = -1$$

非线性约束规划

- 在大多数情况下，约束规划问题无法直接求解，有没有一种通用的方法可以用于求解一般非线性约束规划问题呢？

$$\begin{aligned} & \min_{\mathbf{x}} f(\mathbf{x}) \\ \text{s. t. } & g_i(\mathbf{x}) \leq 0, \quad i = 1, 2, \dots, k \\ & h_j(\mathbf{x}) = 0, \quad j = 1, 2, \dots, l \end{aligned}$$

- 把上述非线性约束规划问题转化为拉格朗日函数，其中对偶变量 $\alpha_i \geq 0$ 与 β_j 称为拉格朗日乘子^①

$$\mathcal{L}(\mathbf{x}, \boldsymbol{\alpha}, \boldsymbol{\beta}) = f(\mathbf{x}) + \sum_{i=1}^k \alpha_i g_i(\mathbf{x}) + \sum_{j=1}^l \beta_j h_j(\mathbf{x})$$


^①英文为Lagrange multipliers。

非线性约束规划

- 例：假设有一个挤奶工要去奶牛场挤奶，但在挤奶前她首先需要在附近的河里清洗桶，她想尽快到达奶牛场，问如何选择最优的洗桶点 P

目标为寻找在沿河点 P 能够最小化总距离 $f(P) = d(M, P) + d(P, C)$ ，对应的优化问题可以形式化为


$$\begin{aligned} \min_{x_1, x_2} & f(x_1, x_2) \\ \text{s. t.} & h(x_1, x_2) = 0 \end{aligned}$$




非线性约束规划

■ （接上例）可以通过几何解释找到最优解 P 吗？

- 1、令 M 和 C 为一系列以其为焦点的椭圆
- 2、找到能够接触到河流 $h(x_1, x_2)$ 的最小椭圆
- 3、把接触点定义为 P



$$d(F_1, P) + d(P, F_2) = 2a$$



非线性约束规划


- （接上例）回顾梯度与等高线是正交的，由于 f 的等高线与 h 正好接触，因此两者的梯度平行， β 称为**拉格朗日乘子**

$$\nabla f(P) = -\beta \nabla h(P) \quad \text{梯度平行}$$
$$h(x_1, x_2) = 0 \quad \text{P在} h \text{上}$$

观察到以上即为 $\nabla \mathcal{L}(\mathbf{x}, \boldsymbol{\beta}) = 0$


$\mathcal{L}(\mathbf{x}, \boldsymbol{\beta}) = f(\mathbf{x}) + \beta h(\mathbf{x})$ 为拉格朗日函数

$$\begin{bmatrix} \nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}, \beta) \\ \nabla_{\beta} \mathcal{L}(\mathbf{x}, \beta) \end{bmatrix} = \begin{bmatrix} \nabla f(\mathbf{x}) + \beta \nabla h(\mathbf{x}) \\ h(\mathbf{x}) \end{bmatrix} = 0$$



非线性约束规划

- 类似思想可以拓展到不等式约束 $g_i(\mathbf{x}) \leq 0$ ，但解会有两种可能情况：内部解与边界解



内部解：解在可行域内，约束 $g_i(\mathbf{x}) \leq 0$ 不起作用，即 $\alpha_i = 0$

边界解：解在可行域边界上 $g_i(\mathbf{x}) = 0$ ，存在 $\alpha_i^* > 0$ 使 $\nabla_{\mathbf{x}} f(\mathbf{x}^*) = -\alpha_i \nabla_{\mathbf{x}} g_i(\mathbf{x}^*)$

拉格朗日对偶

- 拉格朗日函数如下（其中 $\alpha_i \geq 0, \beta_j$ 为拉格朗日乘子）

$$\mathcal{L}(\mathbf{x}, \boldsymbol{\alpha}, \boldsymbol{\beta}) = f(\mathbf{x}) + \sum_{i=1}^k \alpha_i g_i(\mathbf{x}) + \sum_{j=1}^l \beta_j h_j(\mathbf{x})$$

- 定义 $\mathbf{x}$ 的函数 θ_P

$$\theta_P(\mathbf{x}) = \max_{\boldsymbol{\alpha} \geq 0, \boldsymbol{\beta}} \mathcal{L}(\mathbf{x}, \boldsymbol{\alpha}, \boldsymbol{\beta})$$

- 假设给定某个 $\mathbf{x}$ ，如果 $\mathbf{x}$ 违反原始问题的约束条件，即存在某个 i 使得 $g_i(\mathbf{x}) > 0$ ，或者存在某个 j 使得 $h_j(\mathbf{x}) \neq 0$ ，就有 $\theta_P = +\infty$ ，故 θ_P 满足

$$\theta_P(\mathbf{x}) = \begin{cases} f(\mathbf{x}), & \mathbf{x} \text{ 满足原始问题约束} \\ +\infty, & \text{其他} \end{cases}$$

- 因此 $\min_{\mathbf{x}} \theta_P(\mathbf{x}) = \min_{\mathbf{x}} \max_{\boldsymbol{\alpha} \geq 0, \boldsymbol{\beta}} \mathcal{L}(\mathbf{x}, \boldsymbol{\alpha}, \boldsymbol{\beta})$ 满足同等约束条件，与原始最优化问题等价——称为广义拉格朗日函数的**极小极大问题**

拉格朗日对偶

- 定义 $\theta_D = \min_{\mathbf{x}} L(\mathbf{x}, \boldsymbol{\alpha}, \boldsymbol{\beta})$ ，并考虑将其极大化，就能得到广义拉格朗日函数的极大极小问题

$$\max_{\boldsymbol{\alpha}, \boldsymbol{\beta}: \alpha_i \geq 0} \theta_D(\boldsymbol{\alpha}, \boldsymbol{\beta}) = \max_{\boldsymbol{\alpha} \geq 0, \boldsymbol{\beta}} \min_{\mathbf{x}} \mathcal{L}(\mathbf{x}, \boldsymbol{\alpha}, \boldsymbol{\beta})$$

- 将上述问题转换为带约束的优化问题，即可得到原始问题的对偶问题

$$\begin{aligned} \max_{\boldsymbol{\alpha}, \boldsymbol{\beta}} \theta_D(\boldsymbol{\alpha}, \boldsymbol{\beta}) &= \max_{\boldsymbol{\alpha}, \boldsymbol{\beta}} \min_{\mathbf{x}} \mathcal{L}(\mathbf{x}, \boldsymbol{\alpha}, \boldsymbol{\beta}) \\ \text{s. t. } \alpha_i &\geq 0, \quad i = 1, 2, \dots, k \end{aligned}$$

- 定义原始问题的最优值 $p^* = \min_{\mathbf{x}} \theta_P(\mathbf{x})$ ，对偶问题的最优值 $d^* = \max_{\boldsymbol{\alpha} \geq 0, \boldsymbol{\beta}} \theta_D(\boldsymbol{\alpha}, \boldsymbol{\beta})$ ，能通过求解对偶问题来获得原始问题的解吗？

拉格朗日对偶

- 定理：当原始问题与对偶问题都有最优解时

$$d^* = \max_{\alpha \geq 0, \beta} \min_{\mathbf{x}} \mathcal{L}(\mathbf{x}, \alpha, \beta) \leq \min_{\mathbf{x}} \max_{\alpha \geq 0, \beta} \mathcal{L}(\mathbf{x}, \alpha, \beta) = p^*$$

$$\theta_D(\alpha, \beta) = \min_{\mathbf{x}} \mathcal{L}(\mathbf{x}, \alpha, \beta) \leq \mathcal{L}(\mathbf{x}, \alpha, \beta) \leq \max_{\alpha \geq 0, \beta} \mathcal{L}(\mathbf{x}, \alpha, \beta) = \theta_P(\mathbf{x})$$

$$\theta_D(\alpha, \beta) \leq \theta_P(\mathbf{x}) \Rightarrow \max_{\alpha \geq 0, \beta} \theta_D(\alpha, \beta) \leq \min_{\mathbf{x}} \theta_P(\mathbf{x}) \Rightarrow \theta_P(\mathbf{x}^*) \geq \theta_D(\alpha^*, \beta^*)$$

- 弱对偶性： $\theta_P(\mathbf{x}^*) \geq \theta_D(\alpha^*, \beta^*)$
- 强对偶性：考虑原始问题和对偶问题， $f(\mathbf{x})$ 和 $g_i(\mathbf{x})$ 为凸函数， $h_j(\mathbf{x})$ 是仿射函数，且不等式约束 $g_i(\mathbf{x})$ 严格可行^①，即存在 $\mathbf{x}$ 对所有 i 满足 $g_i(\mathbf{x}) < 0$ ，则存在 $\mathbf{x}^*$ 和 α^*, β^* ，使得 $\mathbf{x}^*$ 是原始问题的解， α^*, β^* 是对偶问题的解，并且 $d^* = p^* = \mathcal{L}(\mathbf{x}^*, \alpha^*, \beta^*)$

^①即Slater条件：原始问题为凸且严格可行（ $\exists \mathbf{x} \forall i g_i(\mathbf{x}) < 0$ ）

拉格朗日对偶

- **定理：** 考虑原始问题和对偶问题， $f(\mathbf{x})$ 和 $g_i(\mathbf{x})$ 为凸函数， $h_j(\mathbf{x})$ 是仿射函数，且不等式约束 $g_i(\mathbf{x})$ 严格可行，则 $\mathbf{x}^*$ 和 α^*, β^* 分别是原始问题和对偶问题的解的充分必要条件是 $\mathbf{x}^*, \alpha^*, \beta^*$ 满足**KKT条件**
- KKT条件
 - 1、 $\nabla_{\mathbf{x}} L(\mathbf{x}^*, \alpha^*, \beta^*) = 0$
 - 2、 $\alpha_i^* g_i(\mathbf{x}^*) = 0$ 为KKT条件的对偶互补条件， $\alpha_i^* > 0$ 时， $g_i(\mathbf{x}^*) = 0$
 - 3、 $\alpha_i^* \geq 0$
 - 4、 $g_i(\mathbf{x}^*) \leq 0$
 - 5、 $h_j(\mathbf{x}^*) = 0$
- 若存在 $\mathbf{x}^*$ 和 α^*, β^* 满足KKT条件，则它们分别为原始问题和对偶问题的解，并且 $d^* = p^*$ ，即对偶问题和原始问题的最优值相同，可以将原始问题转换为对偶问题求解

①全称为Karush-Kuhn-Tucker。

本章课后作业

1. 第10页例题，使用图解法求解买蛋糕问题。
2. 第15页通过原始问题的下界导出对应的对偶问题，写出推导过程。
3. 写出以下二次规划问题 $\nabla \mathcal{L}(\mathbf{x}, \boldsymbol{\beta}) = 0$ 的具体形式：

$$\begin{aligned} \min_{\mathbf{x}} f(\mathbf{x}) &= \frac{1}{2} \mathbf{x}^\top \mathbf{Q} \mathbf{x} \\ \text{s. t. } h(\mathbf{x}) &= \mathbf{C} \mathbf{x} - \mathbf{d} = \mathbf{0} \end{aligned}$$

4. 假设有正例 $\mathbf{x}_1 = [3, 3]^\top$ 和 $\mathbf{x}_2 = [4, 3]^\top$ ，负例 $\mathbf{x}_3 = [1, 1]^\top$ ，基于支持向量机的对偶问题求出 $f(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b = \sum_{n=1}^N \alpha_n y_n \mathbf{x}_n^\top \mathbf{x} + b$ （提示：可手算出结果，需讨论二次函数的极值是否在边界上取到）。